



Licence 3 du Département de Mathématiques de l'Université de Pau et Pays de l'Adour

Notes de cours, Algorithmique et python 4

Quelques résultats d'algèbre linéaire et d'algèbre
numérique, 2024–2026

Sébastien Tordeux¹

1. Équipe projet commune Makutu (INRIA/UPPA/CNRS UMR 5142).

Table des matières

1	Modélisation des problèmes linéaires en dimension finie	6
1.1	Les espaces de Hilbert de dimension finie	6
1.1.1	Définition	6
1.1.2	Produit scalaire et orthogonalité	6
1.1.3	Base orthonormale	8
1.2	Des espaces vectoriels abstraits aux espaces de vecteurs	8
1.2.1	Les vecteurs abstraits et concrets	8
1.2.2	Représentation des endomorphismes par les matrices carrées	9
1.2.3	Changement de base	10
1.2.4	Représentation d'un endomorphisme dans une nouvelle base	10
1.3	Caractère bien posé des problèmes linéaires	11
1.3.1	Injectivité, surjectivité, bijectivité	11
1.3.2	L'adjoint d'un endomorphisme et d'une matrice	12
1.3.3	Décomposition des opérateurs linéaires	13
1.4	Exercice sur l'interpolation de Lagrange	14
1.5	Exercice sur la dérivation des polynômes	16
2	Diagonalisation des matrices symétriques	18
2.1	Rappel sur la diagonalisation des matrices	18
2.1.1	Vecteurs propres et valeurs propres des matrices générales	18
2.1.2	Les matrices diagonalisables	19
2.2	Définition et premières propriétés des matrices orthogonales et hermitiennes	19
2.2.1	Les matrices unitaires	19
2.3	Le théorème spectral	20
2.4	Exercices	22
2.4.1	Exercice sur les produits scalaires définis par les matrices hermitiennes définies positives	22
2.4.2	Exercice sur la diagonalisation d'une matrice tridiagonale	25
2.4.3	Exercice sur la décomposition en valeurs singulières	29
2.5	Annexe sur la résolution des suites bi-récurrentes	30
3	Les normes matricielles	32
3.1	Rappel des notions nécessaires à ce chapitre	32
3.1.1	Décomposition de Jordan d'une matrice générale	32
3.1.2	Les normes sur les espaces vectoriels	33
3.1.3	Technique de preuve pour les suprema	33
3.2	Les normes matricielles	34
3.3	Lien entre le rayon spectral et la norme matricielle	35
3.4	Le théorème de point fixe de Picard	36
3.5	Quelques exercices	36
3.5.1	Exercice sur la norme matricielle 2	36
3.5.2	Exercice sur la norme matricielle infinie	38
3.5.3	Exercice sur les matrices à diagonale dominante	39

3.5.4	Exercice sur l'existence d'une norme matricielle proche du rayon spectral	40
4	Conditionnement d'une matrice	41
4.1	Définition	41
4.2	Conditionnement et résolution des systèmes linéaires	41
4.3	Les préconditionneurs	42
4.3.1	Le cas général	42
4.3.2	Quelques exemples de préconditionneurs	43
4.4	Exercices sur le conditionnement	44
4.4.1	Exercice. Minoration du conditionnement	44
4.4.2	Exercice. Un système mal conditionné	44
5	Factorisation QR par la méthode de Householder	45
5.1	Définition de la factorisation QR	45
5.2	Les symétries orthogonales par rapport à un hyperplan	45
5.3	Méthode de factorisation de Householder	46
5.3.1	Les deux premières étapes	46
5.3.2	Itération de la méthode	48
5.3.3	Conclusion	49
5.4	Exemple d'implémentation en Python	49
5.5	Application à la résolution d'un système linéaire	50
5.5.1	Résolution des systèmes unitaires	50
5.5.2	Résolution des systèmes triangulaires	50
5.6	Exercices.	51
5.6.1	Exercice. Calcul d'un inverse	51
5.6.2	Exercice. Les symétries	52
6	Résolution des problèmes aux valeurs propres par factorisation QR	53
6.1	Rappel sur la décomposition QR	53
6.2	L'algorithme de calcul des valeurs propres	54
6.3	Cadre pour la démonstration du théorème	55
6.4	Preuve de convergence	55
6.4.1	Première décomposition QR	55
6.4.2	Seconde décomposition QR	56
6.4.3	Comparaison des deux développements	58
6.5	Conclusion	58
6.6	Exemple d'implémentation en Python	59
7	Résolution des systèmes surdéterminés par la factorisation QR	61
7.1	Présentation du cadre des systèmes surdéterminés	61
7.2	Résolution par méthode QR	62
7.3	Un exemple d'implémentation en Python	62
8	Méthode du gradient pour l'inversion d'une matrice	64
8.1	Rappel sur la dérivation des fonctions de plusieurs variables	64
8.2	Résolution des systèmes linéaires par méthode de minimisation	65
8.2.1	Cas d'une matrice symétrique définie positive	65
8.2.2	Cas d'une matrice inversible	65
8.3	La méthode du gradient	65
8.3.1	Méthode du gradient à pas fixe	66
8.3.2	Méthode du gradient à pas optimal	66
8.4	Convergence de la méthode du gradient	67
8.4.1	Preuve de convergence	68
8.4.2	Cas particulier du gradient à pas fixe	68
8.4.3	Cas particulier du gradient à pas optimal	69

8.5	Exercices sur la méthode du gradient	69
8.5.1	Majoration de l'erreur	69
8.5.2	Calcul de gradients et de hessienne	69
9	Interpolation de Tchebychev	70
9.1	L'interpolation polynomiale	70
9.2	Le polynôme de Tchebychev	71
9.3	Interpolation de Tchebychev	73
10	Méthode du gradient conjugué	74
10.1	Rappel sur les matrices symétriques	74
10.2	Les espaces de Krylov et la méthode du gradient conjugué	75
10.3	Équation d'optimalité	75
10.4	L'algorithme du gradient conjugué	76
10.5	Restart et convergence de la méthode du gradient conjugué	77
10.6	Exemple d'implémentation du gradient conjugué	78
10.7	Exercices	80
10.7.1	Exercice. Calcul de l'inverse d'une matrice	80
10.7.2	Exercice. Approximation de l'inverse par un polynôme d'ordre 1	80
10.7.3	Approximation de l'inverse d'une matrice par un polynôme matriciel	80
A	Travaux Pratiques 1 : Mise en œuvre numérique de l'algorithme de Gram-Schmidt	83
A.1	Utilisation de google colab	83
A.2	Factorisation QR d'une matrice	84
A.3	L'algorithme de Gram-Schmidt	85
A.4	Mise en œuvre en python	85
A.5	Application à la résolution d'un système linéaire	86
B	Travaux pratiques : transformations géométriques dans $\mathbb{R}^3$	87
B.1	Un programme qui trace un tétraèdre	87
B.2	Projection orthogonale dans $\mathbb{R}^3$	87
B.3	Mise en œuvre python des projections	89
B.4	Symétrie orthogonale dans $\mathbb{R}^3$	89
B.5	Mise en œuvre python des symétries	90
C	Travaux pratiques 2 : Décomposition en valeurs singulières pour compresser les matrices	91
C.1	Produit matrice vecteur	91
C.2	Décomposition en valeurs singulières de A	91
C.3	Évaluation théorique du temps de calcul	92
D	Travaux pratiques 3 : Décomposition régulière singulière	94
D.1	Définition	94
D.2	Exemples de décomposition	94
D.2.1	Décomposition de Jacobi	94
D.2.2	Décomposition de Gauss-Seidel	95
D.3	Mise en œuvre en python	96
D.3.1	Programmation de l'algorithme de Jacobi	96
E	Résolution d'un système surdéterminé	97
F	Travaux pratiques 4 : la méthode du gradient	98
F.1	Le problème de minimisation	98
F.2	Définition et analyse de la méthode numérique	98
F.3	Implémentation	98

Remarque introductive

Chères étudiantes, chers étudiants,

N'hésitez pas à me faire remonter vos corrections et remarques en m'écrivant à l'adresse

`sebastien.tordeux@univ-pau.fr`

J'apporterai les corrections dans le document dont vous trouverez la dernière version sur elearn.

Je remercie à ce titre

- Andréa Lagardère (Doctorante au sein de l'équipe projet commune Makutu)
- Bruno Latre (étudiant au M1 M2A2E) pour leurs corrections.

Je vous rappelle que vous avez sur elearn des exercices d'autoformation au Python. N'hésitez pas à les réaliser. Il faut compter environ une demi-journée pour les réaliser.

Ces notes ne remplacent pas les ouvrages de référence. Pour aller plus loin, je vous conseille en français les livres [1, 2, 3, 9, 10] et en anglais [4, 6, 11, 13]. Les références utilisées dans chaque chapitre sont indiquées au début de celui-ci et rassemblées dans la bibliographie à la fin du document.

Je vous souhaite une bonne lecture.

Chapitre 1

Modélisation des problèmes linéaires en dimension finie

Pour approfondir les notions de ce chapitre, on pourra consulter [2, 3, 9].

1.1 Les espaces de Hilbert de dimension finie

1.1.1 Définition

Soit H un espace vectoriel de dimension finie sur le corps des complexes. Nous rappelons qu'un système de vecteurs $\mathbf{e} = (\vec{e}_1, \vec{e}_2, \dots, \vec{e}_I) \in H^I$, avec $I \in \mathbb{N}$, est générateur si

$$\forall \vec{x} \in H \quad \exists \mathbf{x} = (x_1, x_2, \dots, x_I) \in \mathbb{C}^I \text{ tel que } \vec{x} = \sum_{i=1}^I x_i \vec{e}_i$$

De même, un système est libre si pour tout $\mathbf{x} = (x_1, x_2, \dots, x_I) \in \mathbb{C}^I$, avec $I \in \mathbb{N}$, alors

$$\sum_{i=1}^I x_i \vec{e}_i = \vec{0} \implies x_i = 0 \quad \forall i \in \llbracket 1, I \rrbracket.$$

Définition 1. Une base est un système de vecteurs $\mathbf{e} = (\vec{e}_1, \vec{e}_2, \dots, \vec{e}_I)$ libre et générateur.

Nous rappelons que toutes les bases de l'espace H contiennent le même nombre de vecteurs $\vec{e}_i$. On parle alors de la dimension de H

$$\dim(H) = I.$$

On dit que deux sous-espaces vectoriels H_1 et H_2 de H sont en somme directe si

$$\forall \vec{x} \in H \quad \exists! (\vec{x}_1, \vec{x}_2) \in H_1 \times H_2 \text{ tel que } \vec{x} = \vec{x}_1 + \vec{x}_2.$$

Nous notons

$$H = H_1 \oplus H_2.$$

1.1.2 Produit scalaire et orthogonalité

Lorsque H est équipé d'un produit scalaire $(\cdot, \cdot)_H$ complexe $H \times H \longrightarrow \mathbb{C}$ on dit que c'est un espace préhilbertien. Nous rappelons la définition des produits scalaires

Définition 2. On dit que l'application $(\cdot, \cdot)_H : H \times H \longrightarrow \mathbb{C}$ est un produit scalaire si

$$\left\{ \begin{array}{l} (\vec{x} + \vec{y}, \vec{z})_H = (\vec{x}, \vec{z})_H + (\vec{y}, \vec{z})_H, \\ (\alpha \vec{x}, \vec{y})_H = \alpha (\vec{x}, \vec{y})_H, \\ (\vec{x}, \vec{y})_H = \overline{(\vec{y}, \vec{x})_H}, \\ (\vec{x}, \vec{x})_H = 0 \implies \vec{x} = \vec{0}, \\ (\vec{x}, \vec{x})_H \geq 0. \end{array} \right.$$

On associe à un produit scalaire une norme induite $\|\cdot\|_H : H \longrightarrow \mathbb{R}^+$ définie par

$$\|\vec{x}\|_H := \sqrt{(\vec{x}, \vec{x})_H}$$

Nous avons

Proposition 1. Pour tout $\vec{x}, \vec{y} \in H$ et $\alpha \in \mathbb{C}$, nous avons

$$\left\{ \begin{array}{l} \|\vec{x}\|_H = 0 \implies \vec{x} = \vec{0}. \\ \|\alpha \vec{x}\|_H = |\alpha| \|\vec{x}\|_H \\ |(\vec{x}, \vec{y})_H| \leq \|\vec{x}\|_H \|\vec{y}\|_H \\ \|\vec{x} + \vec{y}\|_H \leq \|\vec{x}\|_H + \|\vec{y}\|_H \end{array} \right.$$

Preuve. Le premier point s'obtient en remarquant que

$$\|\vec{x}\|_H = 0 \implies (\vec{x}, \vec{x})_H = 0 \implies \vec{x} = \vec{0}$$

Le second est conséquence du calcul suivant

$$\|\alpha \vec{x}\|_H = \sqrt{(\alpha \vec{x}, \alpha \vec{x})_H} = \sqrt{\alpha \bar{\alpha} (\vec{x}, \vec{x})_H} = |\alpha| \|\vec{x}\|_H$$

L'inégalité de Cauchy-Schwarz est plus difficile à obtenir. Soit $\theta \in [0, 2\pi[$ défini par

$$e^{i\theta} (\vec{x}, \vec{y})_H = |(\vec{x}, \vec{y})_H|$$

On définit pour $\lambda \in \mathbb{R}$

$$p(\lambda) = \|\lambda e^{i\theta} \vec{x} + \vec{y}\|_H^2 = (\lambda e^{i\theta} \vec{x} + \vec{y}, \lambda e^{i\theta} \vec{x} + \vec{y})_H = \lambda^2 \|\vec{x}\|_H^2 + 2\lambda |(\vec{x}, \vec{y})_H| + \|\vec{y}\|_H^2.$$

C'est un polynôme de degré 2 à valeurs positives. Son discriminant est donc négatif

$$\Delta = 4|(\vec{x}, \vec{y})_H|^2 - 4\|\vec{x}\|_H^2 \|\vec{y}\|_H^2 \leq 0.$$

Il suit

$$4|(\vec{x}, \vec{y})_H|^2 \leq 4\|\vec{x}\|_H^2 \|\vec{y}\|_H^2.$$

On déduit

$$|(\vec{x}, \vec{y})_H| \leq \|\vec{x}\|_H \|\vec{y}\|_H.$$

L'inégalité triangulaire s'obtient de la manière suivante

$$\|\vec{x} + \vec{y}\|_H^2 = (\vec{x} + \vec{y}, \vec{x} + \vec{y})_H = \|\vec{x}\|_H^2 + (\vec{x}, \vec{y})_H + (\vec{y}, \vec{x})_H + \|\vec{y}\|_H^2$$

Nous avons donc

$$\|\vec{x} + \vec{y}\|_H^2 = (\vec{x} + \vec{y}, \vec{x} + \vec{y})_H = \|\vec{x}\|_H^2 + 2\operatorname{Re}(\vec{x}, \vec{y})_H + \|\vec{y}\|_H^2 \leq \|\vec{x}\|_H^2 + 2|(\vec{x}, \vec{y})_H| + \|\vec{y}\|_H^2.$$

Il suit de l'inégalité de Cauchy-Schwarz que

$$\|\vec{x} + \vec{y}\|_H^2 \leq \|\vec{x}\|_H^2 + 2\|\vec{x}\|_H \|\vec{y}\|_H + \|\vec{y}\|_H^2 = (\|\vec{x}\|_H + \|\vec{y}\|_H)^2$$

Définition 3. Soit $(\vec{x}, \vec{y}) \in H^2$. On dit que $\vec{x}$ et $\vec{y}$ sont orthogonaux ($\vec{x} \perp \vec{y}$) si

$$(\vec{x}, \vec{y})_H = 0.$$

Enfin, deux sous-espaces vectoriels H_1 et H_2 de H sont en somme directe orthogonale si

$$H = H_1 \oplus H_2 \text{ et } (\vec{x}_1, \vec{x}_2)_H = 0 \quad \forall (\vec{x}_1, \vec{x}_2) \in H_1 \times H_2$$

Nous notons

$$H = H_1 \overset{\perp}{\oplus} H_2$$

1.1.3 Base orthonormale

On dit qu'une base de H ($\dim(H) = I$)

$$\mathbf{e} = (\vec{e}_1, \vec{e}_2, \dots, \vec{e}_I)$$

est orthonormale si

$$(\vec{e}_i, \vec{e}_j)_H = \delta_{i,j}$$

avec $\delta_{i,j}$ le symbole de Kronecker

$$\delta_{i,j} = 0 \text{ sauf si } i = j \text{ où } \delta_{i,i} = 1$$

Le procédé de Gram-Schmidt permet à partir d'une base non orthonormale

$$\mathbf{w} = (\vec{w}_1, \vec{w}_2, \dots, \vec{w}_I)$$

de définir une base orthonormale

$$\mathbf{e} = (\vec{e}_1, \vec{e}_2, \dots, \vec{e}_I)$$

Algorithme de Gram-Schmidt Initialisation

$$\vec{e}_1 = \frac{\vec{w}_1}{\|\vec{w}_1\|_H}$$

Définition de $\vec{e}_i$ pour $2 \leq i \leq I$

$$\vec{e}_i = \frac{\vec{w}_i - \sum_{j=1}^{i-1} (\vec{w}_i, \vec{e}_j) \vec{e}_j}{\|\vec{w}_i - \sum_{j=1}^{i-1} (\vec{w}_i, \vec{e}_j) \vec{e}_j\|_H}$$

La construction explicite de cette base permet d'affirmer

Théorème 1. On peut toujours munir un espace vectoriel H de dimension finie d'une base orthonormale.

Nous reviendrons sur ce sujet lors du chapitre qui s'intéressera aux décompositions QR des matrices au chapitre A.

1.2 Des espaces vectoriels abstraits aux espaces de vecteurs

1.2.1 Les vecteurs abstraits et concrets

On équipe aussi H d'une base orthonormale $(\vec{e}_i)_{1 \leq i \leq I} \in H^I$. Tout élément $\vec{x} \in H$ admet une représentation unique dans cette base

$$\vec{x} = \sum_{i=1}^I x_i \vec{e}_i.$$

On associe à cette représentation les vecteurs colonne et ligne

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_I \end{bmatrix} \text{ et } \mathbf{e} = [\vec{e}_1, \vec{e}_2, \dots, \vec{e}_I]$$

Le vecteur $\mathbf{x}$ est à coefficients complexes tandis que le vecteur $\mathbf{e}$ est à coefficients vecteurs.
La formule de représentation s'écrit alors

$$\vec{x} = \mathbf{e} \mathbf{x}.$$

Comme la base $(\vec{e}_i)_{1 \leq i \leq I}$ est orthonormale, le produit scalaire entre deux éléments $\vec{x}$ et $\vec{y}$ de H peut être évalué à l'aide du produit scalaire euclidien à valeurs complexes $(\cdot, \cdot)_0$ de $\mathbb{C}^I$

$$(\vec{x}, \vec{y})_H = \left(\sum_{i=1}^I x_i \vec{e}_i, \sum_{j=1}^I y_j \vec{e}_j \right)_H = \sum_{i=1}^I \sum_{j=1}^I x_i \overline{y_j} (\vec{e}_i, \vec{e}_j)_H = \sum_{i=1}^I x_i \overline{y_i} = (\mathbf{x}, \mathbf{y})_0$$

Remarque 1. Le produit scalaire euclidien peut s'écrire comme le produit suivant

$$(\mathbf{x}, \mathbf{y})_0 = \mathbf{y}^* \mathbf{x},$$

avec $\mathbf{y}^*$ le transposé conjugué de $\mathbf{y}$

$$\mathbf{y}^* = (\overline{y_1}, \overline{y_2}, \dots, \overline{y_I}).$$

À un vecteur abstrait $\vec{x} \in H$ correspond un unique vecteur concret $\mathbf{x} \in \mathbb{C}^I$.

1.2.2 Représentation des endomorphismes par les matrices carrées

Soit $\mathcal{M}$ une application linéaire $H \rightarrow H$. Nous allons associer à $\mathcal{M}$ une matrice $M \in \mathbb{C}^{I \times I}$.

Soit $(\vec{w}_j)_{1 \leq j \leq I}$ les images par $\mathcal{M}$ de la base $(\vec{e}_j)_{1 \leq j \leq I}$

$$\vec{w}_j = \mathcal{M} \vec{e}_j$$

Nous représentons les vecteurs $(\vec{w}_j)_{1 \leq j \leq I}$ dans la base $(\vec{e}_i)_{1 \leq i \leq I}$.

$$\vec{w}_j = \sum_{i=1}^I \vec{e}_i M_{i,j},$$

avec $(M_{i,j})_{1 \leq i \leq I}$ les coordonnées de $\vec{w}_j$. Soit $M \in \mathbb{C}^{I \times I}$ la matrice à valeurs complexes de coefficients $M_{i,j}$.
Nous sommes en mesure de calculer $\mathcal{M} \vec{x}$ l'image de $\vec{x} \in H$ par $\mathcal{M}$

$$\vec{y} := \mathcal{M} \vec{x} = \mathcal{M} \left(\sum_{j=1}^I x_j \vec{e}_j \right) = \sum_{j=1}^I x_j \mathcal{M} \vec{e}_j = \sum_{j=1}^I x_j \vec{w}_j = \sum_{i=1}^I \sum_{j=1}^I \vec{e}_i M_{i,j} x_j$$

C'est-à-dire en écrivant ceci comme un produit

$$\vec{y} = \mathcal{M} \vec{x} = \mathbf{e} M \mathbf{x}$$

Les coordonnées du vecteur $\vec{y} \in H$ sont données par

$$\mathbf{y} = M \mathbf{x}.$$

On dit que l'endomorphisme $\mathcal{M}$ est représenté par la matrice M .

1.2.3 Changement de base

On considère une seconde base de l'espace H que l'on range dans un vecteur ligne

$$\mathbf{E} = (\vec{E}_1, \vec{E}_2, \dots, \vec{E}_I)$$

On représente les vecteurs de cette nouvelle base à l'aide de l'ancienne base

$$\vec{E}_i = \sum_{j=1}^I \vec{e}_j P_{j,i}.$$

Cette égalité peut s'écrire de manière compacte en introduisant la matrice $P \in \mathbb{C}^{I \times I}$.

$$\mathbf{E} = \mathbf{e}P.$$

La matrice de passage P étant inversible, nous avons aussi

$$\mathbf{e} = \mathbf{E}P^{-1}.$$

Nous considérons les deux représentations d'un vecteur $\vec{x} \in H$

$$\vec{x} = \sum_{i=1}^I x_i \vec{e}_i = \sum_{i=1}^I X_i \vec{E}_i$$

C'est-à-dire

$$\vec{x} = \mathbf{e}\mathbf{x} = \mathbf{E}\mathbf{X} = \mathbf{e}P\mathbf{X}$$

Nous avons par unicité des coordonnées

$$\mathbf{x} = P\mathbf{X} \text{ ou encore } \mathbf{X} = P^{-1}\mathbf{x}.$$

1.2.4 Représentation d'un endomorphisme dans une nouvelle base

Les expressions $\mathcal{M}\vec{e}_j = \sum_{i=1}^I \vec{e}_i M_{i,j}$ s'écrivent matriciellement dans la base $\mathbf{e} = (\vec{e}_1, \vec{e}_2, \dots, \vec{e}_I)$

$$\mathcal{M}\mathbf{e} = \mathbf{e}M \quad \text{avec } \mathcal{M}\mathbf{e} := (\mathcal{M}\vec{e}_1, \mathcal{M}\vec{e}_2, \dots, \mathcal{M}\vec{e}_I).$$

On se pose alors la question de la représentation de $\mathcal{M}$ dans la base $\mathbf{E} = (\vec{E}_1, \vec{E}_2, \dots, \vec{E}_I)$. En tenant compte des relations,

$$\mathbf{E} = \mathbf{e}P \text{ et } \mathbf{e} = \mathbf{E}P^{-1},$$

nous obtenons

$$\mathcal{M}\mathbf{E}P^{-1} = \mathbf{E}P^{-1}M.$$

Comme P est inversible, nous avons

$$\mathcal{M}\mathbf{E} = \mathbf{E}P^{-1}MP.$$

Dans la base $\mathbf{E} = (\vec{E}_1, \vec{E}_2, \dots, \vec{E}_I)$, la matrice de représentation de $\mathcal{M}$ est

$$P^{-1}MP$$

Ceci introduit la notion de matrice similaire

Définition 4. On dit que les matrices M et $N \in \mathbb{C}^{I \times I}$ sont similaires s'il existe $P \in \mathbb{C}^{I \times I}$ inversible telle que

$$N = P^{-1}MP$$

1.3 Caractère bien posé des problèmes linéaires

1.3.1 Injectivité, surjectivité, bijectivité

On rappelle les notions d'image et de noyau

$$Ker(\mathcal{M}) = \left\{ \vec{x} \in H \mid \mathcal{M}\vec{x} = 0 \right\} \text{ et } R(\mathcal{M}) = \left\{ \vec{y} = \mathcal{M}\vec{x} \mid \vec{x} \in H \right\}$$

$$Ker(M) = \left\{ \mathbf{x} \in \mathbb{C}^I \mid M\mathbf{x} = 0 \right\} \text{ et } R(M) = \left\{ \mathbf{y} = M\mathbf{x} \mid \mathbf{x} \in \mathbb{C}^I \right\}$$

On dit que $\mathcal{M}$ et M sont injectifs ssi

$$Ker(\mathcal{M}) = \{ \vec{0} \} \text{ et } Ker(M) = \{ 0 \}.$$

C'est-à-dire

$$\mathcal{M}\vec{x} = \vec{0} \Rightarrow \vec{x} = \vec{0} \text{ ou encore } M\mathbf{x} = 0 \Rightarrow \mathbf{x} = 0.$$

On dit que $\mathcal{M}$ et M sont surjectifs ssi

$$R(\mathcal{M}) = H \text{ ou encore } R(M) = \mathbb{C}^I.$$

C'est-à-dire

$$\forall \vec{y} \in H \quad \exists \vec{x} \in H \text{ tel que } \vec{y} = \mathcal{M}\vec{x}$$

ou encore

$$\forall \mathbf{y} \in \mathbb{C}^I \quad \exists \mathbf{x} \in \mathbb{C}^I \text{ tel que } \mathbf{y} = M\mathbf{x}.$$

D'après le théorème du rang qui affirme que

$$\dim(Ker(\mathcal{M})) + Rang(\mathcal{M}) = I$$

ou encore

$$\dim(Ker(M)) + Rang(M) = I$$

avec $Rang(\mathcal{M}) = Rang(M) = \dim(R(\mathcal{M})) = \dim(R(M))$ et $\dim(Ker(\mathcal{M})) = \dim(Ker(M))$. On rappelle donc qu'un corollaire du théorème du rang est le suivant

$$M \text{ injectif} \iff M \text{ surjectif} \iff M \text{ bijectif}.$$

ou encore

$$\mathcal{M} \text{ injectif} \iff \mathcal{M} \text{ surjectif} \iff \mathcal{M} \text{ bijectif}.$$

Définition 5. On dit qu'un problème est bien posé, s'il admet exactement une solution.

Il suit donc que

— si $\mathcal{M}$ est injectif (ou surjectif) alors pour tout $\vec{f} \in H$ le problème suivant est bien posé

$$\text{Chercher } \vec{x} \in H \text{ tel que } \mathcal{M}\vec{x} = \vec{f}.$$

— si M est injectif (ou surjectif) alors pour tout $\mathbf{f} \in \mathbb{C}^I$ le problème suivant est bien posé

$$\text{Chercher } \mathbf{x} \in \mathbb{C}^I \text{ tel que } M\mathbf{x} = \mathbf{f}.$$

En effet, la surjectivité implique l'existence d'une solution (comme $\vec{f} \in H$ il existe au moins un $\vec{x} \in H$ tel que $\mathcal{M}\vec{x} = \vec{f}$). Supposons maintenant qu'il existe deux solutions $\vec{x}_1$ et $\vec{x}_2$

$$\mathcal{M}\vec{x}_1 = \vec{f} \text{ et } \mathcal{M}\vec{x}_2 = \vec{f}$$

Nous faisons la différence et tenons compte du fait que $\mathcal{M}$ est linéaire

$$\mathcal{M}(\vec{x}_1 - \vec{x}_2) = \vec{0}$$

Comme $\mathcal{M}$ est injectif, il suit que $\vec{x}_1 - \vec{x}_2 = 0$. C'est-à-dire

$$\vec{x}_1 = \vec{x}_2.$$

1.3.2 L'adjoint d'un endomorphisme et d'une matrice

On rappelle que $\mathcal{M}$ est un opérateur linéaire $H \rightarrow H$, avec $\dim(H) = I$.

Proposition 2. *Il existe un unique opérateur linéaire $\mathcal{M}^* : H \rightarrow H$ qui vérifie*

$$(\mathcal{M}\vec{x}, \vec{y})_H = (\vec{x}, \mathcal{M}^*\vec{y})_H \quad \forall \vec{x}, \vec{y} \in H$$

On dit que $\mathcal{M}^$ est l'adjoint de $\mathcal{M}$.*

Preuve. On introduit une base orthonormale

$$\mathbf{e} = (\vec{e}_1, \vec{e}_2, \dots, \vec{e}_I).$$

de H . Dans cette base on note M la matrice de représentation de $\mathcal{M}$.

Existence : On définit $\mathcal{M}^* : H \rightarrow H$ l'opérateur de matrice de représentation $M^* \in \mathbb{C}^{I \times I}$

$$\mathcal{M}^*\vec{x} = \sum_{i=1}^I \vec{e}_i \sum_{j=1}^I M_{i,j}^* x_j \text{ avec } \vec{x} = \sum_{i=1}^I x_i \vec{e}_i.$$

dont les coefficients sont donnés par

$$M_{i,j}^* = \overline{M_{j,i}}.$$

Nous avons l'identité suivante

$$(M\mathbf{x}, \mathbf{y})_0 = (\mathbf{x}, M^*\mathbf{y})_0$$

En effet,

$$\begin{aligned} (M\mathbf{x}, \mathbf{y})_0 &= \sum_{i=1}^I (M\mathbf{x})_i \overline{y_i} = \sum_{i=1}^I \left(\sum_{j=1}^I M_{i,j} x_j \right) \overline{y_i} = \sum_{i=1}^I \sum_{j=1}^I (M_{i,j} x_j \overline{y_i}) = \sum_{j=1}^I \sum_{i=1}^I (M_{i,j} x_j \overline{y_i}) \\ &= \sum_{j=1}^I x_j \sum_{i=1}^I (\overline{M_{i,j} y_i}) = \sum_{j=1}^I x_j \overline{\sum_{i=1}^I (M_{j,i}^* y_i)} = \sum_{j=1}^I x_j \overline{(M^*\mathbf{y})_j} = (\mathbf{x}, M^*\mathbf{y})_0. \end{aligned} \quad (1.1)$$

Ceci s'écrit aussi sous forme abstraite

$$(\mathcal{M}\vec{x}, \vec{y})_H = (\vec{x}, \mathcal{M}^*\vec{y})_H \quad \forall \vec{x}, \vec{y} \in H.$$

Unicité : On suppose qu'il existe deux opérateurs linéaires $\mathcal{M}_1^*$ et $\mathcal{M}_2^*$ qui vérifient

$$(\vec{x}, \mathcal{M}_1^*\vec{y})_H = (\mathcal{M}\vec{x}, \vec{y})_H \text{ et } (\vec{x}, \mathcal{M}_2^*\vec{y})_H = (\mathcal{M}\vec{x}, \vec{y})_H \quad \forall \vec{x}, \vec{y} \in H$$

On fait la différence entre ces deux égalités

$$(\vec{x}, \mathcal{M}_1^*\vec{y} - \mathcal{M}_2^*\vec{y})_H = 0 \quad \forall \vec{x}, \vec{y} \in H$$

Pour $\vec{x} = \mathcal{M}_1^*\vec{y} - \mathcal{M}_2^*\vec{y}$, nous avons

$$(\mathcal{M}_1^*\vec{y} - \mathcal{M}_2^*\vec{y}, \mathcal{M}_1^*\vec{y} - \mathcal{M}_2^*\vec{y})_H = 0 \quad \forall \vec{y} \in H$$

Il suit du caractère défini du produit scalaire que

$$\mathcal{M}_1^*\vec{y} = \mathcal{M}_2^*\vec{y} \quad \forall \vec{y} \in H.$$

Remarque 2. *Nous avons lors de la preuve précédente démontré que la matrice trans-conjuguée M^* de M est la matrice de représentation de $\mathcal{M}^*$.*

Nous avons aussi l'identité suivante

$$(M^*)^* = M \text{ et } (\mathcal{M}^*)^* = \mathcal{M}.$$

L'adjoint a notamment pour utilité de permettre le calcul de l'image de $\mathcal{M}$ et M à l'aide du résultat suivant

Proposition 3. *Nous avons*

$$R(\mathcal{M}) \overset{\perp}{\oplus} Ker(\mathcal{M}^*) = H \text{ et } R(\mathcal{M}^*) \overset{\perp}{\oplus} Ker(\mathcal{M}) = H$$

ou encore sous forme vectorielle

$$R(M) \overset{\perp}{\oplus} Ker(M^*) = \mathbb{C}^I \text{ et } R(M^*) \overset{\perp}{\oplus} Ker(M) = \mathbb{C}^I$$

Preuve. Soit $\mathbf{x} \in (R(M^*))^\perp$. Nous avons

$$(\mathbf{x}, M^*\mathbf{y})_0 = 0 \quad \forall \mathbf{y} \in \mathbb{C}^I.$$

Il suit que

$$(M\mathbf{x}, \mathbf{y})_0 = 0 \quad \forall \mathbf{y} \in \mathbb{C}^I.$$

On prend alors $\mathbf{y} = M\mathbf{x}$ et nous obtenons que

$$(M\mathbf{x}, M\mathbf{x})_0 = 0.$$

C'est-à-dire

$$M\mathbf{x} = 0.$$

Nous venons de démontrer que $(R(M^*))^\perp \subset Ker(M)$. Si maintenant $\mathbf{x} \in Ker(M)$, nous avons $M\mathbf{x} = 0$ et donc

$$(M\mathbf{x}, \mathbf{y})_0 = 0 \quad \forall \mathbf{y} \in \mathbb{C}^I.$$

Il suit donc que

$$(\mathbf{x}, M^*\mathbf{y})_0 = 0 \quad \forall \mathbf{y} \in \mathbb{C}^I.$$

Donc $\mathbf{x} \in (R(M^*))^\perp$. Nous venons d'obtenir que $Ker(M) \subset (R(M^*))^\perp$. On déduit donc $Ker(M) = (R(M^*))^\perp$. Il suit donc

$$R(M^*) \overset{\perp}{\oplus} Ker(M) = \mathbb{C}^I.$$

Les autres relations s'obtiennent de manière similaire.

Définition 6. *On dit que $\mathcal{M}$ est un opérateur autoadjoint si*

$$\mathcal{M}^* = \mathcal{M}.$$

On dit que M est une matrice hermitienne si

$$M^* = M \text{ c'est-à-dire } M_{i,j} = \overline{M_{j,i}}.$$

Dans ce cas nous avons

$$R(\mathcal{M}) \overset{\perp}{\oplus} Ker(\mathcal{M}) = H \text{ ou encore } R(M) \overset{\perp}{\oplus} Ker(M) = \mathbb{C}^I.$$

1.3.3 Décomposition des opérateurs linéaires

On considère un opérateur linéaire $\mathcal{M} : H \longrightarrow H$ avec H de dimension finie. L'espace H est décomposé sous la forme

$$H = R(\mathcal{M}^*) \overset{\perp}{\oplus} Ker(\mathcal{M})$$

On équipe les deux sous-espaces vectoriels $R(\mathcal{M}^*)$ (avec $\dim(R(\mathcal{M}^*)) = \text{Rang}(\mathcal{M}) = m$) et $Ker(\mathcal{M})$ de bases orthonormales

$$R(\mathcal{M}^*) = \text{Vect}(\vec{e}_1, \dots, \vec{e}_m) \text{ et } Ker(\mathcal{M}) = \text{Vect}(\vec{e}_{m+1}, \dots, \vec{e}_I)$$

Comme $\mathcal{M}\vec{e}_i = 0$ pour tout $i > m$, la matrice de représentation M de $\mathcal{M}$ a pour coefficients

$$M_{i,j} = 0 \quad \text{pour } j > m.$$

On a donc trouvé une base où la matrice a la forme suivante

$$M = \begin{bmatrix} M_{1,1} & \cdots & M_{1,m} & 0 & \cdots & 0 \\ \cdots & \cdots & \cdots & 0 & \cdots & 0 \\ \cdots & \cdots & \cdots & 0 & \cdots & 0 \\ \cdots & \cdots & \cdots & 0 & \cdots & 0 \\ M_{I,1} & \cdots & M_{I,m} & 0 & \cdots & 0 \end{bmatrix}$$

Dans le cas où la matrice est hermitienne, comme $M^* = M$, nous avons

$$M_{i,j} = \overline{M_{j,i}} = 0 \quad \text{pour } i > m.$$

La matrice M a alors la forme suivante

$$M = \begin{bmatrix} M_{1,1} & \cdots & M_{1,m} & 0 & \cdots & 0 \\ \cdots & \cdots & \cdots & 0 & \cdots & 0 \\ M_{m,1} & \cdots & M_{m,m} & 0 & \cdots & 0 \\ 0 & \cdots & 0 & 0 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ 0 & \cdots & 0 & 0 & \cdots & 0 \end{bmatrix}$$

Enfin comme le rang de la matrice M est m , la matrice $M^{red} \in \mathbb{C}^{m \times m}$ de coefficients

$$M_{i,j} \text{ pour } 1 \leq i, j \leq m$$

est inversible. Ceci signifie en fait que l'on peut réduire l'opérateur $\mathcal{M}$ à $R(\mathcal{M})$ et que cela définit un opérateur inversible

$$\mathcal{M}^{red} : R(\mathcal{M}) \longrightarrow R(\mathcal{M}) \quad \vec{x} \longmapsto \mathcal{M}\vec{x}$$

1.4 Exercice sur l'interpolation de Lagrange

On considère l'espace des polynômes de degré au plus I . Cet espace fonctionnel est un espace vectoriel de dimension $I + 1$ dont la base canonique est formée des fonctions définies pour $0 \leq i \leq I$

$$e_i(x) = x^i$$

On introduit $I + 1$ points (dits d'interpolation) deux à deux distincts définis pour $0 \leq k \leq I$

$$X_k \in \mathbb{R} \quad (k \neq k' \implies X_k \neq X_{k'})$$

1. Montrer qu'il existe un unique polynôme de degré au plus I qui vérifie

$$p(X_k) = f_k$$

avec $f_k, 0 \leq k \leq I$, donnés.

2. En déduire que la matrice de Vandermonde suivante est inversible

$$P \in \mathbb{C}^{(I+1) \times (I+1)} \quad \text{et } P_{k,i} = (X_k)^i \text{ pour } 0 \leq k, i \leq I.$$

Réponse. 1. Il suffit d'après le théorème du rang de montrer l'unicité. On agit par l'absurde. On suppose qu'il existe un polynôme de degré d avec $1 \leq d \leq I$ tel qu'il s'annule en $I + 1$ points. D'après le théorème de la moyenne, sa dérivée est un polynôme de degré $d - 1$ qui s'annule en I points. Sa dérivée d -ième est un polynôme de degré 0 qui s'annule en un point. Il suit que $p^{(d)}(x) = 0$. Ceci est impossible car le degré de p est exactement d et $p^{(d)}(x) = d! p_d$.

2. Tout polynôme de degré au plus I s'écrit

$$p(x) = \sum_{j=0}^I p_j x^j = \sum_{j=0}^I p_j e_j(x) = (e_0(x), e_1(x), \dots, e_I(x)) \begin{bmatrix} p_0 \\ p_1 \\ \vdots \\ p_I \end{bmatrix}$$

Imposer la valeur de p au point X_i revient à résoudre le système linéaire

$$\left\{ \begin{array}{l} (e_0(X_0), e_1(X_0), \dots, e_I(X_0)) \\ (e_0(X_1), e_1(X_1), \dots, e_I(X_1)) \\ \dots \\ (e_0(X_I), e_1(X_I), \dots, e_I(X_I)) \end{array} \begin{bmatrix} p_0 \\ p_1 \\ \vdots \\ p_I \end{bmatrix} \right. = \begin{bmatrix} f_0 \\ f_1 \\ \vdots \\ f_I \end{bmatrix}$$

C'est-à-dire

$$\begin{bmatrix} e_0(X_0) & e_1(X_0) & \dots & e_I(X_0) \\ e_0(X_1) & e_1(X_1) & \dots & e_I(X_1) \\ \dots & \dots & \dots & \dots \\ e_0(X_I) & e_1(X_I) & \dots & e_I(X_I) \end{bmatrix} \begin{bmatrix} p_0 \\ p_1 \\ \vdots \\ p_I \end{bmatrix} = \begin{bmatrix} f_0 \\ f_1 \\ \vdots \\ f_I \end{bmatrix}$$

En évaluant la matrice nous obtenons la matrice de Vandermonde

$$\begin{bmatrix} 1 & X_0 & \dots & (X_0)^I \\ 1 & X_1 & \dots & (X_1)^I \\ \dots & \dots & \dots & \dots \\ 1 & X_I & \dots & (X_I)^I \end{bmatrix} \begin{bmatrix} p_0 \\ p_1 \\ \vdots \\ p_I \end{bmatrix} = \begin{bmatrix} f_0 \\ f_1 \\ \vdots \\ f_I \end{bmatrix}$$

Cette matrice carrée est donc inversible d'après la première question.

Rappel de la preuve directe. On définit

$$B_I(x) = \begin{bmatrix} 1 & X_0 & \dots & X_0^I \\ 1 & X_1 & \dots & (X_1)^I \\ \dots & \dots & \dots & \dots \\ 1 & x & \dots & x^I \end{bmatrix}$$

qui vérifie

$$B_I(X_I) = \begin{bmatrix} 1 & X_0 & \dots & X_0^I \\ 1 & X_1 & \dots & (X_1)^I \\ \dots & \dots & \dots & \dots \\ 1 & X_I & \dots & X_I^I \end{bmatrix}$$

Le déterminant est défini par

$$\det(B_I) = \sum_{m \in \llbracket 0, I \rrbracket^{I+1}} \left[\varepsilon_m \prod_{i=0}^I B_{i, m_i} \right].$$

avec $m = (m_0, m_1, \dots, m_I)$ et ε_m le symbole de Levi-Civita. Il suit que $p_I(x) = \det(B_I(x))$ est un polynôme de degré au plus I . D'autre part, en raison du caractère lié des lignes, nous avons pour tout i entre 0 et $I-1$

$$p_I(X_i) = \det(B_I(X_i)) = 0$$

Il suit donc que

$$p_I(x) = \lambda(X_0, X_1, \dots, X_{I-1}) \prod_{i=0}^{I-1} (x - X_i)$$

Le coefficient du monôme de plus grand degré x^I est donné par

$$\lambda(X_0, X_1, \dots, X_{I-1})$$

D'autre part, nous remarquons ensuite grâce à la définition du déterminant que le coefficient du monôme de plus grand degré x^I est aussi donné par

$$\det \begin{bmatrix} 1 & X_0 & \cdots & X_0^{I-1} \\ 1 & X_1 & \cdots & X_1^{I-1} \\ \cdots & \cdots & \cdots & \cdots \\ 1 & X_{I-1} & \cdots & X_{I-1}^{I-1} \end{bmatrix}$$

$$\det \begin{bmatrix} 1 & X_0 & \cdots & X_0^I \\ 1 & X_1 & \cdots & X_1^I \\ \cdots & \cdots & \cdots & \cdots \\ 1 & X_I & \cdots & X_I^I \end{bmatrix} = \det \begin{bmatrix} 1 & X_0 & \cdots & X_0^{I-1} \\ 1 & X_1 & \cdots & X_1^{I-1} \\ \cdots & \cdots & \cdots & \cdots \\ 1 & X_{I-1} & \cdots & X_{I-1}^{I-1} \end{bmatrix} \prod_{i=0}^{I-1} (X_I - X_i)$$

Il suit par récurrence que

$$\det \begin{bmatrix} 1 & X_0 & \cdots & X_0^I \\ 1 & X_1 & \cdots & X_1^I \\ \cdots & \cdots & \cdots & \cdots \\ 1 & X_I & \cdots & X_I^I \end{bmatrix} = \prod_{k=1}^I \prod_{i=0}^{k-1} (X_k - X_i) = \prod_{0 \leq i < k \leq I} (X_k - X_i).$$

Ce déterminant est donc différent de zéro si les points X_k sont deux à deux distincts.

1.5 Exercice sur la dérivation des polynômes

On considère l'espace des polynômes de degré au plus I . Cet espace fonctionnel est un espace vectoriel de dimension $I+1$ dont la base canonique est formée des fonctions e_i définies pour $0 \leq i \leq I$ par

$$x \mapsto x^i.$$

Quelle est la matrice de représentation de l'opérateur de dérivation sur cet espace vectoriel

$$f \mapsto f'?$$

Réponse. Pour $0 \leq i \leq I$, soit $e_i : \mathbb{R} \rightarrow \mathbb{R}$ la fonction définie par $e_i(x) = x^i$. Tout polynôme $p : \mathbb{R} \rightarrow \mathbb{R}$ de degré au plus I peut être représenté sous la forme

$$p(x) = \sum_{i=0}^I p_i x^i = \sum_{i=0}^I p_i e_i(x) = (e_0(x), e_1(x), \dots, e_I(x)) \begin{bmatrix} p_0 \\ p_1 \\ \vdots \\ p_I \end{bmatrix}$$

La dérivée de p est donnée par

$$p'(x) = \sum_{j=0}^I p_j j x^{j-1} = \sum_{j=0}^I e_{j-1}(x) j p_j = \sum_{i=0}^I \sum_{j=0}^I e_i(x) \delta_{i,j-1} j p_j = (e_0(x), e_1(x), \dots, e_I(x)) M \begin{bmatrix} p_0 \\ p_1 \\ \vdots \\ p_I \end{bmatrix}$$

Il suit que la matrice de représentation $M \in \mathbb{R}^{(I+1) \times (I+1)}$ est donnée par

$$M_{i,j} = \delta_{i,j-1}j \quad \text{c'est-à-dire } M = \begin{bmatrix} 0 & 1 & 0 & \cdots & 0 & 0 \\ 0 & 0 & 2 & \cdots & 0 & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & 0 & \cdots & I-1 & 0 \\ 0 & 0 & 0 & \cdots & 0 & I \\ 0 & 0 & 0 & \cdots & 0 & 0 \end{bmatrix}$$

Chapitre 2

Diagonalisation des matrices symétriques

Pour approfondir les notions de ce chapitre, on pourra consulter [2, 3, 13].

2.1 Rappel sur la diagonalisation des matrices

2.1.1 Vecteurs propres et valeurs propres des matrices générales

Soit $M \in \mathbb{C}^{I \times I}$ une matrice. Les modes propres sont les couples $(\mathbf{w}, \lambda) \in H \times \mathbb{C}$, c'est-à-dire les couples vecteurs propres/valeurs propres qui vérifient

$$\mathbf{w} \neq 0 \quad \text{et} \quad M\mathbf{w} = \lambda\mathbf{w}.$$

Les valeurs propres sont les zéros du polynôme caractéristique de M

$$p_M(\lambda) = \det(M - \lambda Id).$$

Nous rappelons que d'après le théorème de d'Alembert, ce polynôme admet au moins une racine. L'ensemble des valeurs propres est appelé le spectre de M et noté

$$Sp(M) = \left\{ \lambda \in \mathbb{C} \mid p_M(\lambda) = 0 \right\} = \left\{ \lambda_j \in \mathbb{C} \mid 1 \leq j \leq J \right\} \text{ avec } J = \text{card}(Sp(M)) \in \llbracket 1, I \rrbracket.$$

On associe à chaque valeur propre λ_j , le sous-espace vectoriel H_j de H dit espace propre

$$H_j = \text{Ker}(M - \lambda_j Id).$$

Ce sous-espace propre est de dimension d_j et est équipé d'une base orthonormale.

$$H_j = \text{Vect}(\mathbf{w}_1^j, \mathbf{w}_2^j, \dots, \mathbf{w}_{d_j}^j)$$

Toutefois, il existe des matrices $M \in \mathbb{C}^{I \times I}$ telles que

$$\sum_{j=1}^J d_j < I \quad \text{et} \quad H \neq H_1 \oplus H_2 \oplus \dots \oplus H_J$$

Un exemple est donné par la matrice

$$M = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$$

qui n'admet que 0 comme valeur propre et n'a qu'un seul vecteur propre.

D'autre part, le plus souvent, les espaces propres ne sont pas deux à deux orthogonaux.

$$H_i \not\perp H_j \text{ si } i \neq j.$$

C'est le cas par exemple de la matrice

$$M = \begin{bmatrix} 2 & 1 \\ 0 & 0 \end{bmatrix}$$

qui admet comme modes propres

$$\lambda_1 = 0, \mathbf{w}_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ -2 \end{bmatrix} \text{ et } \lambda_2 = 2, \mathbf{w}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Enfin, les valeurs propres ne sont pas toujours des nombres réels mais des nombres complexes.

2.1.2 Les matrices diagonalisables

Dans le cas où

$$\sum_{j=1}^J d_j = I,$$

nous avons

$$H = H_1 \oplus H_2 \oplus \cdots \oplus H_J.$$

La matrice est alors diagonalisable. Cela signifie qu'il existe une matrice $P \in \mathbb{C}^{I \times I}$ inversible telle que

$$M = P \Lambda P^{-1}.$$

Les matrices $P \in \mathbb{C}^{I \times I}$ et $\Lambda \in \mathbb{C}^{I \times I}$ sont définies par blocs

$$P = [P_1 \ P_2 \ \cdots \ P_J] \text{ avec } P_j \in \mathbb{C}^{I \times d_j} \text{ et } P_j = \begin{bmatrix} \mathbf{w}_1^j & \mathbf{w}_2^j & \cdots & \mathbf{w}_{d_j}^j \end{bmatrix},$$

$$\Lambda = \begin{bmatrix} \Lambda_1 & 0 & \cdots & 0 & 0 \\ 0 & \Lambda_2 & \cdots & 0 & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ \cdots & \cdots & \cdots & \Lambda_{J-1} & 0 \\ 0 & 0 & \cdots & 0 & \Lambda_J \end{bmatrix} \text{ avec } \Lambda_j = \lambda_j \text{ Id}_{d_j \times d_j}.$$

Bien que les matrices P_j , avec $1 \leq j \leq J$, soient formées de bases orthonormales de H_j , nous avons le plus souvent

$$H_i \not\perp H_j \text{ si } i \neq j.$$

Nous rappelons enfin que toute matrice diagonalisable a pour polynôme annulateur minimal

$$q(\lambda) = \prod_{j=1}^J (\lambda - \lambda_j).$$

2.2 Définition et premières propriétés des matrices orthogonales et hermitiennes

2.2.1 Les matrices unitaires

Définition 7. On dit qu'une matrice $P \in \mathbb{C}^{I \times I}$ est unitaire si les vecteurs $\mathbf{w}_j \in \mathbb{C}^I$ définis par

$$\mathbf{w}_j = (P_{i,j})_{1 \leq i \leq I}$$

forment une base orthonormale

Proposition 4. Si P est une matrice unitaire alors

$$P^*P = PP^* = Id \text{ et } P^* = P^{-1}$$

Preuve. Montrons que $P^*P = Id$

$$(P^*P)_{i,k} = \sum_{j=1}^I P_{i,j}^* P_{j,k} = \sum_{j=1}^I \overline{P_{j,i}} P_{j,k} = \sum_{j=1}^I \overline{(w_i)_j} (w_k)_j = (\mathbf{w}_k, \mathbf{w}_i)_0 = \delta_{i,k} = Id_{i,k}$$

Nous déduisons de $P^*P = Id$ que P^* est l'inverse de P . Nous avons alors

$$PP^* = PP^{-1} = Id$$

Remarque 3. L'identité $PP^* = Id$ signifie que les lignes de P forment une base orthonormale de $\mathbb{C}^I$

Proposition 5. La matrice $P \in \mathbb{C}^{I \times I}$ est une matrice unitaire ssi

$$\|P\mathbf{x}\|_H = \|\mathbf{x}\|_H \quad \forall \mathbf{x} \in H.$$

Preuve. Si P est unitaire, pour tout $\mathbf{x} \in \mathbb{C}^I$, nous avons

$$\|P\mathbf{x}\|^2 = (P\mathbf{x}, P\mathbf{x})_H = (P\mathbf{x})^* P\mathbf{x} = \mathbf{x}^* P^* P\mathbf{x} = \mathbf{x}^* \mathbf{x} = \|\mathbf{x}\|^2.$$

Si $\|P\mathbf{x}\|_H = \|\mathbf{x}\|_H$ pour tout $\mathbf{x} \in \mathbb{C}^I$, alors pour tout $\alpha \in \mathbb{C}$ tel que $|\alpha| = 1$

$$\|P(\mathbf{x} + \alpha\mathbf{y})\|^2 - \|P(\mathbf{x} - \alpha\mathbf{y})\|^2 = \|\mathbf{x} + \alpha\mathbf{y}\|^2 - \|\mathbf{x} - \alpha\mathbf{y}\|^2$$

$$\begin{aligned} (P\mathbf{x} + \alpha P\mathbf{y}, P\mathbf{x} + \alpha P\mathbf{y}) - (P\mathbf{x} - \alpha P\mathbf{y}, P\mathbf{x} - \alpha P\mathbf{y}) &= (\mathbf{x} + \alpha\mathbf{y}, \mathbf{x} + \alpha\mathbf{y}) - (\mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y}) \\ 4\Re[\overline{\alpha}(P\mathbf{x}, P\mathbf{y})] &= 4\Re[\overline{\alpha}(\mathbf{x}, \mathbf{y})] \end{aligned}$$

En prenant $\alpha = 1$ et $\alpha = -i$, on obtient

$$\Re[(P\mathbf{x}, P\mathbf{y})] = \Re[(\mathbf{x}, \mathbf{y})] \text{ et } \Im[(P\mathbf{x}, P\mathbf{y})] = \Im[(\mathbf{x}, \mathbf{y})]$$

C'est-à-dire pour tout $\mathbf{x}$ et $\mathbf{y}$ dans $\mathbb{C}^I$

$$(P\mathbf{x}, P\mathbf{y}) = (\mathbf{x}, \mathbf{y})$$

Pour $\mathbf{x} = \mathbf{e}_i$ et $\mathbf{y} = \mathbf{e}_j$, deux vecteurs de la base canonique

$$(P\mathbf{e}_i, P\mathbf{e}_j) = (\mathbf{e}_i, \mathbf{e}_j) = \delta_{i,j} \text{ c'est-à-dire } (P^*P)_{i,j} = \mathbf{e}_i^* P^* P \mathbf{e}_j = \delta_{i,j}$$

Ce qu'il fallait démontrer

2.3 Le théorème spectral

Nous rappelons qu'une matrice est hermitienne si elle vérifie

$$M^* = M$$

Proposition 6. Toute valeur propre d'une matrice hermitienne $M \in \mathbb{C}^{I \times I}$ est réelle.

Preuve. Soit $(\mathbf{w}, \lambda) \in H \times \mathbb{C}$ qui vérifie

$$\mathbf{w} \neq 0 \text{ et } M\mathbf{w} = \lambda\mathbf{w}$$

Nous avons

$$\lambda(\mathbf{w}, \mathbf{w})_0 = (M\mathbf{w}, \mathbf{w})_0$$

Comme M est hermitienne, $(M\mathbf{w}, \mathbf{w})_0 \in \mathbb{R}$. En effet, nous avons

$$(M\mathbf{w}, \mathbf{w})_0 = (\mathbf{w}, M^*\mathbf{w})_0 = (\mathbf{w}, M\mathbf{w})_0 = \overline{(M\mathbf{w}, \mathbf{w})_0}.$$

Nous en déduisons que la valeur propre est réelle

$$\lambda = \frac{(M\mathbf{w}, \mathbf{w})_0}{\|\mathbf{w}\|_0^2} \in \mathbb{R}.$$

Ceci termine la preuve.

Théorème 2. *Si $M \in \mathbb{C}^{I \times I}$ est une matrice hermitienne, alors M est diagonalisable dans une base orthonormale de vecteurs propres.*

Dit autrement, il existe une matrice $P \in \mathbb{C}^{I \times I}$ unitaire et une matrice $\Lambda \in \mathbb{R}^{I \times I}$ diagonale telles que

$$M = P\Lambda P^*.$$

Preuve. Soit $\lambda_1 \in \mathbb{R}$, une valeur propre de M . La matrice $M - \lambda_1 Id$ est hermitienne car λ_1 est réel. Nous pouvons alors reprendre les arguments de la section 1.3.3 pour décomposer la matrice $M - \lambda_1 Id$.

$$\mathbb{C}^I = \text{Ker}(M - \lambda_1 Id) \overset{\perp}{\oplus} R(M - \lambda_1 Id).$$

Il existe une base orthonormale $\mathbf{e}$ constituée de la réunion

- d'une base orthonormale $\mathbf{e}^1 = (\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_{d_1})$ de $\text{Ker}(M - \lambda_1 Id)$
- d'une base orthonormale $\mathbf{e}^2 = (\mathbf{e}_{d_1+1}, \mathbf{e}_{d_1+2}, \dots, \mathbf{e}_I)$ de $R(M - \lambda_1 Id)$

Nous notons $P_1 \in \mathbb{C}^{I \times I}$ la matrice unitaire dont les colonnes sont formées par les vecteurs qui composent la base orthonormale $\mathbf{e}$. Nous notons $M_1 \in \mathbb{C}^{I \times I}$ la matrice définie par

$$M_1 = P_1^* M P_1 \quad \text{avec } P_1 = \left(\begin{array}{ccc|ccc} (e_1)_1 & \cdots & (e_{d_1})_1 & (e_{d_1+1})_1 & \cdots & (e_I)_1 \\ (e_1)_2 & \cdots & (e_{d_1})_2 & (e_{d_1+1})_2 & \cdots & (e_I)_2 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ (e_1)_I & \cdots & (e_{d_1})_I & (e_{d_1+1})_I & \cdots & (e_I)_I \end{array} \right)$$

Nous remarquons que la matrice M_1 est hermitienne car

$$M_1^* = (P_1^* M P_1)^* = P_1^* M^* (P_1^*)^* = P_1^* M P_1 = M_1.$$

Nous pouvons évaluer les valeurs des d_1 premières colonnes de M_1

$$(M_1)_{i,j} = \mathbf{e}_i^* M \mathbf{e}_j.$$

Pour $1 \leq j \leq d_1$, $M \mathbf{e}_j = \lambda_1 \mathbf{e}_j$ (car $\mathbf{e}_j \in \text{Ker}(M - \lambda_1 Id)$). Donc

$$(M_1)_{i,j} = \lambda_1 \mathbf{e}_i^* \mathbf{e}_j = \lambda_1 (\mathbf{e}_j, \mathbf{e}_i)_0 = \lambda_1 \delta_{i,j}.$$

La matrice M_1 a donc la forme suivante

$$M_1 = \begin{bmatrix} \lambda_1 Id_{d_1 \times d_1} & ?_{d_1 \times (I-d_1)} \\ 0_{(I-d_1) \times d_1} & ?_{(I-d_1) \times (I-d_1)} \end{bmatrix}$$

où la notation $?_{m \times n}$ désigne une matrice de taille m par n et la notation $0_{m \times n}$ désigne la matrice nulle de taille m par n . La matrice M_1 étant hermitienne, nous avons

$$M_1 = \begin{bmatrix} \lambda_1 Id_{d_1 \times d_1} & 0_{d_1 \times (I-d_1)} \\ 0_{(I-d_1) \times d_1} & \widetilde{M}_1 \end{bmatrix}$$

avec $\widetilde{M}_1 \in \mathbb{C}^{(I-d_1) \times (I-d_1)}$ une matrice hermitienne.

Nous avons donc factorisé la matrice M sous la forme

$$M = P_1 \begin{bmatrix} \lambda_1 Id_{d_1 \times d_1} & 0_{d_1 \times (I-d_1)} \\ 0_{(I-d_1) \times d_1} & \widetilde{M}_1 \end{bmatrix} P_1^*$$

avec $P_1 \in \mathbb{C}^{I \times I}$ une matrice unitaire et $\widetilde{M}_1 \in \mathbb{C}^{(I-d_1) \times (I-d_1)}$ une matrice hermitienne.

Nous pouvons alors répéter le raisonnement sur $\widetilde{M}_1$

$$\widetilde{M}_1 = \widetilde{P}_2 \begin{bmatrix} \lambda_2 Id_{d_2 \times d_2} & 0_{d_2 \times (I-d_1-d_2)} \\ 0_{(I-d_1-d_2) \times d_2} & \widetilde{M}_2 \end{bmatrix} \widetilde{P}_2^*$$

avec $\widetilde{P}_2 \in \mathbb{C}^{(I-d_1) \times (I-d_1)}$ une matrice unitaire et $\widetilde{M}_2 \in \mathbb{C}^{(I-d_1-d_2) \times (I-d_1-d_2)}$ une matrice hermitienne. Il suit que

$$M = P_2 M_2 P_2^*$$

avec P_2 une matrice unitaire ($P_2^* P_2 = Id$) donnée par

$$P_2 = P_1 \begin{bmatrix} Id_{d_1 \times d_1} & 0_{d_1 \times (I-d_1)} \\ 0_{(I-d_1) \times d_1} & \widetilde{P}_2 \end{bmatrix}$$

et

$$M_2 = \begin{bmatrix} \lambda_1 Id_{d_1 \times d_1} & 0_{d_1 \times d_2} & 0_{d_1 \times (I-d_1-d_2)} \\ 0_{d_2 \times d_1} & \lambda_2 Id_{d_2 \times d_2} & 0_{d_2 \times (I-d_1-d_2)} \\ 0_{(I-d_1-d_2) \times d_1} & 0_{(I-d_1-d_2) \times d_2} & \widetilde{M}_2 \end{bmatrix}$$

On peut alors itérer le raisonnement pour éliminer le bloc $\widetilde{M}_j$. Ceci termine la preuve.

2.4 Exercices

2.4.1 Exercice sur les produits scalaires définis par les matrices hermitiennes définies positives

On considère une matrice $M \in \mathbb{C}^{I \times I}$ hermitienne définie positive

1. Montrer que M est inversible
2. Montrer que M est diagonalisable
3. Montrer que les valeurs propres de M sont des nombres réels strictement positifs
4. Comment définir les puissances M^s de M pour $s \in \mathbb{R}$?
5. Montrer que cette notion coïncide avec les puissances entières des matrices
6. Montrer que

$$M^{s_1+s_2} = M^{s_1} M^{s_2}$$

7. Montrer que la forme hermitienne

$$(\mathbf{x}, \mathbf{y})_M = (M\mathbf{x}, \mathbf{y})$$

définit un produit scalaire complexe.

8. Montrer que la matrice M^s est hermitienne.
9. Montrer que la norme induite par ce produit scalaire est donnée par

$$\|\mathbf{x}\|_{M^{\frac{1}{2}}} = \|M^{\frac{1}{2}} \mathbf{x}\|_2$$

10. Montrer que

$$\sqrt{\lambda_{\min}(M)} \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_{M^{\frac{1}{2}}} \leq \sqrt{\lambda_{\max}(M)} \|\mathbf{x}\|_2$$

Correction.

1. Soit $\mathbf{x} \in \text{Ker}(M)$ alors $M\mathbf{x} = 0$. Il suit que

$$(M\mathbf{x}, \mathbf{x})_0 = 0$$

Comme M est définie, $\mathbf{x} = 0$

2. Comme M est hermitienne, M est diagonalisable.
3. Nous avons pour tout mode propre de M

$$M\mathbf{w}_p = \lambda_p \mathbf{w}_p \text{ avec } \mathbf{w}_p \neq 0.$$

Nous avons

$$(M\mathbf{w}_p, \mathbf{w}_p) = \lambda_p (\mathbf{w}_p, \mathbf{w}_p) \implies \lambda_p = \frac{(M\mathbf{w}_p, \mathbf{w}_p)}{(\mathbf{w}_p, \mathbf{w}_p)}.$$

Comme M est positive, il suit que $\lambda_p \geq 0$. Comme M est inversible, toutes les valeurs propres de M sont différentes de 0.

4. On introduit une diagonalisation de M

$$M = P\Lambda P^*$$

avec P une matrice unitaire et Λ une matrice diagonale

$$P = \begin{bmatrix} w_1 & w_2 & \cdots & w_I \end{bmatrix} \quad \text{et} \quad \Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_I \end{bmatrix}$$

avec $(w_i, w_j) = \delta_{i,j}$ et $\lambda_i > 0$. On définit

$$M^s = P\Lambda^s P^* \quad \text{avec} \quad \Lambda^s := \begin{bmatrix} \lambda_1^s & 0 & \cdots & 0 \\ 0 & \lambda_2^s & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_I^s \end{bmatrix}$$

5. Il suffit de vérifier que $M^{n+1} = M M^n$

$$M^{n+1} = P\Lambda^{n+1}P^* = P \begin{bmatrix} \lambda_1^{n+1} & 0 & \cdots & 0 \\ 0 & \lambda_2^{n+1} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_I^{n+1} \end{bmatrix} P^*$$

Comme $P^*P = Id$ et $\Lambda^{n+1} = \Lambda^n \Lambda$

$$\begin{bmatrix} \lambda_1^{n+1} & 0 & \cdots & 0 \\ 0 & \lambda_2^{n+1} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_I^{n+1} \end{bmatrix} = \begin{bmatrix} \lambda_1^n & 0 & \cdots & 0 \\ 0 & \lambda_2^n & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_I^n \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_I \end{bmatrix},$$

nous avons

$$M^{n+1} = P\Lambda^n P^* P\Lambda P^* = M^n M.$$

6. Il suffit de répéter la preuve précédente.

7. L'application $(\cdot, \cdot)_M$ est bien une forme car elle associe à un couple de $(\mathbb{C}^I)^2$ un nombre complexe. Elle est aussi sesquilinéaire

$$(\mathbf{x}_1 + \alpha \mathbf{x}_2, \mathbf{y}_1 + \beta \mathbf{y}_2)_M = (M\mathbf{x}_1, \mathbf{y}_1) + \alpha(M\mathbf{x}_2, \mathbf{y}_1) + \bar{\beta}(M\mathbf{x}_1, \mathbf{y}_2) + \alpha\bar{\beta}(M\mathbf{x}_2, \mathbf{y}_2)$$

Elle est positive

$$(\mathbf{x}, \mathbf{x})_M = (M\mathbf{x}, \mathbf{x}) \geq 0$$

Elle est définie

$$(\mathbf{x}, \mathbf{x})_M = (M\mathbf{x}, \mathbf{x}) = 0 \implies \mathbf{x} = 0$$

Elle est hermitienne

$$(\mathbf{x}, \mathbf{y})_M = (M\mathbf{x}, \mathbf{y}) = (\mathbf{x}, M\mathbf{y}) = \overline{(M\mathbf{y}, \mathbf{x})} = \overline{(\mathbf{y}, \mathbf{x})_M}$$

8. Par définition, la matrice M^s est hermitienne

$$(M^s)^* = (P\Lambda^s P^*)^* = P(\Lambda^s)^* P^* = P\Lambda^s P^*$$

comme

$$(\Lambda^s)^* = \begin{bmatrix} \lambda_1^s & 0 & \cdots & 0 \\ 0 & \lambda_2^s & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_I^s \end{bmatrix}^* = \begin{bmatrix} \bar{\lambda}_1^s & 0 & \cdots & 0 \\ 0 & \bar{\lambda}_2^s & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \bar{\lambda}_I^s \end{bmatrix} = \Lambda^s.$$

car les valeurs propres de M sont réelles

9. Nous avons

$$\|\mathbf{x}\|_{M^{\frac{1}{2}}} = \sqrt{(M\mathbf{x}, \mathbf{x})} = \sqrt{(M^{\frac{1}{2}} M^{\frac{1}{2}} \mathbf{x}, \mathbf{x})}$$

Comme la matrice $M^{\frac{1}{2}}$ est hermitienne

$$\|\mathbf{x}\|_{M^{\frac{1}{2}}} = \sqrt{(M^{\frac{1}{2}} \mathbf{x}, M^{\frac{1}{2}} \mathbf{x})} = \|M^{\frac{1}{2}} \mathbf{x}\|_2$$

10. On développe $\mathbf{x} \in \mathbb{C}^I$ et $\mathbf{y} \in \mathbb{C}^I$ sur la base orthonormale $\mathbf{w}_i$

$$\mathbf{x} = \sum_{i=1}^I \alpha_i \mathbf{w}_i \quad \text{et} \quad \mathbf{y} = \sum_{i=1}^I \beta_i \mathbf{w}_i$$

D'après le théorème de Pythagore, nous avons

$$(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^I \sum_{j=1}^I \alpha_i \bar{\beta}_j (\mathbf{w}_i, \mathbf{w}_j) = \sum_{i=1}^I \sum_{j=1}^I \alpha_i \bar{\beta}_j \delta_{i,j} = \sum_{i=1}^I \alpha_i \bar{\beta}_i$$

Nous pouvons aussi obtenir facilement les coordonnées de $M\mathbf{x}$ dans la base $\mathbf{w}_i$

$$M\mathbf{x} = \sum_{i=1}^I \alpha_i M \mathbf{w}_i = \sum_{i=1}^I \alpha_i \lambda_i \mathbf{w}_i$$

Il suit donc que

$$(\mathbf{x}, \mathbf{x})_M = (M\mathbf{x}, \mathbf{x}) = \sum_{i=1}^I \lambda_i \alpha_i \bar{\alpha}_i = \sum_{i=1}^I \lambda_i |\alpha_i|^2$$

Il suit comme il s'agit d'une somme de nombres positifs

$$\lambda_{\min} \sum_{i=1}^I |\alpha_i|^2 \leq (\mathbf{x}, \mathbf{x})_M = (M\mathbf{x}, \mathbf{x}) \leq \lambda_{\max} \sum_{i=1}^I |\alpha_i|^2$$

Nous avons donc

$$\lambda_{\min} \|\mathbf{x}\|^2 \leq (\mathbf{x}, \mathbf{x})_M \leq \lambda_{\max} \|\mathbf{x}\|^2$$

2.4.2 Exercice sur la diagonalisation d'une matrice tridiagonale

On considère la matrice $A \in \mathbb{C}^{I \times I}$ dont tous les éléments sont nuls sauf si $|i - j| = 1$ où

$$A_{i,j} = 1.$$

On pose $u_0 = 0$ et $u_{I+1} = 0$.

1. Montrer que A est diagonalisable
2. Soit $U = (u_1, u_2, \dots, u_I)^T \in \mathbb{C}^I$. Montrer que

$$U^*(A + 2Id)U = \sum_{i=0}^I |u_{i+1} + u_i|^2.$$

3. Montrer que $Sp(A) \subset [-2, +\infty[$
4. Montrer que $-2 \notin Sp(A)$
5. Soit $U = (u_1, u_2, \dots, u_I)^T \in \mathbb{C}^I$. Montrer que

$$U^*(A - 2Id)U = - \sum_{i=0}^I |u_{i+1} - u_i|^2.$$

6. Montrer que $Sp(A) \subset]-\infty, 2]$
7. Montrer que $2 \notin Sp(A)$
8. Montrer que $Sp(A) \subset]-2, 2[$.
9. Montrer que si $\lambda \in \mathbb{R}$ est valeur propre de A alors pour tout $i \in [1, I]$

$$u_{i-1} - \lambda u_i + u_{i+1} = 0 \text{ et } u_0 = 0 \text{ et } u_{I+1} = 0.$$

10. Déterminer toutes les valeurs propres et vecteurs propres de A .

Correction.

1. La matrice A est diagonalisable car elle est symétrique

$$A = \begin{bmatrix} 0 & 1 & 0 & \cdots & 0 & 0 & 0 \\ 1 & 0 & 1 & \cdots & 0 & 0 & 0 \\ 0 & 1 & 0 & \cdots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & 1 & 0 \\ 0 & 0 & 0 & \cdots & 1 & 0 & 1 \\ 0 & 0 & 0 & \cdots & 0 & 1 & 0 \end{bmatrix}$$

2. Calculons U^*AU

$$U^*AU = \sum_{i=1}^I \sum_{j=1}^I \overline{u_i} A_{i,j} u_j = \sum_{i=1}^I \sum_{j=1}^I \overline{u_i} (\delta_{i,j+1} + \delta_{i,j-1}) u_j$$

Nous pouvons évaluer les deux termes

$$\begin{aligned} \sum_{j=1}^I \overline{u_i} (\delta_{i,j+1}) u_j &= \overline{u_i} u_{i-1} \text{ si } i \in [2, I], \\ \sum_{j=1}^I \overline{u_i} (\delta_{i,j-1}) u_j &= 0 \text{ si } i = 1 \end{aligned}$$

Nous avons en posant $u_0 := 0$ dans tous les cas

$$\sum_{j=1}^I \overline{u_i}(\delta_{i,j+1})u_j = \overline{u_i}u_{i-1} \text{ si } i \in \llbracket 1, I \rrbracket$$

De même, avec $u_{I+1} := 0$, nous avons

$$\sum_{j=1}^I \overline{u_i}(\delta_{i,j-1})u_j = \overline{u_i}u_{i+1} \text{ si } i \in \llbracket 1, I \rrbracket$$

Il suit que

$$U^*AU = \sum_{i=1}^I \overline{u_i}u_{i+1} + \sum_{i=1}^I \overline{u_i}u_{i-1}.$$

Nous pouvons faire un changement d'indice sur la seconde somme

$$U^*AU = \sum_{i=1}^I \overline{u_i}u_{i+1} + \sum_{i=0}^{I-1} \overline{u_{i+1}}u_i.$$

Nous avons en tenant compte du fait que $u_0 = u_{I+1} = 0$ que

$$U^*AU = \sum_{i=0}^I \overline{u_i}u_{i+1} + \sum_{i=0}^I \overline{u_{i+1}}u_i.$$

D'autre part, nous avons

$$U^*U = \sum_{i=1}^I \overline{u_i}u_i = \frac{1}{2} \left[\left(\sum_{i=0}^I \overline{u_i}u_i \right) + \left(\sum_{i=0}^I \overline{u_{i+1}}u_{i+1} \right) \right]$$

Nous avons donc

$$U^*(A + 2Id)U = U^*AU + 2U^*U = \sum_{i=0}^I \left(\overline{u_i}u_i + \overline{u_{i+1}}u_i + \overline{u_i}u_{i+1} + \overline{u_{i+1}}u_{i+1} \right)$$

Il suit que

$$U^*(A + 2Id)U = \sum_{i=0}^I \left((\overline{u_{i+1}} + \overline{u_i})(u_{i+1} + u_i) \right) = \sum_{i=0}^I |u_{i+1} + u_i|^2$$

3. La matrice $A + 2Id$ est positive donc

$$Sp(A + 2Id) \subset [0, +\infty[.$$

Il suit que

$$Sp(A) \subset [-2, +\infty[.$$

4. Il suffit de montrer que $Ker(A + 2Id) = \{0\}$. Si $AU + 2U = 0$ alors

$$(AU + 2U, U) = 0.$$

Il suit que

$$\sum_{i=0}^I |u_{i+1} + u_i|^2 = 0 \quad \text{avec } u_0 = 0 \text{ et } u_{I+1} = 0$$

Ainsi $u_{i+1} = -u_i = \dots = (-1)^{i+1}u_0 = 0$ Il suit que $u_i = 0$ pour tout i . Donc $U = 0$.

5. Nous avons

$$U^*(A - 2Id)U = U^*AU - 2U^*U = \sum_{i=0}^I \left(-\overline{u_i}u_i + \overline{u_{i+1}}u_i + \overline{u_i}u_{i+1} - \overline{u_{i+1}}u_{i+1} \right)$$

Il suit que

$$U^*(A - 2Id)U = - \sum_{i=0}^I \left((\overline{u_{i+1}} - \overline{u_i})(u_{i+1} - u_i) \right) = - \sum_{i=0}^I |u_{i+1} - u_i|^2$$

6. $A - 2Id$ est négative donc

$$Sp(A - 2Id) \subset]-\infty, 0]$$

Il suit que

$$Sp(A) \subset]-\infty, 2]$$

7. Il suffit de montrer que $Ker(A - 2Id) = \{0\}$ Soit $U \in Ker(A - 2Id)$. Nous avons $AU - 2U = 0$.

$$(AU - 2U, U) = 0.$$

Il suit que

$$\sum_{i=0}^I |u_{i+1} - u_i|^2 = 0 \quad \text{avec } u_0 = 0 \text{ et } u_{I+1} = 0$$

Ainsi $u_{i+1} = u_i = \dots = u_0 = 0$ Il suit que $u_i = 0$ pour tout i . Donc $U = 0$.

8. Il suffit de regrouper les questions 3, 4, 6 et 7

9. Si λ est valeur propre alors

$$\begin{bmatrix} 0 & 1 & 0 & \cdots & 0 & 0 & 0 \\ 1 & 0 & 1 & \cdots & 0 & 0 & 0 \\ 0 & 1 & 0 & \cdots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & 1 & 0 \\ 0 & 0 & 0 & \cdots & 1 & 0 & 1 \\ 0 & 0 & 0 & \cdots & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ \vdots \\ u_{I-2} \\ u_{I-1} \\ u_I \end{bmatrix} = \lambda \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ \vdots \\ u_{I-2} \\ u_{I-1} \\ u_I \end{bmatrix}$$

C'est-à-dire

$$\begin{cases} u_0 + u_2 = \lambda u_1 \text{ avec } u_0 = 0 \\ u_{i-1} + u_{i+1} = \lambda u_i \text{ pour } 2 \leq i \leq I-1 \\ u_{I-1} + u_{I+1} = \lambda u_I \text{ avec } u_{I+1} = 0 \end{cases}$$

Nous avons donc avec les notations $u_0 = 0$ et $u_{I+1} = 0$

$$\begin{cases} u_0 + u_2 = \lambda u_1 \\ u_{i-1} + u_{i+1} = \lambda u_i \text{ pour } 2 \leq i \leq I-1 \\ u_{I-1} + u_{I+1} = \lambda u_I \end{cases}$$

C'est ce que nous devons démontrer.

10. Nous sommes face à une suite bi-récurrente, voir section 2.5, et nous savons que $\lambda \in]-2, 2[$. Le discriminant du polynôme caractéristique $p(x) = x^2 - \lambda x + 1$ est strictement négatif car $|\lambda| < 2$

$$\Delta = \lambda^2 - 4 < 0.$$

D'autre part le produit des deux racines est 1. Les deux racines conjuguées sont donc de la forme

$$r_+ = \exp(i\theta) \text{ et } r_- = \exp(-i\theta)$$

Nous avons donc

$$u_n = \alpha \exp(in\theta) + \beta \exp(-in\theta).$$

Comme $u_0 = 0$, il suit que

$$\alpha \exp(i0\theta) + \beta \exp(-i0\theta) = \alpha + \beta = 0$$

$$u_n = \alpha \left(\exp(in\theta) - \exp(-in\theta) \right) = 2i\alpha \sin(n\theta).$$

Le complexe α est différent de zéro car $U \neq 0$ D'autre part, on a $u_{I+1} = 0$, il suit que

$$2i\alpha \sin((I+1)\theta) = 0.$$

Ainsi

$$(I+1)\theta = 0 \text{ modulo } \pi.$$

Nous avons identifié des candidats $\mathbf{w}_m \in \mathbb{C}^I$, $m \in \mathbb{Z}$ pour être vecteurs propres

$$(\mathbf{w}_m)_n = \sin\left(\frac{mn\pi}{I+1}\right) \text{ avec } 1 \leq n \leq I.$$

Nous notons d'autre part

$$(\mathbf{w}_m)_0 = (\mathbf{w}_m)_{I+1} = 0.$$

Nous remarquons que pour $1 \leq m \leq I$ nous avons pour $1 \leq n \leq I$

$$(A\mathbf{w}_m)_n = (\mathbf{w}_m)_{n-1} + (\mathbf{w}_m)_{n+1} = \sin\left(\frac{m(n-1)\pi}{I+1}\right) + \sin\left(\frac{m(n+1)\pi}{I+1}\right) = 2 \cos\left(\frac{m\pi}{I+1}\right) \sin\left(\frac{mn\pi}{I+1}\right).$$

Nous venons d'exhiber un système de vecteurs propres $(\mathbf{w}_m)_{1 \leq m \leq I}$ associés aux valeurs propres

$$\lambda_m = 2 \cos\left(\frac{m\pi}{I+1}\right) \in]-2, 2[$$

qui sont deux à deux distinctes car l'application

$$[1, I] \longrightarrow \mathbb{R} \quad m \longmapsto \cos\left(\frac{m\pi}{I+1}\right)$$

est strictement décroissante. Ce système est une base de vecteurs propres car les valeurs propres sont deux à deux distinctes.

Remarque 4. La question du trop grand nombre de vecteurs propres reste entière. Nous remarquons que pour $m = m'(I+1)$

$$(\mathbf{w}_m)_n = \sin(m'n\pi) = 0.$$

Nous avons d'autre part,

$$(\mathbf{w}_{-m})_n = \sin\left(\frac{-mn\pi}{I+1}\right) = -\sin\left(\frac{mn\pi}{I+1}\right) = -(\mathbf{w}_m)_n$$

et

$$(\mathbf{w}_{m+2(I+1)})_n = \sin\left(\frac{mn\pi}{I+1} + 2n\pi\right) = \sin\left(\frac{mn\pi}{I+1}\right) = (\mathbf{w}_m)_n.$$

C'est pourquoi les $(\mathbf{w}_m)_n$ en dehors de $1 \leq m \leq I$ ne fournissent aucun nouveau vecteur propre.

2.4.3 Exercice sur la décomposition en valeurs singulières

Soit $A \in \mathbb{C}^{I \times I}$ une matrice inversible. Nous rappelons que $A^* \in \mathbb{C}^{I \times I}$ et

$$A_{i,j}^* = \overline{A_{j,i}}$$

1. Montrer que A^*A est diagonalisable dans une base orthonormale de vecteurs propres. On note

$$A^*A = P\Lambda P^*$$

avec $P = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_I)$ unitaire et Λ une matrice diagonale définie positive.

2. Montrer que les valeurs propres $\lambda_i \in \mathbb{R}$ de A^*A sont strictement positives.
3. Soit $Q = AP\Lambda^{-\frac{1}{2}}$, montrer que Q est unitaire.
4. Dédurre la décomposition en valeurs singulières de A : il existe deux matrices unitaires P et Q et une matrice diagonale D qui a pour coefficients les racines des valeurs propres de A^*A telles que

$$A = QDP^*$$

Correction.

1. Nous remarquons que la matrice A^*A est hermitienne

$$(A^*A)^* = A^*A^{**} = A^*A$$

Elle est donc diagonalisable

2. La matrice A^*A est aussi positive d'après la théorie de l'adjoint

$$(A^*A\mathbf{x}, \mathbf{x}) = (A\mathbf{x}, A\mathbf{x}) \geq 0$$

La matrice A^*A est aussi définie

$$0 = (A^*A\mathbf{x}, \mathbf{x}) = \|A\mathbf{x}\|^2$$

Ceci implique $A\mathbf{x} = 0$ et $\mathbf{x} = 0$ comme A est inversible. Les valeurs propres de A^*A sont toutes strictement positives.

3. Il nous faut montrer que $Q^*Q = Id$

$$Q^*Q = (AP\Lambda^{-\frac{1}{2}})^*(AP\Lambda^{-\frac{1}{2}}) = \Lambda^{-\frac{1}{2}}P^*A^*AP\Lambda^{-\frac{1}{2}}$$

On a recours à la diagonalisation de A^*A

$$Q^*Q = (AP\Lambda^{-\frac{1}{2}})^*(AP\Lambda^{-\frac{1}{2}}) = \Lambda^{-\frac{1}{2}}P^*P\Lambda P^*P\Lambda^{-\frac{1}{2}}$$

Comme P est unitaire, nous avons $P^*P = Id$. Ainsi, il suit

$$Q^*Q = \Lambda^{-\frac{1}{2}}\Lambda\Lambda^{-\frac{1}{2}} = Id$$

4. Il nous suffit de modifier l'expression

$$Q = AP\Lambda^{-\frac{1}{2}}$$

en tenant compte de $\Lambda^{-\frac{1}{2}}\Lambda^{\frac{1}{2}} = Id$ et de $PP^* = Id$

$$Q = AP\Lambda^{-\frac{1}{2}} \iff Q\Lambda^{\frac{1}{2}}P^* = A.$$

Nous remarquons que la matrice $D = \Lambda^{\frac{1}{2}}$ est une matrice diagonale définie positive.

Remarque 5. Il existe un résultat dans la littérature qui permet aussi de traiter les cas rectangulaires et non inversibles.

Théorème 3 (Décomposition en valeurs singulières). Pour tout $A \in \mathbb{R}^{m \times n}$ de rang p , il existe deux matrices $P \in \mathbb{C}^{n \times p}$ et $Q \in \mathbb{C}^{m \times p}$ et une matrice diagonale définie positive $D \in \mathbb{R}^{p \times p}$ telles que

$$A = QDP^*, \quad P^*P = Id_{p \times p}, \quad Q^*Q = Id_{p \times p} \text{ et } D_{i,i} = \sigma_i$$

avec $\sigma_i = \sqrt{\lambda_i}$ et λ_i la i -ème plus grande valeur propre de A^*A .

On dit que les σ_i , $1 \leq i \leq p$ sont les valeurs singulières de A . On dit que P et Q sont deux matrices unitaires incomplètes.

2.5 Annexe sur la résolution des suites bi-récurrentes

Nous considérons une suite de la forme

$$u_{n+2} + bu_{n+1} + cu_n = 0 \quad \text{pour tout } n \in \mathbb{N}$$

avec $u_0 = \alpha$ et $u_1 = \beta$ donnés.

Réduction d'ordre. La technique classique pour expliciter sa solution est de faire un échange degré contre dimension. On pose

$$\mathbf{Y}_n = \begin{bmatrix} u_n \\ u_{n+1} \end{bmatrix}$$

La condition initiale s'écrit

$$\mathbf{Y}_0 = \begin{bmatrix} u_0 \\ u_1 \end{bmatrix} = \begin{bmatrix} \alpha \\ \beta \end{bmatrix}$$

Il suit que

$$\mathbf{Y}_{n+1} = \begin{bmatrix} u_{n+1} \\ u_{n+2} \end{bmatrix} = \begin{bmatrix} u_{n+1} \\ -bu_{n+1} - cu_n \end{bmatrix} = A\mathbf{Y}_n \text{ avec } A = \begin{bmatrix} 0 & 1 \\ -c & -b \end{bmatrix}$$

Nous avons donc par récurrence que

$$\mathbf{Y}_n = A^n \mathbf{Y}_0$$

Le calcul de A^n de ce problème passe par la diagonalisation de A dont les valeurs propres sont les racines du polynôme caractéristique

$$p(\lambda) = \det(A - \lambda Id) = \begin{vmatrix} -\lambda & 1 \\ -c & -b - \lambda \end{vmatrix} = \lambda^2 + b\lambda + c.$$

Cas de deux racines simples On note $\lambda_1 \neq \lambda_2 \in \mathbb{C}$ les deux racines de p . Nous avons

$$A = P \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} P^{-1} \quad \text{et} \quad A^n = P \begin{bmatrix} \lambda_1^n & 0 \\ 0 & \lambda_2^n \end{bmatrix} P^{-1} = \lambda_1^n P \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} P^{-1} + \lambda_2^n P \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} P^{-1}$$

Il suit que

$$A^n = \lambda_1^n A_1 + \lambda_2^n A_2 \quad \text{avec} \quad A_1 = P \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} P^{-1} \quad \text{et} \quad A_2 = P \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} P^{-1}$$

Comme $\mathbf{Y}_n = A^n \mathbf{Y}_0$, nous avons

$$\begin{bmatrix} u_n \\ u_{n+1} \end{bmatrix} = \lambda_1^n A_1 \begin{bmatrix} u_0 \\ u_1 \end{bmatrix} + \lambda_2^n A_2 \begin{bmatrix} u_0 \\ u_1 \end{bmatrix}$$

Nous avons donc

$$u_n = \alpha_1 \lambda_1^n + \alpha_2 \lambda_2^n \quad \text{avec } \alpha_1 \text{ et } \alpha_2 \text{ dans } \mathbb{C}.$$

On peut alors tenir compte des conditions initiales pour déterminer α_1 et α_2

$$u_0 = \alpha_1 + \alpha_2 \quad \text{et} \quad u_1 = \lambda_1 \alpha_1 + \lambda_2 \alpha_2 \quad \implies \quad \alpha_1 = \frac{\lambda_2 u_0 - u_1}{\lambda_2 - \lambda_1} \quad \text{et} \quad \alpha_2 = \frac{\lambda_1 u_0 - u_1}{\lambda_1 - \lambda_2}$$

Cas d'une racine double (avec $\lambda_1 \neq 0$) Nous agissons par l'absurde et supposons que A est diagonalisable, c'est-à-dire $A = \lambda_1 Id$. Considérons la suite définie par

$$v_{n+2} + bv_{n+1} + cv_n = 0, \quad v_0 = 0 \quad \text{et} \quad v_1 = 1.$$

Nous avons $v_1 = \lambda_1 v_0$ car

$$\begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \lambda_1 \begin{bmatrix} v_0 \\ v_1 \end{bmatrix}$$

Ceci est impossible car $1 \neq 0$. La matrice A n'est donc pas diagonalisable. Par conséquent, elle s'écrit sous la forme d'une trigonalisation de Jordan

$$A = P(\lambda Id + N)P^{-1} \quad \text{avec} \quad N = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$$

Comme $N^2 = 0$, la formule du binôme de Newton

$$(\lambda Id + N)^n = \sum_{k=0}^n C_n^k \lambda^{n-k} N^k = \lambda^n Id + C_n^1 \lambda^{n-1} N + C_n^2 \lambda^{n-2} N^2 + \dots = \lambda^n Id + n \lambda^{n-1} N$$

permet de calculer A^n

$$A^n = P(\lambda^n Id + n \lambda_1^{n-1} N)P^{-1} = \lambda_1^n Id + n \lambda_1^n A_1 \quad \text{avec} \quad A_1 = \frac{PNP^{-1}}{\lambda_1}$$

Il suit de $\mathbf{Y}_n = A^n \mathbf{Y}_0$ que

$$\begin{bmatrix} u_n \\ u_{n+1} \end{bmatrix} = \lambda_1^n \begin{bmatrix} u_0 \\ u_1 \end{bmatrix} + n \lambda_1^n A_1 \begin{bmatrix} u_0 \\ u_1 \end{bmatrix}$$

Nous avons donc

$$u_n = \alpha_1 \lambda_1^n + \alpha_2 n \lambda_1^n \quad \text{avec} \quad \alpha_1 \text{ et } \alpha_2 \text{ dans } \mathbb{C}.$$

On utilise les conditions initiales pour déterminer α_1 et α_2

$$\alpha_1 = u_0 \text{ et } \alpha_1 \lambda_1 + \alpha_2 \lambda_1 = u_1 \quad \implies \quad \alpha_1 = u_0 \text{ et } \alpha_2 = \frac{u_1 - \lambda_1 u_0}{\lambda_1}.$$

Cas d'une racine double (avec $\lambda_1 = 0$) Ce dernier cas ne nécessite pas de traitement car il correspond au cas évident

$$u_{n+2} = 0$$

Chapitre 3

Les normes matricielles

Pour approfondir les notions de ce chapitre, on pourra consulter [2, 3].

3.1 Rappel des notions nécessaires à ce chapitre

3.1.1 Décomposition de Jordan d'une matrice générale

Soit $A \in \mathbb{C}^{I \times I}$ une matrice carrée. Nous rappelons que le spectre de A est l'ensemble des valeurs propres de A

$$Sp(A) = \{\lambda \in \mathbb{C} \text{ tel que } \exists \mathbf{x} \in \mathbb{C}^I \text{ tel que } A\mathbf{x} = \lambda\mathbf{x} \text{ et } \mathbf{x} \neq 0\}.$$

Nous numérotons les valeurs propres λ_j de A deux à deux distinctes par l'entier j qui vérifie $1 \leq j \leq J$. Le rayon spectral d'une matrice est le plus grand module des valeurs propres

$$\rho(A) = \max_{\lambda \in Sp(A)} |\lambda| = \max_{1 \leq j \leq J} |\lambda_j|$$

Les valeurs propres de A sont les racines du polynôme caractéristique

$$p(\lambda) = \det(\lambda Id - A) = \prod_{j=1}^J (\lambda - \lambda_j)^{d_j}$$

La théorie spectrale de Jordan permet d'affirmer

$$A = PDP^{-1}$$

avec $P \in \mathbb{C}^{I \times I}$ une matrice inversible et D une matrice bloc diagonale

$$D = \begin{bmatrix} D_1 & 0 & 0 & \cdots & 0 \\ 0 & D_2 & 0 & \cdots & 0 \\ 0 & 0 & D_3 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & 0 & \cdots & D_J \end{bmatrix}$$

avec les blocs diagonaux $D_j \in \mathbb{C}^{d_j \times d_j}$, définis pour $1 \leq j \leq J$, dont tous les coefficients sont nuls sauf

$$(D_j)_{m,m} = \lambda_j \text{ et } (D_j)_{m,m+1} = 1 \text{ ou } 0$$

On dit que les matrices D_j sont les blocs de Jordan de la matrice A .

3.1.2 Les normes sur les espaces vectoriels

Nous considérons l'espace vectoriel de dimension finie $H = \mathbb{C}^I$. On rappelle qu'une norme est une application $\|\cdot\| : H \longrightarrow \mathbb{R}^+$ qui vérifie les points suivants

- (i) $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$
- (ii) $\|\lambda \mathbf{x}\| = |\lambda| \|\mathbf{x}\|$
- (iii) $\|\mathbf{x}\| = 0 \implies \mathbf{x} = 0$

Parmi les normes usuelles, nous avons

$$\begin{aligned}\|\mathbf{x}\|_1 &= \sum_{i=1}^I |x_i| \\ \|\mathbf{x}\|_\infty &= \max_{1 \leq i \leq I} |x_i| \\ \|\mathbf{x}\|_p &= \left(\sum_{i=1}^I |x_i|^p \right)^{\frac{1}{p}} \text{ pour } 1 < p < +\infty.\end{aligned}$$

Le cas $p = 2$ a une importance particulière car il correspond à la norme euclidienne

$$\|\mathbf{x}\|_2 = \left(\sum_{i=1}^I |x_i|^2 \right)^{\frac{1}{2}}.$$

À partir de n'importe quelle norme et d'une matrice inversible $P \in \mathbb{C}^{I \times I}$, on peut construire une nouvelle norme

$$\|\mathbf{x}\|_P = \|P\mathbf{x}\| \text{ pour tout } \mathbf{x} \in H.$$

Je rappelle enfin que dans un espace vectoriel de dimension finie toutes les normes sont équivalentes. Dit autrement pour tout couple de normes $\|\cdot\|_1$ et $\|\cdot\|_2$ il existe $c > 0$ et $C > 0$ tels que

$$c \|\cdot\|_1 \leq \|\cdot\|_2 \leq C \|\cdot\|_1$$

3.1.3 Technique de preuve pour les suprema

Nous rappelons que dans un espace vectoriel H de dimension finie, si E est un ensemble fermé et borné et f est une application continue, pour démontrer que

$$\sup_{x \in E} f(x) = A$$

il faut démontrer

1. Pour tout $x \in E$ on a

$$f(x) \leq A$$

Ceci implique que

$$\sup_{x \in E} f(x) \leq A.$$

2. il existe $x_0 \in E$ tel que

$$f(x_0) = A.$$

Ceci implique que

$$\sup_{x \in E} f(x) \geq A.$$

Une autre façon de procéder pour obtenir cette seconde inégalité consiste à construire une suite x_n de E telle que

$$\lim_{n \rightarrow +\infty} f(x_n) = A.$$

3.2 Les normes matricielles

On considère l'ensemble des matrices $\mathbb{C}^{I \times I}$. C'est aussi un espace vectoriel de dimension I^2 . Nous allons le munir d'une norme qui aura des propriétés intéressantes.

Définition 8. On associe à toute norme vectorielle $\|\cdot\| : \mathbb{C}^I \rightarrow \mathbb{R}^+$ l'application $\| \cdot \| : \mathbb{C}^{I \times I} \rightarrow \mathbb{R}^+ \cup \{+\infty\}$

$$\|A\| = \sup_{\mathbf{x} \in \mathbb{C}^I \setminus \{0\}} \frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|}$$

On parle aussi de norme triple.

Remarque 6. Pour tout $A \in \mathbb{C}^{I \times I}$, nous avons

$$\|A\| \neq +\infty$$

En effet, pour tout $\mathbf{x} \in \mathbb{C}^I$, on a par équivalence de normes

$$c\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\| \leq C\|\mathbf{x}\|_\infty \text{ avec } 0 < c \leq C$$

Nous avons donc

$$\frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|} \leq \frac{C}{c} \frac{\|A\mathbf{x}\|_\infty}{\|\mathbf{x}\|_\infty}$$

On remarque alors que

$$(A\mathbf{x})_i = \sum_{j=1}^I A_{i,j}x_j \implies |(A\mathbf{x})_i| \leq \sum_{j=1}^I |A_{i,j}| |x_j| \leq \sum_{j=1}^I |A_{i,j}| \|\mathbf{x}\|_\infty$$

On a donc pour tout i

$$\|A\mathbf{x}\|_\infty \leq \max_{1 \leq i \leq I} \sum_{j=1}^I |A_{i,j}| \|\mathbf{x}\|_\infty.$$

On vient d'obtenir que pour $\mathbf{x} \in \mathbb{C}^I$

$$\frac{\|A\mathbf{x}\|_\infty}{\|\mathbf{x}\|_\infty} \leq \max_{1 \leq i \leq I} \sum_{j=1}^I |A_{i,j}|.$$

Ainsi, il suit que

$$\|A\| \leq \frac{C}{c} \max_{1 \leq i \leq I} \sum_{j=1}^I |A_{i,j}|$$

Les normes matricielles $\| \cdot \| : \mathbb{C}^{I \times I} \rightarrow \mathbb{R}^+$ ont les propriétés suivantes

Proposition 7. Pour tout $\lambda \in \mathbb{C}$, tout $\mathbf{x} \in \mathbb{C}^I$ et toutes matrices A et B dans $\mathbb{C}^{I \times I}$, nous avons

$$\left\{ \begin{array}{ll} (i) & \|A\mathbf{x}\| \leq \|A\| \|\mathbf{x}\|, \\ (ii) & \|A+B\| \leq \|A\| + \|B\|, \\ (iii) & \|\lambda A\| = |\lambda| \|A\|, \\ (iv) & \|A\| = 0 \implies A = 0, \\ (v) & \|AB\| \leq \|A\| \cdot \|B\|. \end{array} \right.$$

Preuve. Nous démontrons les résultats dans l'ordre :

(i) Pour tout $\mathbf{x} \in \mathbb{C}^I \setminus \{0\}$

$$\frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|} \leq \|A\|$$

Il suit que pour $\mathbf{x} \neq 0$,

$$\|A\mathbf{x}\| \leq \|A\| \|\mathbf{x}\|$$

Cette inégalité est aussi vérifiée pour $\mathbf{x} = 0$.

(ii) Pour tout $\mathbf{x} \in \mathbb{C}^I \setminus \{0\}$, nous avons par inégalité triangulaire

$$\frac{\|(A+B)\mathbf{x}\|}{\|\mathbf{x}\|} \leq \frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|} + \frac{\|B\mathbf{x}\|}{\|\mathbf{x}\|} \leq \|A\| + \|B\|.$$

Nous avons donc

$$\|A+B\| \leq \|A\| + \|B\|.$$

(iii) Nous avons

$$\frac{\|\lambda A\mathbf{x}\|}{\|\mathbf{x}\|} = |\lambda| \frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|}.$$

On peut passer au sup pour obtenir le résultat.

(iv) Pour tous les vecteurs de la base canonique, nous avons

$$\|A\mathbf{e}_i\| \leq \|A\| \|\mathbf{e}_i\| = 0$$

Ainsi $A\mathbf{e}_i = 0$. Le vecteur $A\mathbf{e}_i$ est la i -ème colonne de A . La matrice A est donc nulle.

(v) Pour tout $\mathbf{x} \in \mathbb{C}^I \setminus \{0\}$

$$\|AB\mathbf{x}\| \leq \|A\| \|B\mathbf{x}\| \leq \|A\| \|B\| \|\mathbf{x}\|$$

On a donc

$$\frac{\|AB\mathbf{x}\|}{\|\mathbf{x}\|} \leq \|A\| \cdot \|B\|.$$

Il suit le résultat.

Remarque 7. On vient de démontrer que les normes matricielles sont des normes.

3.3 Lien entre le rayon spectral et la norme matricielle

L'objet de cette section est de démontrer deux résultats importants sur les normes matricielles.

Proposition 8. Pour toute matrice $A \in \mathbb{C}^{I \times I}$ et toute norme matricielle $\|\cdot\|$, nous avons

$$\rho(A) \leq \|A\|.$$

Preuve. Soit $(\lambda, \mathbf{w}) \in \mathbb{C} \times \mathbb{C}^I$ un mode propre qui maximise $|\lambda|$

$$\mathbf{w} \neq 0, \quad A\mathbf{w} = \lambda\mathbf{w} \quad \text{avec } |\lambda| = \rho(A).$$

Nous avons

$$\|A\mathbf{w}\| = \rho(A) \|\mathbf{w}\| \implies \frac{\|A\mathbf{w}\|}{\|\mathbf{w}\|} = \rho(A).$$

Il suit que

$$\|A\| \geq \rho(A).$$

Proposition 9. Pour toute matrice $A \in \mathbb{C}^{I \times I}$ et tout $\varepsilon > 0$, il existe une norme matricielle $\|\cdot\|$ telle que

$$\|A\| \leq \rho(A) + \varepsilon.$$

La preuve sera traitée en exercice.

3.4 Le théorème de point fixe de Picard

Nous considérons une matrice $A \in \mathbb{C}^{I \times I}$ et nous nous intéressons à la résolution numérique du problème suivant

Pour $\mathbf{f} \in \mathbb{C}^I$ chercher $\mathbf{x} \in \mathbb{C}^I$ tel que $\mathbf{x} - A\mathbf{x} = \mathbf{f}$

Proposition 10. *Si $\rho(A) < 1$ alors il existe un unique $\mathbf{x} \in \mathbb{C}^I$ tel que $\mathbf{x} - A\mathbf{x} = \mathbf{f}$. Nous avons d'autre part que*

$$\lim_{n \rightarrow +\infty} \mathbf{x}_n = \mathbf{x}$$

avec $\mathbf{x}_0 = 0$ et

$$\mathbf{x}_{n+1} = A\mathbf{x}_n + \mathbf{f}.$$

Preuve. Comme $\rho(A) < 1$, nous avons d'après la Proposition 9 qu'il existe une norme et une norme matricielle induite telle que

$$\|A\| < 1$$

Pour montrer que le problème est bien posé, il suffit de montrer que $\text{Ker}(Id - A) = \{0\}$.

$$\mathbf{y} - A\mathbf{y} = 0 \implies \|\mathbf{y}\| = \|A\mathbf{y}\| \implies \|\mathbf{y}\| \leq \|A\| \|\mathbf{y}\| \implies \underbrace{(1 - \|A\|)}_{>0} \|\mathbf{y}\| \leq 0 \implies \|\mathbf{y}\| = 0 \implies \mathbf{y} = 0.$$

Nous avons

$$\mathbf{x}_{n+1} = A\mathbf{x}_n + \mathbf{f} \text{ et } \mathbf{x} = A\mathbf{x} + \mathbf{f}.$$

Nous pouvons faire la différence et obtenir

$$\mathbf{x}_{n+1} - \mathbf{x} = A(\mathbf{x}_n - \mathbf{x}).$$

Il suit que

$$\|\mathbf{x}_{n+1} - \mathbf{x}\| \leq \|A\| \cdot \|\mathbf{x}_n - \mathbf{x}\|.$$

Comme $\mathbf{x}_0 = 0$, nous avons par récurrence que

$$\|\mathbf{x}_n - \mathbf{x}\| \leq \|A\|^n \cdot \|\mathbf{x}_0 - \mathbf{x}\| \leq \|A\|^n \cdot \|\mathbf{x}\|.$$

Nous venons de démontrer que $\mathbf{x}_n$ converge vers $\mathbf{x}$.

3.5 Quelques exercices

3.5.1 Exercice sur la norme matricielle 2

On considère la norme 2 définie pour $\mathbf{x} \in \mathbb{C}^I$

$$\|\mathbf{x}\|_2 = \left(\sum_{i=1}^I |x_i|^2 \right)^{\frac{1}{2}}.$$

ainsi que sa norme matricielle induite définie pour $A \in \mathbb{C}^{I \times I}$

$$\|A\|_2 = \sup_{\mathbf{x} \in \mathbb{C}^I \setminus \{0\}} \frac{\|A\mathbf{x}\|_2}{\|\mathbf{x}\|_2}$$

On rappelle que le rayon spectral d'une matrice A est défini par

$$\rho(A) = \max_{\lambda \in \text{Sp}(A)} |\lambda|$$

1. Montrer que pour toute matrice $A \in \mathbb{C}^{I \times I}$ $\|A\|_2 = \sqrt{\rho(A^*A)}$.

2. Montrer que pour toute matrice $A \in \mathbb{C}^{I \times I}$ hermitienne $\|A\|_2 = \rho(A)$.

Correction.

1. La matrice A^*A est hermitienne positive car

$$(A^*Ax, x) = (Ax, Ax) = \|Ax\|^2$$

Elle est donc diagonalisable dans une base orthonormée de vecteurs propres $(\mathbf{w}^{(i)})_{1 \leq i \leq I}$

$$A^*A\mathbf{w}^{(i)} = \lambda_i \mathbf{w}^{(i)} \text{ avec } \lambda_i \geq 0$$

Nous décomposons $\mathbf{x}$ dans cette base

$$\mathbf{x} = \sum_{i=1}^I (\mathbf{x}, \mathbf{w}^{(i)}) \mathbf{w}^{(i)}$$

Il suit que

$$A^*Ax = \sum_{i=1}^I \lambda_i (\mathbf{x}, \mathbf{w}^{(i)}) \mathbf{w}^{(i)}$$

D'après le théorème de Pythagore, nous avons

$$\|Ax\|^2 = (Ax, Ax) = (A^*Ax, x) = \sum_{i=1}^I \lambda_i |(\mathbf{x}, \mathbf{w}^{(i)})|^2 \leq \lambda_{\max} \sum_{i=1}^I |(\mathbf{x}, \mathbf{w}^{(i)})|^2 \leq \lambda_{\max} \|\mathbf{x}\|^2.$$

avec $\lambda_{\max}$ la plus grande valeur propre de A^*A

$$\rho(A^*A) = \lambda_{\max}.$$

Il suit que pour $\mathbf{x} \neq 0$,

$$\frac{\|Ax\|}{\|\mathbf{x}\|} \leq \sqrt{\lambda_{\max}}.$$

Nous pouvons passer au supremum et obtenir que

$$\|A\| \leq \sqrt{\lambda_{\max}}$$

Considérons maintenant $\mathbf{x} = \mathbf{w}_{\max}$ le vecteur propre associé à la valeur propre maximale

$$\|Ax\|^2 = (Ax, Ax) = (A^*Ax, x) = \lambda_{\max} (\mathbf{x}, \mathbf{x}) \implies \|A\| \geq \sqrt{\lambda_{\max}}.$$

Nous venons de montrer que

$$\|A\| = \sqrt{\lambda_{\max}}$$

2. Si $A^* = A$, nous avons $A^*A = A^2$ et

$$\rho(A^*A) = \rho(A^2) = \rho(A)^2.$$

Donc

$$\|A\| = \sqrt{\rho(A^*A)} = \rho(A) = \max_{1 \leq i \leq I} |\lambda_i(A)|.$$

3.5.2 Exercice sur la norme matricielle infinie

On considère la norme infinie définie pour $\mathbf{x} \in \mathbb{C}^I$

$$\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq I} |x_i|.$$

ainsi que sa norme matricielle induite définie pour $A \in \mathbb{C}^{I \times I}$

$$\|A\|_\infty = \sup_{\mathbf{x} \in \mathbb{C}^I \setminus \{0\}} \frac{\|A\mathbf{x}\|_\infty}{\|\mathbf{x}\|_\infty}$$

Montrer que pour $A \in \mathbb{C}^{I \times I}$

$$\|A\|_\infty = \max_{1 \leq i \leq I} \sum_{j=1}^I |A_{i,j}|$$

Correction. Soit $A \neq 0$. Soit i_0 l'entier qui réalise le maximum de

$$\sum_{j=1}^I |A_{i_0,j}| = \max_{1 \leq i \leq I} \sum_{j=1}^I |A_{i,j}| > 0$$

On définit le vecteur $\mathbf{x} \in \mathbb{C}^I$ qui vérifie

$$\begin{cases} \mathbf{x}_j = \frac{\overline{A_{i_0,j}}}{|A_{i_0,j}|} & \text{si } A_{i_0,j} \neq 0. \\ \mathbf{x}_j = 0 & \text{si } A_{i_0,j} = 0. \end{cases}$$

Nous remarquons que

$$\|\mathbf{x}\|_\infty = 1.$$

Nous avons ainsi pour tout $j \in \llbracket 1, I \rrbracket$

$$A_{i_0,j} \mathbf{x}_j = |A_{i_0,j}|.$$

Nous avons alors

$$(A\mathbf{x})_{i_0} = \sum_{j=1}^I |A_{i_0,j}|$$

Il suit que

$$\|A\mathbf{x}\|_\infty = \max_{i \in \llbracket 1, I \rrbracket} |(A\mathbf{x})_i| \geq \sum_{j=1}^I |A_{i_0,j}| \implies \frac{\|A\mathbf{x}\|_\infty}{\|\mathbf{x}\|_\infty} \geq \sum_{j=1}^I |A_{i_0,j}| \implies \|A\|_\infty \geq \sum_{j=1}^I |A_{i_0,j}|$$

Passons à la majoration. Nous avons

$$|(A\mathbf{x})_i| = \left| \sum_{j=1}^I A_{i,j} \mathbf{x}_j \right| \leq \sum_{j=1}^I |A_{i,j}| |\mathbf{x}_j| \leq \left(\sum_{j=1}^I |A_{i,j}| \right) \|\mathbf{x}\|_\infty$$

On prend le maximum de cette expression sur $1 \leq i \leq I$

$$\|A\mathbf{x}\|_\infty = \max_{i \in \llbracket 1, I \rrbracket} |(A\mathbf{x})_i| \leq \max_{i \in \llbracket 1, I \rrbracket} \left(\sum_{j=1}^I |A_{i,j}| \right) \|\mathbf{x}\|_\infty \leq \left(\sum_{j=1}^I |A_{i_0,j}| \right) \|\mathbf{x}\|_\infty$$

Il suit que pour tout $\mathbf{x} \neq 0$

$$\frac{\|A\mathbf{x}\|_\infty}{\|\mathbf{x}\|_\infty} \leq \left(\sum_{j=1}^I |A_{i_0,j}| \right)$$

Nous pouvons passer au sup sur $\mathbf{x} \neq 0$

$$\|A\|_\infty \leq \left(\sum_{j=1}^I |A_{i_0,j}| \right).$$

La minoration et la majoration mènent à la conclusion.

3.5.3 Exercice sur les matrices à diagonale dominante

Définition 9. On dit que $A \in \mathbb{C}^{I \times I}$ est à diagonale strictement dominante si pour tout entier i tel que $1 \leq i \leq I$

$$|A_{i,i}| > \sum_{j=1, j \neq i}^I |A_{i,j}|$$

On appelle écart à la diagonale δ le réel strictement positif

$$\delta = \min_{1 \leq i \leq I} \delta_i$$

avec pour $1 \leq i \leq I$

$$\delta_i = |A_{i,i}| - \sum_{j=1, j \neq i}^I |A_{i,j}|$$

1. Montrer que si $A \in \mathbb{C}^{I \times I}$ est une matrice à diagonale strictement dominante alors A est inversible
2. Montrer que si $A \in \mathbb{C}^{I \times I}$ est une matrice à diagonale strictement dominante alors

$$\|A^{-1}\|_{\infty} \leq \frac{1}{\delta}$$

Correction.

1. Montrons que A est injective. Soit $\mathbf{x} \in \mathbb{C}^I$ tel que

$$A\mathbf{x} = 0$$

Soit i_0 un entier qui maximise $|x_i|$

$$|x_{i_0}| = \|\mathbf{x}\|_{\infty}$$

Nous avons

$$0 = (A\mathbf{x})_{i_0} = \sum_{j=1}^I A_{i_0,j} \mathbf{x}_j$$

Nous avons grâce à la seconde inégalité triangulaire ($|\mathbf{x} - \mathbf{y}| \geq |\mathbf{x}| - |\mathbf{y}|$)

$$0 \geq |A_{i_0,i_0}| |\mathbf{x}_{i_0}| - \sum_{j=1, j \neq i_0}^I |A_{i_0,j}| |\mathbf{x}_j|$$

Comme $|x_{i_0}| = \|\mathbf{x}\|_{\infty}$ et $|\mathbf{x}_j| \leq \|\mathbf{x}\|_{\infty}$, nous avons

$$0 \geq |A_{i_0,i_0}| \|\mathbf{x}\| - \sum_{j=1, j \neq i_0}^I |A_{i_0,j}| \|\mathbf{x}\| = \delta_{i_0} \|\mathbf{x}\|$$

Nous avons par positivité ($\delta_{i_0} > 0$)

$$\delta_{i_0} \|\mathbf{x}\| = 0$$

Ceci implique que $\|\mathbf{x}\| = 0$ et donc $\mathbf{x} = 0$.

2. Pour tout $\mathbf{y} \neq 0$, nous notons $\mathbf{x} = A^{-1}\mathbf{y}$, nous avons

$$(A\mathbf{x})_i = \sum_{j=1}^I A_{i,j} \mathbf{x}_j$$

avec i_0 qui maximise $|x_i|$. De même, nous avons

$$\|A\mathbf{x}\|_{\infty} \geq |(A\mathbf{x})_{i_0}| \geq |A_{i_0,i_0}| |\mathbf{x}_{i_0}| - \sum_{j=1, j \neq i_0}^I |A_{i_0,j}| |\mathbf{x}_j| \geq \delta_{i_0} \|\mathbf{x}\|_{\infty}.$$

Nous avons donc

$$\frac{\|A^{-1}\mathbf{y}\|_\infty}{\|\mathbf{y}\|_\infty} = \frac{\|\mathbf{x}\|_\infty}{\|A\mathbf{x}\|_\infty} \leq \frac{1}{\delta_{i_0}} \leq \frac{1}{\min_{i \in \llbracket 1, I \rrbracket} \delta_i} = \frac{1}{\delta}.$$

On passe au supremum pour $\mathbf{y} \neq 0$ et on obtient que

$$\|A^{-1}\|_\infty \leq \frac{1}{\delta}.$$

3.5.4 Exercice sur l'existence d'une norme matricielle proche du rayon spectral

1. Rappeler la preuve qui affirme que

$$\rho(A) \leq \|A\|.$$

2. Pour tout $\varepsilon > 0$, montrer qu'il existe une matrice inversible $Q \in \mathbb{C}^{I \times I}$ telle que

$$A = QDQ^{-1}$$

avec $Q \in \mathbb{C}^{I \times I}$ une matrice inversible et D une matrice bloc diagonale

$$D = \begin{bmatrix} D_1 & 0 & 0 & \cdots & 0 \\ 0 & D_2 & 0 & \cdots & 0 \\ 0 & 0 & D_3 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & 0 & \cdots & D_J \end{bmatrix}$$

avec les blocs diagonaux $D_j \in \mathbb{C}^{d_j \times d_j}$, définis pour $1 \leq j \leq J$, dont tous les coefficients sont nuls sauf

$$(D_j)_{m,m} = \lambda_j \text{ et } (D_j)_{m,m+1} = \varepsilon \text{ ou } 0$$

3. On considère la norme vectorielle

$$\|\mathbf{x}\| = \|Q^{-1}\mathbf{x}\|_\infty$$

ainsi que la norme matricielle associée. Montrer que

$$\|A\| \leq \rho(A) + \varepsilon.$$

4. Que peut-on affirmer si la matrice est diagonalisable ?

Chapitre 4

Conditionnement d'une matrice

Pour approfondir les notions de ce chapitre, on pourra consulter [3, 4, 13].

4.1 Définition

Parmi les quantités qui sont attachées aux matrices, le conditionnement est particulièrement important car il est impliqué dans la plupart des estimations des erreurs de convergence des erreurs commises par les algorithmes de résolution des systèmes linéaires.

Soit $A \in \mathbb{C}^{I \times I}$ une matrice carrée **inversible** et $\|\cdot\|$ une norme matricielle. On définit le nombre de conditionnement de la matrice A par

$$\kappa : \mathbb{C}^{I \times I} \longrightarrow \mathbb{R}^+, \quad \kappa(A) = \|A\| \|A^{-1}\|.$$

Remarque 8. Ce nombre de conditionnement peut être évalué dans le cadre de la norme euclidienne. Nous notons $\sigma_{\max}(A)$ et $\sigma_{\min}(A)$ les plus grandes et plus petites valeurs singulières de A

$$\sigma_{\max}(A) = \max_{\lambda \in Sp(A^*A)} \sqrt{\lambda} \quad \text{et} \quad \sigma_{\min}(A) = \min_{\lambda \in Sp(A^*A)} \sqrt{\lambda}.$$

Nous avons pour $\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2$

$$\kappa_2(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}$$

Dans le cas où la matrice est hermitienne, définie, positive

$$\kappa_2(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}$$

4.2 Conditionnement et résolution des systèmes linéaires

La résolution des systèmes linéaires provient très souvent d'un problème inverse qui consiste à trouver des paramètres d'un modèle $\mathbf{x} = (x_1, \dots, x_I)^T$ en fonction de données obtenues à l'aide de mesures $\mathbf{f} = (f_1, f_2, \dots, f_I)^T$. Ce problème s'écrit :

Chercher $\mathbf{x} \in \mathbb{C}^I$ tel que

$$A\mathbf{x} = \mathbf{f}$$

Les données $\mathbf{f} \in \mathbb{C}^I$ qui sont issues de mesures ne sont pas exactement les vraies données $\mathbf{f}_0 \in \mathbb{C}^I$ mais sont polluées par des erreurs $\delta\mathbf{f} \in \mathbb{C}^I$

$$\mathbf{f} = \mathbf{f}_0 + \delta\mathbf{f}$$

Ces erreurs sur les données vont provoquer des erreurs sur la solution. La solution numérique $\mathbf{x}$ ne sera donc pas la solution exacte $\mathbf{x}_0 \in \mathbb{C}^I$ mais sa perturbation par une erreur $\delta\mathbf{x} \in \mathbb{C}^I$

$$\mathbf{x} = \mathbf{x}_0 + \delta\mathbf{x}.$$

Le fait que la solution exacte et la solution numérique vérifient

$$A\mathbf{x}_0 = \mathbf{f}_0 \quad \text{et} \quad A\mathbf{x} = \mathbf{f}$$

implique par linéarité l'équation qui porte sur les erreurs

$$A(\mathbf{x} - \mathbf{x}_0) = \mathbf{f} - \mathbf{f}_0 \implies A\delta\mathbf{x} = \delta\mathbf{f} \implies \delta\mathbf{x} = A^{-1}\delta\mathbf{f}$$

Nous avons donc en utilisant les propriétés des normes matricielles que :

$$\begin{cases} \|\delta\mathbf{x}\| = \|A^{-1}\delta\mathbf{f}\| \leq \|A^{-1}\| \|\delta\mathbf{f}\|, \\ \|\mathbf{f}\| = \|A\mathbf{x}\| \leq \|A\| \|\mathbf{x}\| \end{cases}$$

Ces deux relations impliquent que les deux erreurs relatives vérifient l'inégalité suivante

$$\frac{\|\delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \kappa(A) \frac{\|\delta\mathbf{f}\|}{\|\mathbf{f}\|} \quad \text{avec } \kappa(A) = \|A\| \|A^{-1}\|.$$

Ainsi plus le conditionnement est grand, plus il y a de risques que l'erreur relative soit grande.

4.3 Les préconditionneurs

4.3.1 Le cas général

Nous venons de voir que la résolution de problèmes linéaires à l'aide de matrices mal conditionnées ne permet pas de bien maîtriser l'erreur relative. Nous allons voir par la suite que c'est aussi une quantité qui est impliquée dans le contrôle de la vitesse de convergence de beaucoup d'algorithmes numériques.

Une idée naturelle consiste à modifier le système linéaire considéré par des changements de variables ou en combinant les lignes des systèmes linéaires afin d'obtenir des systèmes bien conditionnés.

Nous considérons dans cette section la résolution du système linéaire

$$\text{Étant donné } \mathbf{f} \in \mathbb{C}^I \text{ chercher } \mathbf{x} \in \mathbb{C}^I \text{ tel que } A\mathbf{x} = \mathbf{f}.$$

Ceci traduit le système linéaire

$$\begin{cases} A_{11}x_1 + A_{12}x_2 + \dots + A_{1I}x_I = f_1 \\ A_{21}x_1 + A_{22}x_2 + \dots + A_{2I}x_I = f_2 \\ \vdots \quad \vdots \quad \vdots \quad \vdots \quad \ddots \quad \vdots \quad \vdots \quad \vdots \\ A_{I1}x_1 + A_{I2}x_2 + \dots + A_{II}x_I = f_I \end{cases}$$

La ligne i s'écrit donc

$$\sum_{j=1}^I A_{i,j}x_j = f_i$$

Une première façon de reconditionner le système consiste à combiner les lignes pour définir un nouveau système linéaire

$$\sum_{i=1}^I P_{k,i} \sum_{j=1}^I A_{i,j}x_j = \sum_{i=1}^I P_{k,i}f_i$$

Matriciellement ceci s'écrit

$$PA\mathbf{x} = P\mathbf{f}.$$

Il est nécessaire que la matrice P soit inversible afin que ce nouveau système soit équivalent au premier. On parle alors de préconditionneur à gauche.

Une seconde possibilité consiste à effectuer un changement de variable. On définit la nouvelle variable $\mathbf{y} \in \mathbb{C}^I$

$$\mathbf{x} = Q\mathbf{y}$$

Les coordonnées x_j sont des combinaisons linéaires de y_k

$$\begin{cases} x_1 = Q_{11}y_1 + Q_{12}y_2 + \dots + Q_{1I}y_I \\ x_2 = Q_{21}y_1 + Q_{22}y_2 + \dots + Q_{2I}y_I \\ \vdots \\ x_I = Q_{I1}y_1 + Q_{I2}y_2 + \dots + Q_{II}y_I \end{cases}$$

Nous avons alors le système

$$\text{Étant donné } \mathbf{f} \in \mathbb{C}^I \text{ chercher } \mathbf{y} \in \mathbb{C}^I \text{ tel que } A Q \mathbf{y} = \mathbf{f}.$$

Il est aussi nécessaire que la matrice Q soit inversible. On parle alors de préconditionneur à droite.

Une alternative consiste aussi à utiliser un préconditionneur bilatéral

$$\text{Étant donné } \mathbf{f} \in \mathbb{C}^I \text{ chercher } \mathbf{y} \in \mathbb{C}^I \text{ tel que } P A Q \mathbf{y} = P \mathbf{f}.$$

avec P et Q deux matrices inversibles.

L'objectif est dans les cas (les matrices P ou Q peuvent être égales à l'identité) d'assurer

$$\kappa(PAQ) \ll \kappa(A)$$

afin d'améliorer les propriétés du système linéaire étudié.

4.3.2 Quelques exemples de préconditionneurs

On définit la matrice diagonale $D \in \mathbb{C}^{I \times I}$ qui reproduit la diagonale de A

$$D_{i,j} = A_{i,j} \delta_{i,j}$$

C'est-à-dire

$$A = \begin{bmatrix} A_{11} & A_{12} & \dots & A_{1I} \\ A_{21} & A_{22} & \dots & A_{2I} \\ \vdots & \vdots & \ddots & \vdots \\ A_{I1} & A_{I2} & \dots & A_{II} \end{bmatrix} \quad \text{et} \quad D = \begin{bmatrix} A_{11} & 0 & \dots & 0 \\ 0 & A_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & A_{II} \end{bmatrix}$$

On définit aussi la matrice triangulaire $L \in \mathbb{C}^{I \times I}$ qui reproduit la partie inférieure de A

$$L = \begin{pmatrix} A_{11} & 0 & \dots & 0 \\ A_{21} & A_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ A_{I1} & A_{I2} & \dots & A_{II} \end{pmatrix}$$

Préconditionneur de Jacobi à gauche : $P = D^{-1}$ et $Q = Id$

Préconditionneur de Jacobi à droite : $Q = D^{-1}$ et $P = Id$

Préconditionneur de Jacobi bilatéral : $Q = P = |D|^{-\frac{1}{2}}$

Préconditionneur de Gauss-Seidel à gauche : $P = L^{-1}$ et $Q = Id$.

L'idée est à chaque fois d'essayer de capturer une partie des propriétés de l'inverse de la matrice A .

Une autre idée consiste à choisir une approximation de l'inverse de A calculée à l'aide d'une précision plus faible (on pourra utiliser des simples à la place des doubles en mémoire).

4.4 Exercices sur le conditionnement

4.4.1 Exercice. Minoration du conditionnement

Montrer que pour toute norme matricielle et toute matrice inversible $A \in \mathbb{C}^{I \times I}$

$$\kappa(A) \geq 1.$$

Correction. Comme A est inversible, nous avons

$$\mathbf{x} = A^{-1} A \mathbf{x}$$

Il suit comme $\|\cdot\|$ est une norme matricielle

$$\|\mathbf{x}\| \leq \|A^{-1}\| \|A\mathbf{x}\| \leq \|A^{-1}\| \|A\| \|\mathbf{x}\|.$$

Nous obtenons pour $\mathbf{x} \neq 0$

$$1 \leq \|A^{-1}\| \|A\| =: \kappa(A).$$

4.4.2 Exercice. Un système mal conditionné

1. Calculer la solution du système

$$\begin{cases} x + y = 2, \\ x + 1.001y = 2.001. \end{cases}$$

2. Calculer la solution du système

$$\begin{cases} x + y = 2, \\ x + 1.001y = 2. \end{cases}$$

3. Calculer le conditionnement induit par la norme euclidienne de ce système linéaire.

Correction.

1. Nous remarquons que $(x, y) = (1, 1)$ est solution de ce système linéaire. Ce problème est bien posé car son déterminant est différent de 0 (il vaut 0.001).
2. La solution s'obtient en soustrayant la deuxième ligne et la première ligne

$$0.001 y = 0 \text{ donc } y = 0$$

La solution de ce système bien posé est $(x, y) = (2, 0)$.

3. Le conditionnement euclidien de la matrice est

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2 \text{ avec } A = \begin{bmatrix} 1 & 1 \\ 1 & 1.001 \end{bmatrix}.$$

Comme A est symétrique, nous avons

$$\kappa_2(A) = \frac{|\lambda|_{\max}}{|\lambda|_{\min}}$$

avec $|\lambda|_{\max}$ et $|\lambda|_{\min}$ la plus grande et la plus petite valeur absolue de valeur propre de A . Le polynôme caractéristique de A est donné par

$$p(\lambda) = \lambda^2 - 2.001\lambda + .001$$

Ainsi $\lambda_{\min} = \frac{2.001 - \sqrt{4.000001}}{2} \simeq .0005$ et $\lambda_{\max} = \frac{2.001 + \sqrt{4.000001}}{2} \simeq 2$.

4. Le conditionnement de la matrice est donné par

$$\kappa_2(A) = \frac{2.001 + \sqrt{4.000001}}{2.001 - \sqrt{4.000001}} \simeq \frac{2}{0.0005} = 4000$$

Chapitre 5

Factorisation QR par la méthode de Householder

La méthode présentée dans ce chapitre a été introduite par Householder [8]. Pour approfondir les notions de ce chapitre, on pourra consulter [2, 6, 13].

5.1 Définition de la factorisation QR

La décomposition QR d'une matrice $M \in \mathbb{C}^{I \times I}$ consiste à factoriser M sous la forme d'un produit de deux matrices :

$$M = QR$$

avec

- $Q \in \mathbb{C}^{I \times I}$ est une matrice unitaire, dont les colonnes forment un ensemble de vecteurs orthonormés.
- $R \in \mathbb{C}^{I \times I}$ est une matrice triangulaire supérieure, $R_{i,j} = 0$ si $i > j$ dont les coefficients diagonaux sont des nombres réels strictement positifs, c'est-à-dire

$$R_{i,i} \in \mathbb{R}^{+,*}.$$

La méthode moderne pour calculer la décomposition QR est la méthode de Householder qui consiste à définir la matrice Q comme une composition de symétries orthogonales. Elle a été introduite dans l'article suivant : *Alston Householder. Unitary triangularization of a nonsymmetric matrix. Journal of the ACM (JACM), 1958*

C'est ce que nous allons voir dans ce chapitre.

5.2 Les symétries orthogonales par rapport à un hyperplan

On considère $\mathbf{u} \in \mathbb{C}^I$ ($\mathbf{u}^* \mathbf{u} = 1$) un vecteur unitaire et $Q \in \mathbb{C}^{I \times I}$ la matrice

$$Q = Id - 2\mathbf{u}\mathbf{u}^*$$

Montrons que Q est unitaire :

$$Q^*Q = (Id - 2\mathbf{u}\mathbf{u}^*)^*(Id - 2\mathbf{u}\mathbf{u}^*) = (Id^* - 2\mathbf{u}^{**}\mathbf{u}^*)(Id - 2\mathbf{u}\mathbf{u}^*) = (Id - 2\mathbf{u}\mathbf{u}^*)(Id - 2\mathbf{u}\mathbf{u}^*).$$

Nous pouvons développer et obtenir

$$Q^*Q = Id - 4\mathbf{u}\mathbf{u}^* + 4\mathbf{u}\mathbf{u}^*\mathbf{u}\mathbf{u}^*.$$

Comme $\mathbf{u}^* \mathbf{u} = 1$, il suit que

$$Q^*Q = Id - 4\mathbf{u}\mathbf{u}^* + 4\mathbf{u}\mathbf{u}^* = Id.$$

D'une part, nous avons

$$Q\mathbf{u} = \mathbf{u} - 2\mathbf{u}\mathbf{u}^*\mathbf{u} = \mathbf{u} - 2\mathbf{u} = -\mathbf{u} \text{ car } \mathbf{u}^*\mathbf{u} = 1.$$

Soit $\mathbf{v} \in \mathbb{C}^I$ tel que $\mathbf{v} \perp \mathbf{u}$. Nous avons

$$Q\mathbf{v} = \mathbf{v} - 2\mathbf{u}\mathbf{u}^*\mathbf{v} = \mathbf{v} \text{ car } \mathbf{u}^*\mathbf{v} = 0.$$

C'est exactement la définition d'une symétrie orthogonale par rapport à l'hyperplan orthogonal à $\mathbf{u}$. Nous venons de démontrer le résultat suivant

Proposition 11. *Soit $\mathbf{u} \in \mathbb{C}^I$ un vecteur de norme 1. La symétrie orthogonale par rapport à*

$$V = \{\mathbf{x} \in \mathbb{C}^I \text{ tel que } (\mathbf{x}, \mathbf{u}) = 0\}$$

est l'application linéaire dont la matrice de représentation est

$$Q = Id - 2\mathbf{u}\mathbf{u}^*$$

5.3 Méthode de factorisation de Householder

5.3.1 Les deux premières étapes

On décrira l'algorithme seulement dans le cas où $A \in \mathbb{C}^{I \times I}$ est inversible. Ceci permet une simplification importante de la présentation.

Remarque 9. *Cette condition peut facilement être relâchée pour définir cet algorithme où A n'est pas inversible. Les coefficients de R ne seront plus strictement positifs mais seulement positifs.*

Nous considérons $\mathbf{w}_1 \in \mathbb{C}^I$ la première colonne de la matrice A . Nous notons

$$\mathbf{v}_1 := \alpha_1 \mathbf{w}_1 + \|\mathbf{w}_1\| \mathbf{e}_1 \neq 0$$

avec $\alpha_1 = \frac{\overline{(\mathbf{w}_1, \mathbf{e}_1)}}{(\mathbf{w}_1, \mathbf{e}_1)}$ ou 1 si $(\mathbf{w}_1, \mathbf{e}_1) = 0$ un nombre complexe de module 1 choisi afin que

$$\alpha_1(\mathbf{w}_1, \mathbf{e}_1) \in \mathbb{R}^+.$$

Remarque 10. *Le vecteur $\mathbf{v}_1 \in \mathbb{C}^I$ est, dans le cas réel, un vecteur directeur d'une des deux bissectrices de l'angle $(\mathbf{e}_1, \mathbf{w}_1)$*




FIGURE 5.1 – La bissectrice à $\mathbf{e}_1$ et $\mathbf{w}_1$

Nous avons

$$\begin{aligned} \text{si } (\mathbf{w}_1, \mathbf{e}_1) \neq 0 \text{ alors } (\mathbf{v}_1, \mathbf{e}_1) &= \frac{\overline{(\mathbf{w}_1, \mathbf{e}_1)}}{(\mathbf{w}_1, \mathbf{e}_1)} (\mathbf{w}_1, \mathbf{e}_1) + \|\mathbf{w}_1\| (\mathbf{e}_1, \mathbf{e}_1) = |(\mathbf{w}_1, \mathbf{e}_1)| + \|\mathbf{w}_1\| \\ \text{si } (\mathbf{w}_1, \mathbf{e}_1) = 0 \text{ alors } (\mathbf{v}_1, \mathbf{e}_1) &= (\mathbf{w}_1, \mathbf{e}_1) + \|\mathbf{w}_1\| (\mathbf{e}_1, \mathbf{e}_1) = \|\mathbf{w}_1\| \end{aligned}$$

Comme $(\mathbf{v}_1, \mathbf{e}_1) > 0$, nous avons toujours $\mathbf{v}_1 \neq 0$. On définit alors $P^{(1)} \in \mathbb{C}^{I \times I}$ la matrice unitaire

$$P^{(1)} = Id - 2\mathbf{u}_1 \mathbf{u}_1^* \text{ avec } \mathbf{u}_1 = \frac{\mathbf{v}_1}{\|\mathbf{v}_1\|}.$$

La matrice $P^{(1)}$ représente la symétrie orthogonale par rapport à l'hyperplan orthogonal à $\mathbf{u}_1$. C'est pourquoi, nous avons la proposition

Proposition 12. *Nous avons*

$$P^{(1)} \mathbf{w}_1 = -\overline{\alpha_1} \|\mathbf{w}_1\| \mathbf{e}_1$$

Preuve. Nous notons $\mathbf{v}'_1 = \alpha_1 \mathbf{w}_1 - \|\mathbf{w}_1\| \mathbf{e}_1 \neq 0$. Nous avons

$$\left\{ \begin{aligned} (\mathbf{v}_1, \mathbf{v}'_1)_0 &= (\alpha_1 \mathbf{w}_1 + \|\mathbf{w}_1\| \mathbf{e}_1, \alpha_1 \mathbf{w}_1 - \|\mathbf{w}_1\| \mathbf{e}_1)_0 \\ &= \|\mathbf{w}_1\|^2 + (\|\mathbf{w}_1\| \mathbf{e}_1, \alpha_1 \mathbf{w}_1)_0 - (\alpha_1 \mathbf{w}_1, \|\mathbf{w}_1\| \mathbf{e}_1)_0 - (\|\mathbf{w}_1\| \mathbf{e}_1, \|\mathbf{w}_1\| \mathbf{e}_1)_0 \\ &= \|\mathbf{w}_1\|^2 + \overline{\alpha_1} \|\mathbf{w}_1\| (\mathbf{e}_1, \mathbf{w}_1)_0 - \alpha_1 \|\mathbf{w}_1\| (\mathbf{w}_1, \mathbf{e}_1)_0 - (\|\mathbf{w}_1\| \mathbf{e}_1, \|\mathbf{w}_1\| \mathbf{e}_1)_0 \\ &= -2i \|\mathbf{w}_1\| \Im \alpha_1 (\mathbf{w}_1, \mathbf{e}_1)_0 \\ &= 0. \end{aligned} \right.$$

Il suit que

$$\left\{ \begin{aligned} P^{(1)} \mathbf{v}_1 = -\mathbf{v}_1 &\iff \alpha_1 P^{(1)} \mathbf{w}_1 + \|\mathbf{w}_1\| P^{(1)} \mathbf{e}_1 = -\alpha_1 \mathbf{w}_1 - \|\mathbf{w}_1\| \mathbf{e}_1 \\ P^{(1)} \mathbf{v}'_1 = \mathbf{v}'_1 &\iff \alpha_1 P^{(1)} \mathbf{w}_1 - \|\mathbf{w}_1\| P^{(1)} \mathbf{e}_1 = \alpha_1 \mathbf{w}_1 - \|\mathbf{w}_1\| \mathbf{e}_1 \end{aligned} \right.$$

On déduit en sommant les deux lignes

$$\alpha_1 P^{(1)} \mathbf{w}_1 = -\|\mathbf{w}_1\| \mathbf{e}_1 \text{ donc } P^{(1)} \mathbf{w}_1 = -\overline{\alpha_1} \|\mathbf{w}_1\| \mathbf{e}_1 \text{ car } |\alpha_1| = 1$$

Ceci termine la preuve.

Nous venons de démontrer que $P^{(1)} \mathbf{w}_1$ est proportionnel à $\mathbf{e}_1$. Ainsi, $P^{(1)} A \in \mathbb{C}^{I \times I}$ est une matrice de la forme suivante :

$$P^{(1)} A = \begin{bmatrix} R_{1,1} & R_{1,2} & \cdots & R_{1,I} \\ 0 & (P^{(1)} A)_{2,2} & \cdots & (P^{(1)} A)_{2,I} \\ 0 & (P^{(1)} A)_{3,2} & \cdots & (P^{(1)} A)_{3,I} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & (P^{(1)} A)_{I,2} & \cdots & (P^{(1)} A)_{I,I} \end{bmatrix}$$

Nous répétons le même raisonnement avec la matrice $A^{(1)} \in \mathbb{C}^{(I-1) \times (I-1)}$ définie par

$$A^{(1)} = \begin{bmatrix} (P^{(1)} A)_{2,2} & \cdots & (P^{(1)} A)_{2,I} \\ \vdots & \ddots & \vdots \\ (P^{(1)} A)_{I,2} & \cdots & (P^{(1)} A)_{I,I} \end{bmatrix}$$

On définit ainsi une matrice unitaire $P^{(2)} \in \mathbb{C}^{(I-1) \times (I-1)}$ (de la même manière que précédemment) telle que

$$P^{(2)} A^{(1)} = \begin{bmatrix} R_{2,2} & R_{2,3} & \cdots & R_{2,I} \\ 0 & (P^{(2)} A^{(1)})_{2,2} & \cdots & (P^{(2)} A^{(1)})_{2,I-1} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & (P^{(2)} A^{(1)})_{I-1,2} & \cdots & (P^{(2)} A^{(1)})_{I-1,I-1} \end{bmatrix}$$

Nous avons donc avec $A^{(2)} \in \mathbb{C}^{(I-2) \times (I-2)}$ une matrice inversible

$$P^{(2)}A^{(1)} = \begin{bmatrix} R_{2,2} & (R_{2,j})_{3 \leq j \leq I} \\ 0_{(I-2) \times 1} & A^{(2)} \end{bmatrix} \text{ avec } A^{(2)} = \begin{bmatrix} (P^{(2)}A^{(1)})_{2,2} & \cdots & (P^{(2)}A^{(1)})_{2,I-1} \\ \vdots & \ddots & \vdots \\ (P^{(2)}A^{(1)})_{I-1,2} & \cdots & (P^{(2)}A^{(1)})_{I-1,I-1} \end{bmatrix}.$$

En réinterprétant cette relation, nous avons

$$Q^{(2)}A = \begin{bmatrix} R_{1,1} & R_{1,2} & R_{1,3} & \cdots & R_{1,I} \\ 0 & R_{2,2} & R_{2,3} & \cdots & R_{2,I} \\ 0 & 0 & (Q^{(2)}A)_{3,3} & \cdots & (Q^{(2)}A)_{3,I} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & (Q^{(2)}A)_{I,3} & \cdots & (Q^{(2)}A)_{I,I} \end{bmatrix} \text{ avec } Q^{(2)} = \begin{bmatrix} 1 & 0_{1 \times (I-1)} \\ 0_{(I-1) \times 1} & P^{(2)} \end{bmatrix} P^{(1)}.$$

Nous remarquons enfin que la matrice $Q^{(2)} \in \mathbb{C}^{I \times I}$ est unitaire car

$$(Q^{(2)})^*Q^{(2)} = (P^{(1)})^* \begin{bmatrix} 1 & 0_{1 \times (I-1)} \\ 0_{(I-1) \times 1} & P^{(2)} \end{bmatrix}^* \begin{bmatrix} 1 & 0_{1 \times (I-1)} \\ 0_{(I-1) \times 1} & P^{(2)} \end{bmatrix} P^{(1)} = (P^{(1)})^* \begin{bmatrix} 1 & 0_{1 \times (I-1)} \\ 0_{(I-1) \times 1} & (P^{(2)})^*P^{(2)} \end{bmatrix} P^{(1)} = Id.$$

5.3.2 Itération de la méthode

On part de la factorisation de l'étape $m-1$

$$Q^{(m-1)}A = \begin{bmatrix} R_{1,1} & R_{1,2} & \cdots & R_{1,m-2} & R_{1,m-1} & R_{1,m} & \cdots & R_{1,I} \\ 0 & R_{2,2} & \cdots & R_{2,m-2} & R_{2,m-1} & R_{2,m} & \cdots & R_{2,I} \\ 0 & \ddots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & R_{m-2,m-2} & R_{m-2,m-1} & R_{m-2,m} & \cdots & R_{m-2,I} \\ 0 & 0 & \cdots & 0 & R_{m-1,m-1} & R_{m-1,m} & \cdots & R_{m-1,I} \\ 0 & 0 & \cdots & 0 & 0 & (Q^{(m-1)}A)_{m,m} & \cdots & (Q^{(m-1)}A)_{m,I} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & 0 & (Q^{(m-1)}A)_{I,m} & \cdots & (Q^{(m-1)}A)_{I,I} \end{bmatrix}$$

1. $(R_{i,j})_{1 \leq i \leq m-1, 1 \leq j \leq I} \in \mathbb{C}^{(m-1) \times I}$ une matrice triangulaire supérieure définie aux étapes précédentes.

$$R_{i,j} = 0 \text{ si } i > j.$$

2. $Q^{(m-1)}$ une matrice unitaire

On définit $A^{(m-1)}$ la matrice carrée inversible de taille $(I+1-m)$

$$A^{(m-1)} = \begin{bmatrix} (Q^{(m-1)}A)_{m,m} & \cdots & (Q^{(m-1)}A)_{m,I} \\ \vdots & \ddots & \vdots \\ (Q^{(m-1)}A)_{I,m} & \cdots & (Q^{(m-1)}A)_{I,I} \end{bmatrix}$$

On définit $P^{(m)}$ pour $A^{(m-1)}$ de la même manière que l'on a défini $P^{(1)}$ pour A . On a alors

$$P^{(m)}A^{(m-1)} = \begin{bmatrix} R_{m,m} & (R_{m,j})_{m+1 \leq j \leq I} \\ 0_{(I-m) \times 1} & A^{(m)} \end{bmatrix}$$

On a alors

$$Q^{(m)} = \begin{bmatrix} Id_{(m-1) \times (m-1)} & 0_{(m-1) \times (I+1-m)} \\ 0_{(I+1-m) \times (m-1)} & P^{(m)} \end{bmatrix} Q^{(m-1)}$$

De même qu'à la seconde étape, on a

$$Q^{(m)}A = \begin{bmatrix} (R_{i,j})_{1 \leq i \leq m, 1 \leq j \leq m} & (R_{i,j})_{1 \leq i \leq m, m+1 \leq j \leq I} \\ 0_{(I-m) \times m} & A^{(m)} \end{bmatrix}$$

5.3.3 Conclusion

Il ne nous reste plus qu'à itérer cet algorithme jusqu'à aboutir à

$$Q^{(I-1)} A = R.$$

avec $Q^{(I-1)}$ une matrice unitaire et R une matrice triangulaire. Nous définissons

$$Q = (Q^{(I-1)})^*.$$

Il ne nous reste qu'à multiplier la matrice $Q^{(I-1)}$ par une matrice diagonale unitaire qui assure que tous les coefficients diagonaux de R sont des réels positifs.

Ceci termine la factorisation.

5.4 Exemple d'implémentation en Python

Une implémentation de cet algorithme en Python est la suivante. Elle utilise la capacité qu'a Python à extraire les blocs de manière aisée. Voici un exemple d'implémentation ([www](#))

```
import numpy as np

def householder_reflection(A):
    # Dimensions de la matrice A
    m, n = A.shape
    # Matrice Q initialement comme matrice identité
    Q = np.eye(m)
    R = A.copy()

    for k in range(n):
        # Sélection du vecteur à transformer
        x = R[k:, k]

        # Calcul du vecteur de réflexion de Householder
        e = np.zeros_like(x)
        e[0] = 1
        u = x + np.linalg.norm(x) * np.sign(x[0])*e
        v = u / np.linalg.norm(u)

        # Création de la matrice de réflexion de Householder
        H_k = np.eye(m)
        H_k[k:, k:] -= 2.0 * np.outer(v, v.conj())

        # Mise à jour de R et Q
        R = H_k @ R
        Q = Q @ H_k.T

    return Q, R

# Exemple d'utilisation
A = np.array([[0, 1, 3], [2, 4, 1], [0, 1, 4]])
Q, R = householder_reflection(A)

print("Matrice Q :")
print(Q)
print("Matrice R :")
```

```
print(R)

print('Vérification')
print(Q@R)
```

5.5 Application à la résolution d'un système linéaire

La factorisation QR permet de résoudre facilement le système

Pour $\mathbf{f} \in \mathbb{C}^I$ chercher $\mathbf{x} \in \mathbb{C}^I$ tel que $M\mathbf{x} = \mathbf{f}$.

avec la matrice $M \in \mathbb{C}^{I \times I}$ qui est factorisée sous la forme $M = QR$.

En posant $\mathbf{y} = R\mathbf{x}$, ce problème revient à résoudre deux systèmes linéaires

Pour $\mathbf{f} \in \mathbb{C}^I$ chercher $\mathbf{y} \in \mathbb{C}^I$ tel que $Q\mathbf{y} = \mathbf{f}$.

Pour $\mathbf{y} \in \mathbb{C}^I$ chercher $\mathbf{x} \in \mathbb{C}^I$ tel que $R\mathbf{x} = \mathbf{y}$.

Nous allons expliquer comment résoudre un système unitaire et un système triangulaire.

5.5.1 Résolution des systèmes unitaires

Nous considérons une matrice carrée $Q \in \mathbb{C}^{I \times I}$ unitaire et le système linéaire

Pour $\mathbf{f} \in \mathbb{C}^I$ chercher $\mathbf{y} \in \mathbb{C}^I$ tel que $Q\mathbf{y} = \mathbf{f}$.

Ainsi, la matrice Q vérifie

$$Q^*Q = Id.$$

L'inverse de Q est donné sans calcul par

$$Q^{-1} = Q^*$$

Le calcul de $\mathbf{y}$ ne nécessite que très peu d'effort car il est donné par la formule

$$\mathbf{y} = Q^*\mathbf{f}.$$

5.5.2 Résolution des systèmes triangulaires

On considère une matrice triangulaire supérieure inversible

$$R = \begin{bmatrix} R_{1,1} & R_{1,2} & R_{1,3} & \cdots & R_{1,I} \\ 0 & R_{2,2} & R_{2,3} & \cdots & R_{2,I} \\ 0 & 0 & R_{3,3} & \cdots & R_{3,I} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & 0 & \cdots & R_{I,I} \end{bmatrix}$$

La résolution d'un système triangulaire supérieur

Pour $\mathbf{y} \in \mathbb{C}^I$ chercher $\mathbf{x} \in \mathbb{C}^I$ tel que $R\mathbf{x} = \mathbf{y}$.

ne passe pas par le calcul de l'inverse de R mais par ce que l'on appelle une montée. Ceci consiste à résoudre les équations de ce système de bas en haut.

$$\left\{ \begin{array}{lcl} R_{I,I}x_I = y_I & \implies & x_I = \frac{y_I}{R_{I,I}} \\ R_{I-1,I-1}x_{I-1} + R_{I-1,I}x_I = y_{I-1} & \implies & x_{I-1} = \frac{y_{I-1} - R_{I-1,I}x_I}{R_{I-1,I-1}} \\ & \dots & \implies \dots \\ R_{i,i}x_i + \sum_{j=i+1}^I R_{i,j}x_j = y_i & \implies & x_i = \frac{y_i - \sum_{j=i+1}^I R_{i,j}x_j}{R_{i,i}} \\ & \dots & \implies \dots \\ R_{1,1}x_1 + \sum_{j=2}^I R_{1,j}x_j = y_1 & \implies & x_1 = \frac{y_1 - \sum_{j=2}^I R_{1,j}x_j}{R_{1,1}} \end{array} \right.$$

On calcule donc d'abord x_I , puis x_{I-1} , puis $\dots$, puis x_2 et enfin x_1 .

5.6 Exercices.

5.6.1 Exercice. Calcul d'un inverse

Soit $R > 0$, $\theta \in]0, \pi[$ et $\varphi \in [0, 2\pi[$, calculer l'inverse de la matrice

$$M = \begin{bmatrix} \sin(\theta) \cos(\varphi) & R \cos(\theta) \cos(\varphi) & -R \sin(\theta) \sin(\varphi) \\ \sin(\theta) \sin(\varphi) & R \cos(\theta) \sin(\varphi) & R \sin(\theta) \cos(\varphi) \\ \cos(\theta) & -R \sin(\theta) & 0 \end{bmatrix}$$

Correction On remarque que les colonnes de M forment une base orthogonale. On écrit donc cette matrice comme le produit d'une matrice orthogonale et d'une matrice diagonale. On calcule les normes des trois colonnes de M .

$$\begin{bmatrix} \sin(\theta) \cos(\varphi) & R \cos(\theta) \cos(\varphi) & -R \sin(\theta) \sin(\varphi) \\ \sin(\theta) \sin(\varphi) & R \cos(\theta) \sin(\varphi) & R \sin(\theta) \cos(\varphi) \\ \cos(\theta) & -R \sin(\theta) & 0 \end{bmatrix}^* \begin{bmatrix} \sin(\theta) \cos(\varphi) & R \cos(\theta) \cos(\varphi) & -R \sin(\theta) \sin(\varphi) \\ \sin(\theta) \sin(\varphi) & R \cos(\theta) \sin(\varphi) & R \sin(\theta) \cos(\varphi) \\ \cos(\theta) & -R \sin(\theta) & 0 \end{bmatrix} \\ = \begin{bmatrix} 1 & 0 & 0 \\ 0 & R^2 & 0 \\ 0 & 0 & R^2 \sin^2(\theta) \end{bmatrix}$$

Il suit que

$$M^*M = D \quad \text{avec } D = \begin{bmatrix} 1 & 0 & 0 \\ 0 & R^2 & 0 \\ 0 & 0 & R^2 \sin^2(\theta) \end{bmatrix}.$$

On a donc $D^{-1}M^*M = Id$. Il suit que

$$M^{-1} = D^{-1}M^*.$$

Il suit que

$$M^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{R^2} & 0 \\ 0 & 0 & \frac{1}{R^2 \sin^2(\theta)} \end{bmatrix} \begin{bmatrix} \sin(\theta) \cos(\varphi) & \sin(\theta) \sin(\varphi) & \cos(\theta) \\ R \cos(\theta) \cos(\varphi) & R \cos(\theta) \sin(\varphi) & -R \sin(\theta) \\ -R \sin(\theta) \sin(\varphi) & R \sin(\theta) \cos(\varphi) & 0 \end{bmatrix}$$

On a l'expression de l'inverse de M

$$M^{-1} = \begin{bmatrix} \sin(\theta) \cos(\varphi) & \sin(\theta) \sin(\varphi) & \cos(\theta) \\ \frac{\cos(\theta) \cos(\varphi)}{R} & \frac{\cos(\theta) \sin(\varphi)}{R} & -\frac{\sin(\theta)}{R} \\ -\frac{\sin(\varphi)}{R \sin(\theta)} & \frac{\cos(\varphi)}{R \sin(\theta)} & 0 \end{bmatrix}$$

5.6.2 Exercice. Les symétries

On dit que $P \in \mathbb{C}^{I \times I}$ est une matrice de symétrie si $P^2 = Id$.

1. Montrer qu'il existe deux sous-espaces vectoriels H_1 et H_2 en somme directe tels que

$$\forall \mathbf{x} \in H_1 \quad P\mathbf{x} = \mathbf{x} \quad \text{et} \quad \forall \mathbf{x} \in H_2 \quad P\mathbf{x} = -\mathbf{x}.$$

2. Montrer que si $\mathbf{x} = \mathbf{x}_1 + \mathbf{x}_2$ avec $\mathbf{x}_1 \in H_1$ et $\mathbf{x}_2 \in H_2$ alors

$$\mathbf{x}_1 = \frac{P\mathbf{x} + \mathbf{x}}{2} \quad \text{et} \quad \mathbf{x}_2 = \frac{\mathbf{x} - P\mathbf{x}}{2}$$

3. Montrer qu'il s'agit d'une symétrie orthogonale si $P^* = P$.

Correction

1. Le polynôme $p(\lambda) = \lambda^2 - 1$ est annulateur de P . Le polynôme minimal de P divise p . Les racines du polynôme minimal ne peuvent donc être égales qu'à 1 et -1 . D'autre part, ce polynôme n'admet que des racines simples, donc

$$\mathbb{C}^I = \text{Ker}(P - Id) \oplus \text{Ker}(P + Id)$$

2. Nous remarquons que

$$\mathbf{x} = \mathbf{x}_1 + \mathbf{x}_2 \quad \text{avec} \quad \mathbf{x}_1 = \frac{\mathbf{x} + P\mathbf{x}}{2} \quad \text{et} \quad \mathbf{x}_2 = \frac{\mathbf{x} - P\mathbf{x}}{2}$$

Nous remarquons que

$$P\mathbf{x}_1 = \frac{P\mathbf{x} + P^2\mathbf{x}}{2} = \frac{P\mathbf{x} + \mathbf{x}}{2} = \mathbf{x}_1 \quad \text{et} \quad P\mathbf{x}_2 = \frac{P\mathbf{x} - P^2\mathbf{x}}{2} = \frac{P\mathbf{x} - \mathbf{x}}{2} = -\mathbf{x}_2$$

3. La symétrie est orthogonale si $H_1 \perp H_2$. Ceci implique pour tout $\mathbf{x} \in \mathbb{C}^I$

$$(\mathbf{x}_1, \mathbf{x}_2) = 0 \quad \implies \quad \left(\frac{P\mathbf{x} + \mathbf{x}}{2}, \frac{P\mathbf{x} - \mathbf{x}}{2} \right) = 0$$

On a en développant

$$(P\mathbf{x}, P\mathbf{x}) + (\mathbf{x}, P\mathbf{x}) - (P\mathbf{x}, \mathbf{x}) - (\mathbf{x}, \mathbf{x}) = 0$$

On prend la partie réelle de cette expression et on obtient que

$$(P\mathbf{x}, P\mathbf{x}) - (\mathbf{x}, \mathbf{x}) = 0$$

Il suit donc que P est une isométrie. Ceci implique que P est orthogonal.

Chapitre 6

Résolution des problèmes aux valeurs propres par factorisation QR

L'algorithme QR a été introduit par Francis [5]. Pour approfondir les notions de ce chapitre, on pourra consulter [4, 6, 10].

6.1 Rappel sur la décomposition QR

Dans cette section, nous allons avoir recours à la décomposition QR qui s'écrit

$$A = QR$$

avec $Q \in \mathbb{C}^{I \times I}$ une matrice unitaire et $R \in \mathbb{C}^{I \times I}$ une matrice triangulaire supérieure.

Cette décomposition n'est pas unique. En effet, nous avons le résultat suivant

Proposition 13 (Quasi-unicité de la décomposition QR). *Soit $A \in \mathbb{C}^{I \times I}$ une matrice inversible dont deux décompositions QR sont données par*

$$Q_1 R_1 = A = Q_2 R_2$$

avec $Q_1 \in \mathbb{C}^{I \times I}$ et $Q_2 \in \mathbb{C}^{I \times I}$ deux matrices unitaires et $R_1 \in \mathbb{C}^{I \times I}$ et $R_2 \in \mathbb{C}^{I \times I}$ deux matrices triangulaires supérieures.

Il existe une matrice diagonale $D \in \mathbb{C}^{I \times I}$ telle que pour $1 \leq i \leq I$

$$|D_{i,i}| = 1, \quad Q_2 = Q_1 D \quad \text{et} \quad D R_2 = R_1.$$

Preuve. Les matrices Q et R sont inversibles. Ainsi les termes diagonaux de R sont tous différents de 0. Il suffit de remarquer que

$$R_1^* R_1 = R_1^* Q_1^* Q_1 R_1 = A^* A = R_2^* Q_2^* Q_2 R_2 = R_2^* R_2.$$

Comme

$$(R^* R)_{i,j} = \sum_{k=1}^I \overline{R_{k,i}} R_{k,j}$$

il suit pour $i = j = 1$ en tenant compte du fait que $R_{k,i} = 0$ pour $k > i$

$$|(R_1)_{1,1}|^2 = |(R_2)_{1,1}|^2 \implies (R_1)_{1,1} = d_{1,1} (R_2)_{1,1} \text{ avec } |d_{1,1}| = 1$$

et pour $i \geq 2$ et $j = 1$

$$\overline{(R_1)_{1,i}} (R_1)_{1,1} = \overline{(R_2)_{1,i}} (R_2)_{1,1} \implies \overline{(R_1)_{1,i}} d_{1,1} (R_2)_{1,1} = \overline{(R_2)_{1,i}} (R_2)_{1,1} \implies \overline{(R_1)_{1,i}} d_{1,1} = \overline{(R_2)_{1,i}}.$$

Ceci implique comme $|d_{1,1}| = 1$

$$(R_1)_{1,i} \overline{d_{1,1}} = (R_2)_{1,i} \implies (R_1)_{1,i} = d_{1,1} (R_2)_{1,i}$$

Pour $i = 2$ et $j = 2$, nous avons

$$|(R_1)_{1,2}|^2 + |(R_1)_{2,2}|^2 = |(R_2)_{1,2}|^2 + |(R_2)_{2,2}|^2 \implies |(R_1)_{2,2}|^2 = |(R_2)_{2,2}|^2$$

Ainsi, il existe $d_{2,2} \in \mathbb{C}$ tel que

$$(R_1)_{2,2} = d_{2,2} (R_2)_{2,2} \text{ avec } |d_{2,2}| = 1$$

Pour $i = 2$ et $j > 2$, nous avons

$$\overline{(R_1)_{1,2}}(R_1)_{1,j} + \overline{(R_1)_{2,2}}(R_1)_{2,j} = \overline{(R_2)_{1,2}}(R_2)_{1,j} + \overline{(R_2)_{2,2}}(R_2)_{2,j}$$

Comme $(R_1)_{1,j} = d_{1,1}(R_2)_{1,j}$ avec $|d_{1,1}| = 1$, nous avons

$$\overline{(R_1)_{1,2}}(R_1)_{1,j} = |d_{1,1}|^2 \overline{(R_2)_{1,2}}(R_2)_{1,j} = \overline{(R_2)_{1,2}}(R_2)_{1,j}.$$

Il suit que

$$\overline{(R_1)_{2,2}}(R_1)_{2,j} = \overline{(R_2)_{2,2}}(R_2)_{2,j}$$

et par conséquent

$$\overline{d_{2,2}(R_2)_{2,2}}(R_1)_{2,j} = \overline{(R_2)_{2,2}}(R_2)_{2,j}$$

Comme $|d_{2,2}| = 1$, nous avons

$$(R_1)_{2,j} = d_{2,2}(R_2)_{2,j}$$

On peut itérer pour obtenir le résultat souhaité

$$\forall i \in \llbracket 1, I \rrbracket, \exists d_{i,i} \in \mathbb{C} \text{ tel que } |d_{i,i}| = 1 \text{ et } (R_1)_{i,j} = d_{i,i}(R_2)_{i,j}$$

C'est-à-dire $R_1 = DR_2$. Il suit que $Q_1 R_1 = Q_1 D R_2 = Q_2 R_2$ et donc $Q_1 D = Q_2$.

Remarque 11. On assure l'unicité de la décomposition QR en assurant que

$$\forall i \in \llbracket 1, I \rrbracket \quad R_{i,i} > 0.$$

Si $R_{i,i} > 0$ pour tout $i \in \llbracket 1, I \rrbracket$, alors on parle de la décomposition QR . Dans le cas général, on parlera d'une décomposition QR .

6.2 L'algorithme de calcul des valeurs propres

Nous allons définir deux suites de matrices

$$(\Lambda^{[k]} \in \mathbb{C}^{I \times I})_{k \in \mathbb{N}} \quad \text{et} \quad (Q^{[k]} \in \mathbb{C}^{I \times I})_{k \in \mathbb{N}}$$

Initialisation : On pose $\Lambda^{[0]} = A$ et $Q^{[0]} = Id$.

Itération sur l'indice k : on calcule une décomposition QR de $\Lambda^{[k]}$

$$\Lambda^{[k]} = Q^{(k+1)} R^{(k+1)}$$

On définit les matrices suivantes

$$\Lambda^{[k+1]} = R^{(k+1)} Q^{(k+1)} \quad \text{et} \quad Q^{[k+1]} = Q^{[k]} Q^{(k+1)}$$

Critère d'arrêt : On va vérifier si tous les coefficients sont bien plus petits qu'un seuil de convergence ε . La boucle for portant sur k sera remplacée par une boucle tant que

$$\exists (i, j) \in \mathbb{N}^2 \text{ tel que } 1 \leq j < i \leq I \text{ et } |\Lambda_{i,j}^{[k]}| > \varepsilon$$

Nous avons le théorème suivant

Théorème 4. La suite de matrices $(\Lambda^{[k]})_{k \in \mathbb{N}}$ converge vers une matrice triangulaire supérieure qui contient sur sa diagonale les valeurs propres de A .

6.3 Cadre pour la démonstration du théorème

Nous ne démontrerons pas ce théorème dans le cas général mais seulement sous des hypothèses qui permettent de nettement simplifier la présentation de ce chapitre tout en faisant ressortir les idées importantes de la preuve classique.

Nous ne traiterons que le cas d'une matrice $A \in \mathbb{C}^{I \times I}$ hermitienne définie positive. Nous cherchons dans cette section à calculer les valeurs propres et vecteurs propres de A . Nous rappelons que la matrice A est diagonalisable

$$A = P\Lambda P^*$$

avec $P \in \mathbb{C}^{I \times I}$ une matrice unitaire et $\Lambda \in \mathbb{C}^{I \times I}$ une matrice diagonale dont les coefficients diagonaux sont les valeurs propres de A ordonnées par ordre décroissant.

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & 0 & \cdots & 0 \\ 0 & \lambda_2 & 0 & \cdots & 0 \\ 0 & 0 & \ddots & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \lambda_I \end{pmatrix} \quad \text{avec } \lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_I.$$

Nous supposons d'une part que les valeurs propres de A sont simples

$$\lambda_1 > \lambda_2 > \cdots > \lambda_I > 0.$$

D'autre part, nous supposons que la matrice P^* admet une décomposition LU sans permutation

$$P^* = LU.$$

Toutes ces hypothèses peuvent être relâchées au prix d'une complexification des factorisations qui sont présentes dans la preuve.

6.4 Preuve de convergence

La preuve consiste à comparer deux décompositions QR de A^k .

6.4.1 Première décomposition QR

La première décomposition QR consiste à avoir recours aux objets introduits pour l'algorithme précédent.

Proposition 14. Les matrices $Q^{[k]} \in \mathbb{C}^{I \times I}$ et $R^{[k]} \in \mathbb{C}^{I \times I}$ définies par

$$Q^{[k]} = Q^{(1)} \cdots Q^{(k)} \quad \text{et} \quad R^{[k]} = R^{(k)} \cdots R^{(1)}.$$

sont respectivement unitaire et triangulaire supérieure.

Preuve. La matrice $Q^{[k]}$ est unitaire car

$$(Q^{[k]})^* Q^{[k]} = (Q^{(1)} \cdots Q^{(k)})^* Q^{(1)} \cdots Q^{(k)} = (Q^{(k)})^* \cdots (Q^{(2)})^* (Q^{(1)})^* Q^{(1)} Q^{(2)} \cdots Q^{(k)}.$$

Nous tenons compte du fait que $(Q^{(1)})^* Q^{(1)} = Id$ et obtenons

$$(Q^{[k]})^* Q^{[k]} = (Q^{(k)})^* \cdots (Q^{(2)})^* Q^{(2)} \cdots Q^{(k)}.$$

En itérant, nous avons

$$(Q^{[k]})^* Q^{[k]} = Id.$$

Pour montrer que $R^{[k]}$ est triangulaire supérieure, il suffit de remarquer que le produit de deux matrices triangulaires supérieures R et S est une matrice triangulaire supérieure. Nous avons pour $i > k$

$$(RS)_{i,k} = \sum_{j=1}^I R_{i,j} S_{j,k}$$

Comme $i > k$, tous les termes de cette somme sont nuls.

$$(RS)_{i,k} = 0 \text{ si } i > k.$$

Ceci termine la preuve.

Proposition 15. *Pour tout $k \in \mathbb{N}$, une décomposition QR de A^k est donnée par*

$$A^k = Q^{[k]} R^{[k]}$$

Preuve. Nous venons d'obtenir que $Q^{[k]} \in \mathbb{C}^{I \times I}$ est unitaire et $R^{[k]} \in \mathbb{C}^{I \times I}$ est triangulaire supérieure. Comme $A = Q^{(1)} R^{(1)}$, nous avons

$$A^k = (Q^{(1)} R^{(1)})^k = Q^{(1)} (R^{(1)} Q^{(1)})^{k-1} R^{(1)} = Q^{(1)} (\Lambda^{[1]})^{k-1} R^{(1)} = Q^{(1)} (Q^{(2)} R^{(2)})^{k-1} R^{(1)} = Q^{[k]} R^{[k]}.$$

On itère le raisonnement et on obtient que

$$A^k = Q^{(1)} Q^{(2)} (R^{(2)} Q^{(2)})^{k-2} R^{(2)} R^{(1)} = Q^{(1)} Q^{(2)} (\Lambda^{[2]})^{k-2} R^{(2)} R^{(1)} = Q^{(1)} Q^{(2)} Q^{(3)} (\Lambda^{[3]})^{k-3} R^{(3)} R^{(2)} R^{(1)}.$$

On obtient finalement

$$A^k = Q^{(1)} Q^{(2)} \dots Q^{(k)} R^{(k)} \dots R^{(2)} R^{(1)}$$

Ceci termine la preuve.

6.4.2 Seconde décomposition QR

La seconde décomposition QR passe par la diagonalisation de $A = P \Lambda P^*$. Les puissances de A sont facilement exprimables à l'aide de cette décomposition

$$A^k = P \Lambda^k P^* \quad \text{pour tout } k \in \mathbb{N}.$$

Par hypothèse, la matrice P^* admet une factorisation LU . Il existe une matrice $L \in \mathbb{C}^{I \times I}$ triangulaire inférieure et une matrice $U \in \mathbb{C}^{I \times I}$ triangulaire supérieure telles que

$$P^* = LU \quad \text{et} \quad L_{i,i} = 1 \quad \text{pour tout } 1 \leq i \leq I.$$

La factorisation de A^k s'écrit

$$A^k = P \Lambda^k LU = P D^{(k)} \Lambda^k U \text{ avec } D^{(k)} = \Lambda^k L \Lambda^{-k} \in \mathbb{C}^{I \times I}.$$

La matrice P est unitaire tandis que la matrice $\Lambda^k U$ est triangulaire supérieure. La matrice $D^{(k)}$ n'est ni unitaire ni triangulaire supérieure (nous allons voir dans la preuve qui suit qu'elle est triangulaire inférieure). Afin d'obtenir une factorisation QR de A^k , nous factorisons $D^{(k)}$

$$D^{(k)} = Q^{(k)} R^{(k)}$$

avec $Q^{(k)}$ une matrice unitaire et $R^{(k)}$ une matrice triangulaire supérieure à coefficients diagonaux positifs. Nous obtenons donc la seconde factorisation QR de A^k

$$A^k = (P Q^{(k)}) (R^{(k)} \Lambda^k U)$$

La suite de la preuve consiste à démontrer que les matrices $Q^{(k)}$ et $R^{(k)}$ convergent vers l'identité car $D^{(k)}$ converge vers l'identité.

Proposition 16. La matrice $D^{(k)}$ vérifie

$$\lim_{k \rightarrow +\infty} D^{(k)} = Id$$

Preuve. Nous rappelons que les valeurs propres de A sont deux à deux distinctes et vérifient

$$\lambda_1 > \lambda_2 > \dots > \lambda_I$$

Ce résultat suit tout simplement de l'évaluation du produit

$$D^{(k)} = \begin{bmatrix} \lambda_1^k & 0 & \dots & 0 \\ 0 & \lambda_2^k & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_I^k \end{bmatrix} \begin{bmatrix} L_{1,1} & 0 & \dots & 0 \\ L_{2,1} & L_{2,2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ L_{I,1} & L_{I,2} & \dots & L_{I,I} \end{bmatrix} \begin{bmatrix} \frac{1}{\lambda_1^k} & 0 & \dots & 0 \\ 0 & \frac{1}{\lambda_2^k} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{\lambda_I^k} \end{bmatrix}.$$

La multiplication à gauche par une matrice diagonale multiplie les lignes tandis que la multiplication à droite par une matrice diagonale multiplie les colonnes

$$D^{(k)} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ \left(\frac{\lambda_2}{\lambda_1}\right)^k L_{2,1} & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \left(\frac{\lambda_I}{\lambda_1}\right)^k L_{I,1} & \left(\frac{\lambda_I}{\lambda_2}\right)^k L_{I,2} & \dots & 1 \end{bmatrix} \cdot \text{c'est-à-dire } D_{i,j}^{(k)} = \left(\frac{\lambda_i}{\lambda_j}\right)^k L_{i,j}$$

Comme les valeurs propres sont classées par ordre décroissant, nous avons pour $i > j$

$$\lim_{k \rightarrow +\infty} \left(\frac{\lambda_i}{\lambda_j}\right)^k = 0.$$

Ceci conclut la preuve.

Proposition 17. Les facteurs de la décomposition QR de $D^{(k)} = Q^{(k)}R^{(k)}$ vérifient

$$\lim_{k \rightarrow +\infty} Q^{(k)} = Id \quad \text{et} \quad \lim_{k \rightarrow +\infty} R^{(k)} = Id$$

Preuve. Comme $(Q^{(k)})^* Q^{(k)} = Id$, nous avons

$$(D^{(k)})^* D^{(k)} = (Q^{(k)} R^{(k)})^* Q^{(k)} R^{(k)} = (R^{(k)})^* (Q^{(k)})^* Q^{(k)} R^{(k)} = (R^{(k)})^* R^{(k)}.$$

Comme $D^{(k)}$ tend vers l'identité, nous avons que

$$\lim_{k \rightarrow +\infty} (R^{(k)})^* R^{(k)} = \lim_{k \rightarrow +\infty} (D^{(k)})^* D^{(k)} = Id$$

Il suit l'identité pour $1 \leq i, j \leq I$

$$\sum_{\ell=1}^I \overline{R_{\ell,i}^{(k)}} R_{\ell,j}^{(k)} \xrightarrow[k \rightarrow +\infty]{} \delta_{i,j}.$$

La matrice $R^{(k)}$ étant triangulaire supérieure, nous avons pour $i = j = 1$

$$|R_{1,1}^{(k)}|^2 = \overline{R_{1,1}^{(k)}} R_{1,1}^{(k)} \xrightarrow[k \rightarrow +\infty]{} 1 \implies R_{1,1}^{(k)} \xrightarrow[k \rightarrow +\infty]{} 1.$$

Nous avons pour $i = 1$ et $j > 1$

$$\overline{R_{1,1}^{(k)}} R_{1,j}^{(k)} \xrightarrow[k \rightarrow +\infty]{} 0 \implies R_{1,j}^{(k)} \xrightarrow[k \rightarrow +\infty]{} 0.$$

On a pour $i = j = 2$

$$|\mathbf{R}_{1,2}^{(k)}|^2 + |\mathbf{R}_{2,2}^{(k)}|^2 \xrightarrow[k \rightarrow +\infty]{} 1. \implies |\mathbf{R}_{2,2}^{(k)}|^2 \xrightarrow[k \rightarrow +\infty]{} 1. \implies \mathbf{R}_{2,2}^{(k)} \xrightarrow[k \rightarrow +\infty]{} 1$$

On a aussi pour $i = 2$ et $j > 2$

$$\overline{\mathbf{R}_{1,2}^{(k)}} \mathbf{R}_{1,j}^{(k)} + \overline{\mathbf{R}_{2,2}^{(k)}} \mathbf{R}_{2,j}^{(k)} \xrightarrow[k \rightarrow +\infty]{} 0 \implies \mathbf{R}_{2,j}^{(k)} \xrightarrow[k \rightarrow +\infty]{} 0.$$

On peut continuer ainsi et obtenir que

$$\mathbf{R}_{i,j}^{(k)} \xrightarrow[k \rightarrow +\infty]{} \delta_{i,j}$$

Il suit que $\mathbf{R}^{(k)}$ tend vers l'identité. Comme $D^{(k)}$ tend vers l'identité, il en est de même pour

$$\mathbf{Q}^{(k)} = D^{(k)}(\mathbf{R}^{(k)})^{-1}.$$

Ceci termine la preuve.

6.4.3 Comparaison des deux développements

Nous avons exhibé deux décompositions QR de A^k

$$A^k = Q^{[k]} R^{[k]} = (PQ^{(k)}) (\mathbf{R}^{(k)} \Lambda^k U)$$

Par quasi-unicité de la décomposition QR , il existe donc une matrice diagonale $\Delta^{(k)} \in \mathbb{C}^{I \times I}$ telle que

$$PQ^{(k)} = Q^{[k]} \Delta^{(k)} \text{ avec } |\Delta_{i,i}^{(k)}| = 1.$$

Comme $\mathbf{Q}^{(k)}$ converge vers l'identité nous avons démontré la proposition

Proposition 18. *Il existe une matrice $\Delta^{(k)}$ diagonale telle que*

$$\lim_{k \rightarrow +\infty} Q^{[k]} \Delta^{(k)} = P \quad \text{avec } |\Delta_{i,i}^{(k)}| = 1 \text{ pour } 1 \leq i \leq I.$$

6.5 Conclusion

Proposition 19. *Pour tout $k \in \mathbb{N}$, nous avons l'identité*

$$A = Q^{[k]} \Lambda^{[k]} (Q^{[k]})^*$$

avec $Q^{[k]} = Q^{(1)} \dots Q^{(k-1)} Q^{(k)}$ et $R^{[k]} = R^{(k)} \dots R^{(2)} R^{(1)}$.

Preuve. Nous avons $\Lambda^{[k]} = R^{(k)} Q^{(k)}$. Il suit que

$$Q^{(k)} \Lambda^{[k]} (Q^{(k)})^* = Q^{(k)} R^{(k)} Q^{(k)} (Q^{(k)})^* = Q^{(k)} R^{(k)} = \Lambda^{[k-1]}.$$

On peut alors itérer et obtenir

$$Q^{(k-1)} Q^{(k)} \Lambda^{[k]} (Q^{(k)})^* (Q^{(k-1)})^* = Q^{(k-1)} \Lambda^{[k-1]} (Q^{(k-1)})^* = \Lambda^{[k-2]}.$$

Il suit par récurrence que

$$Q^{(1)} \dots Q^{(k-1)} Q^{(k)} \Lambda^{[k]} (Q^{(k)})^* (Q^{(k-1)})^* \dots (Q^{(1)})^* = \Lambda^{[0]} = A.$$

La conclusion suit de l'égalité $A^* B^* = (BA)^*$.

Cette dernière proposition termine la preuve du théorème sous l'hypothèse que A est hermitienne avec des valeurs propres de multiplicité simple et P^* admet une décomposition LU sans permutation.

Proposition 20. *La matrice $\Lambda^{[k]}$ converge vers Λ .*

Preuve. Comme $A = Q^{[k]} \Lambda^{[k]} (Q^{[k]})^*$, nous avons

$$(\Delta^{(k)})^* \Lambda^{[k]} \Delta^{(k)} = (\Delta^{(k)})^* (Q^{[k]})^* A Q^{[k]} \Delta^{(k)} = (Q^{[k]} \Delta^{(k)})^* A Q^{[k]} \Delta^{(k)}$$

Comme $Q^{[k]} \Delta^{(k)}$ converge vers P , nous obtenons que

$$(Q^{[k]} \Delta^{(k)})^* A Q^{[k]} \Delta^{(k)} \xrightarrow{k \rightarrow +\infty} P^* A P = \Lambda$$

C'est-à-dire

$$\|(\Delta^{(k)})^* \Lambda^{[k]} \Delta^{(k)} - \Lambda\| \xrightarrow{k \rightarrow +\infty} 0$$

avec $\|\cdot\|$ la norme matricielle euclidienne.

Comme la matrice $\Delta^{(k)}$ est unitaire, nous avons $(\Delta^{(k)})^* \Delta^{(k)} = Id$. Il suit que

$$\|\Lambda^{[k]} - \Lambda\| = \|\Delta^{(k)} (\Delta^{(k)})^* \Lambda^{[k]} \Delta^{(k)} (\Delta^{(k)})^* - \Delta^{(k)} (\Delta^{(k)})^* \Lambda \Delta^{(k)} (\Delta^{(k)})^*\|.$$

Il suit que

$$\|\Lambda^{[k]} - \Lambda\| \leq \|\Delta^{(k)}\| \cdot \|(\Delta^{(k)})^* \Lambda^{[k]} \Delta^{(k)} - (\Delta^{(k)})^* \Lambda \Delta^{(k)}\| \cdot \|(\Delta^{(k)})^*\|$$

Comme $\Delta^{(k)}$ est unitaire $\|\Delta^{(k)}\| = \|(\Delta^{(k)})^*\| = 1$, nous avons

$$\|\Lambda^{[k]} - \Lambda\| \leq \|(\Delta^{(k)})^* \Lambda^{[k]} \Delta^{(k)} - (\Delta^{(k)})^* \Lambda \Delta^{(k)}\|.$$

Comme $|\Delta_{i,i}^{(k)}| = 1$, nous avons $\Delta^{(k)} \Lambda (\Delta^{(k)})^* = \Lambda$ et

$$\|\Lambda^{[k]} - \Lambda\| \leq \|(\Delta^{(k)})^* \Lambda^{[k]} \Delta^{(k)} - \Lambda\|.$$

Il suit que

$$\lim_{k \rightarrow +\infty} \Lambda^{[k]} = \Lambda$$

6.6 Exemple d'implémentation en Python

Le programme suivant crée une matrice 10 par 10 tridiagonale qui a 5 sur la diagonale et -1 sur les sur- et sous-diagonales. Il calcule ensuite les valeurs propres de A . Il teste ensuite que le programme a bien fonctionné à l'aide des routines classiques de Python.

```
import numpy as np
n = 10
matrix = np.zeros((n, n))
for i in range(n):
    for j in range(n):
        if i == j:
            matrix[i, j] = 5
        elif abs(i - j) == 1:
            matrix[i, j] = -1
print(matrix)

def qr_iteration(A, tol=1e-6):
    """
    Calcule les valeurs propres d'une matrice en utilisant l'algorithme QR.
    Args:
        A: La matrice d'entrée.
```

```

    tol: La tolérance pour le critère d'arrêt.
Returns:
    Ak: La matrice après convergence.
"""
Ak = A.copy()
k = 0
while True:
    Q, R = np.linalg.qr(Ak)
    Ak = R @ Q
    k += 1
    # Critère d'arrêt : vérifier si les termes extradiagonaux sont petits
    if np.sum(np.abs(np.triu(Ak, 1))) < tol:
        break
return Ak

# Initialisation
A0 = matrix.copy()
# Boucle QR
Ak = qr_iteration(A0)

# Comparer la diagonale de Ak avec les valeurs propres de A
eigenvalues = np.linalg.eigvals(matrix)
eigenvalues_sorted = np.sort(eigenvalues)[::-1] # Trier les valeurs propres par ordre décroissant
diagonal_Ak = np.diag(Ak)
print("Diagonale de Ak :", diagonal_Ak)
print("Valeurs propres de A (triées) :", eigenvalues_sorted)

```

Chapitre 7

Résolution des systèmes surdéterminés par la factorisation QR

Pour approfondir les notions de ce chapitre, on pourra consulter [6, 13].

7.1 Présentation du cadre des systèmes surdéterminés

On considère un système linéaire à I lignes et J colonnes avec $I > J$. Étant donné $\mathbf{f} = (f_1, f_2, \dots, f_I)^T$, nous cherchons la solution $\mathbf{x} = (x_1, x_2, \dots, x_J)^T \in \mathbb{C}^J$

$$A\mathbf{x} = \mathbf{f}.$$

Nous supposons que A est de rang maximal. C'est-à-dire

$$\text{rang}(A) = J.$$

Ce système est presque toujours mal posé dans le sens où il n'a pas de solutions. Nous ne pouvons pas parler de sa solution. L'idée est de non pas chercher à le résoudre de manière exacte mais au mieux.

On va donc chercher $\mathbf{x} \in \mathbb{C}^J$ qui minimise la somme des équations mises au carré (afin de sommer des nombres positifs)

$$J(\mathbf{x}) = \sum_{i=1}^I \left| \sum_{j=1}^J A_{i,j} x_j - f_i \right|^2 = \sum_{i=1}^I |(A\mathbf{x})_i - f_i|^2 = \|A\mathbf{x} - \mathbf{f}\|_2^2$$

Nous allons traiter la question de l'existence et de l'unicité du minimiseur de J ainsi que la manière de le calculer à l'aide de la décomposition QR de A

$$A = QR,$$

avec

— $Q \in \mathbb{C}^{I \times J}$ dont les colonnes (et pas les lignes) sont des vecteurs de norme 1

$$Q = [\mathbf{w}^{(1)} \quad \mathbf{w}^{(2)} \quad \dots \quad \mathbf{w}^{(J)}] \quad \text{avec } \mathbf{w}^{(j)} \in \mathbb{C}^I \quad \text{et} \quad \mathbf{w}_i^{(j)} = Q_{i,j}$$

qui sont deux à deux orthogonaux

$$(\mathbf{w}^{(m)}, \mathbf{w}^{(n)}) = (\mathbf{w}^{(n)})^* \mathbf{w}^{(m)} = \delta_{m,n}$$

Cette matrice vérifie

$$Q^* Q = \begin{bmatrix} (\mathbf{w}^{(1)})^* \\ (\mathbf{w}^{(2)})^* \\ \vdots \\ (\mathbf{w}^{(J)})^* \end{bmatrix} [\mathbf{w}^{(1)} \quad \mathbf{w}^{(2)} \quad \dots \quad \mathbf{w}^{(J)}] = ((\mathbf{w}^{(m)})^* \mathbf{w}^{(n)})_{1 \leq m \leq J, 1 \leq n \leq J} = Id_{J \times J}$$

— $R \in \mathbb{C}^{J \times J}$ est une matrice triangulaire supérieure de taille J par J

$$R = \begin{bmatrix} R_{1,1} & R_{1,2} & \cdots & R_{1,J-1} & R_{1,J} \\ 0 & R_{2,2} & \cdots & R_{2,J-1} & R_{2,J} \\ \vdots & \ddots & \ddots & \vdots & \vdots \\ 0 & \cdots & \ddots & R_{J-1,J-1} & R_{J-1,J} \\ 0 & \cdots & \cdots & 0 & R_{J,J} \end{bmatrix}$$

7.2 Résolution par méthode QR

Nous commençons par évaluer J à l'aide de la décomposition QR de A

$$J(\mathbf{y}) = \|\mathbf{A}\mathbf{y} - \mathbf{f}\|^2 = \|Q\mathbf{R}\mathbf{y} - \mathbf{f}\|^2 = (Q\mathbf{R}\mathbf{y} - \mathbf{f}, Q\mathbf{R}\mathbf{y} - \mathbf{f})$$

Nous interprétons le produit scalaire à l'aide de produits matriciels

$$J(\mathbf{y}) = (Q\mathbf{R}\mathbf{y} - \mathbf{f})^*(Q\mathbf{R}\mathbf{y} - \mathbf{f})$$

Comme $(AB)^* = B^*A^*$, nous avons

$$J(\mathbf{y}) = (\mathbf{y}^* R^* Q^* - \mathbf{f}^*)(Q\mathbf{R}\mathbf{y} - \mathbf{f}) = \mathbf{y}^* R^* Q^* Q\mathbf{R}\mathbf{y} - \mathbf{y}^* R^* Q^* \mathbf{f} - \mathbf{f}^* Q\mathbf{R}\mathbf{y} + \mathbf{f}^* \mathbf{f}.$$

Comme $Q^*Q = Id$, nous avons

$$J(\mathbf{y}) = \mathbf{y}^* R^* R\mathbf{y} - \mathbf{y}^* R^* Q^* \mathbf{f} - \mathbf{f}^* Q\mathbf{R}\mathbf{y} + \mathbf{f}^* Q Q^* \mathbf{f} + \mathbf{f}^* \mathbf{f} - \mathbf{f}^* Q Q^* \mathbf{f}.$$

Nous obtenons donc

$$J(\mathbf{y}) = (\mathbf{y}^* R^* - \mathbf{f}^* Q)(R\mathbf{y} - Q^* \mathbf{f}) + \|\mathbf{f}\|^2 - \|Q^* \mathbf{f}\|^2 = \|R\mathbf{y} - Q^* \mathbf{f}\|^2 + \|\mathbf{f}\|^2 - \|Q^* \mathbf{f}\|^2.$$

Il suit de cette identité que

1. pour tout $\mathbf{y} \in \mathbb{C}^J$

$$J(\mathbf{y}) \geq \|\mathbf{f}\|^2 - \|Q^* \mathbf{f}\|^2$$

2. Si $\mathbf{x} = R^{-1}Q^* \mathbf{f}$, nous avons

$$J(\mathbf{x}) = \|\mathbf{f}\|^2 - \|Q^* \mathbf{f}\|^2.$$

Ainsi, $\mathbf{x} = R^{-1}Q^* \mathbf{f}$ est un minimiseur de J .

3. si $\mathbf{y} \neq R^{-1}Q^* \mathbf{f}$ alors $J(\mathbf{y}) > J(\mathbf{x})$

Nous venons donc d'obtenir qu'il existe un unique minimiseur de J

$$\mathbf{x} = R^{-1}Q^* \mathbf{f}.$$

Nous venons de définir la solution au sens des moindres carrés du problème surdéterminé.

7.3 Un exemple d'implémentation en Python

Le programme suivant calcule la solution au sens des moindres carrés du problème.

Chercher $(x, y, z) \in \mathbb{R}^3$ tel que

$$\begin{cases} x + y + z = 1, \\ 2x + 3y + 4z = 3, \\ 3x + 5y + 2z = 2, \\ 4x + 2y + 5z = 7, \end{cases}$$

On pourra faire un copié-collé depuis le site web (www)

```

import numpy as np
from scipy.linalg import qr

# Définir la matrice A (4x3) et le vecteur b (4x1)
A = np.array([[1, 1, 1],
              [2, 3, 4],
              [3, 5, 2],
              [4, 2, 5]], dtype=float)

b = np.array([1, 3, 2, 7], dtype=float)

# Étape 1 : Factorisation QR de la matrice A
Q, R = qr(A, mode='economic') # mode 'economic' donne une version compacte de Q et R

# Étape 2 : Calculer  $Q^T * b$ 
Qt_b = np.dot(Q.T, b)

# Étape 3 : Résoudre le système triangulaire supérieur  $R * x = Q^T * b$ 
x = np.linalg.solve(R, Qt_b)

# Afficher la solution
print("Solution du problème aux moindres carrés (valeurs de x) :")
print(x)

# Vérifier le résidu  $\|Ax - b\|$  pour s'assurer que la solution est bonne
residu = np.linalg.norm(np.dot(A, x) - b)
print("\nRésidu  $\|Ax - b\|$  :", residu)

```

Chapitre 8

Méthode du gradient pour l'inversion d'une matrice

Pour approfondir les notions de ce chapitre, on pourra consulter [1, 3, 10].

8.1 Rappel sur la dérivation des fonctions de plusieurs variables

Considérons une fonction F de classe $\mathcal{C}^2(\mathbb{R}^I)$ à valeurs dans $\mathbb{R}$. Nous rappelons que le vecteur gradient est défini comme le vecteur colonne qui contient les dérivées partielles d'ordre 1 de F .

$$\nabla F(\mathbf{x}) = \begin{bmatrix} \frac{\partial F}{\partial x_1}(\mathbf{x}) \\ \frac{\partial F}{\partial x_2}(\mathbf{x}) \\ \vdots \\ \frac{\partial F}{\partial x_I}(\mathbf{x}) \end{bmatrix}$$

La matrice hessienne est une matrice carrée de taille I par I à valeurs réelles

$$H_F(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 F}{\partial x_1^2}(\mathbf{x}) & \frac{\partial^2 F}{\partial x_1 \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 F}{\partial x_1 \partial x_I}(\mathbf{x}) \\ \frac{\partial^2 F}{\partial x_2 \partial x_1}(\mathbf{x}) & \frac{\partial^2 F}{\partial x_2^2}(\mathbf{x}) & \cdots & \frac{\partial^2 F}{\partial x_2 \partial x_I}(\mathbf{x}) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 F}{\partial x_I \partial x_1}(\mathbf{x}) & \frac{\partial^2 F}{\partial x_I \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 F}{\partial x_I^2}(\mathbf{x}) \end{bmatrix}$$

Soit F une fonction de classe $\mathcal{C}^2(\mathbb{R}^I)$. S'il existe $\mathbf{v}_{\mathbf{x}} \in \mathbb{R}^I$ et $A_{\mathbf{x}} \in \mathbb{R}^{I \times I}$ symétrique tels que

$$F(\mathbf{x} + \mathbf{h}) = F(\mathbf{x}) + \mathbf{v}_{\mathbf{x}}^T \mathbf{h} + \frac{\mathbf{h}^T A_{\mathbf{x}} \mathbf{h}}{2} + \|\mathbf{h}\|^2 \varepsilon_{\mathbf{x}}(\mathbf{h})$$

alors nous avons

$$\mathbf{v}_{\mathbf{x}} = \nabla F(\mathbf{x}) \text{ et } A_{\mathbf{x}} = H_F(\mathbf{x}).$$

Nous rappelons aussi que le gradient donne une direction de montée dans le sens où la fonction $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ définie par

$$\varphi(t) = F(\mathbf{x} + t \nabla F(\mathbf{x}))$$

est croissante au voisinage de zéro.

Ainsi, pour augmenter (resp. diminuer) la valeur de $F(\mathbf{x})$ il suffit de déplacer légèrement la position de $\mathbf{x}$ dans la direction du gradient (respectivement dans la direction opposée). La question de la distance optimale à parcourir est une des difficultés qui sera traitée dans ce chapitre.

8.2 Résolution des systèmes linéaires par méthode de minimisation

8.2.1 Cas d'une matrice symétrique définie positive

Soit $A \in \mathbb{R}^{I \times I}$ une matrice symétrique définie positive

$$F(\mathbf{x}) = \frac{1}{2}(A\mathbf{x}, \mathbf{x})_0 - (\mathbf{f}, \mathbf{x})_0$$

Le gradient de cette fonction de plusieurs variables est donné par

$$\nabla F(\mathbf{x}) = A\mathbf{x} - \mathbf{f}$$

et sa hessienne par

$$H_F(\mathbf{x}) = A.$$

Ces deux quantités sont déterminées en calculant le développement de Taylor de F

$$F(\mathbf{x} + \mathbf{h}) = \frac{1}{2}(A\mathbf{x}, \mathbf{x})_0 - (\mathbf{f}, \mathbf{x})_0 + (A\mathbf{x} - \mathbf{f}, \mathbf{h})_0 + \frac{1}{2}(A\mathbf{h}, \mathbf{h})_0$$

et en comparant avec son développement de Taylor à l'ordre 2

$$F(\mathbf{x} + \mathbf{h}) = F(\mathbf{x}) + (\nabla F(\mathbf{x}), \mathbf{h})_0 + \frac{1}{2}(H_F(\mathbf{x})\mathbf{h}, \mathbf{h})_0 + \|\mathbf{h}\|^2 \varepsilon(\mathbf{x}, \mathbf{h})$$

Une des difficultés de compréhension est liée au fait que dans ce cas précis $\varepsilon(\mathbf{x}, \mathbf{h}) = 0$. Nous nous intéressons à la recherche du minimum de la fonction F . La fonction F admet un unique point critique défini par

$$\nabla F(\mathbf{x}_*) = 0 \iff A\mathbf{x}_* = \mathbf{f}.$$

Ce point critique est un point de minimum (qui est donc unique) car la fonction F est strictement convexe (A est symétrique, définie et positive).

8.2.2 Cas d'une matrice inversible

Dans le cas où la matrice est inversible (non nécessairement symétrique), on va utiliser la méthode précédente en symétrisant le système précédent

$$\text{Chercher } \mathbf{x}_* \in \mathbb{R}^I \text{ tel que } A^T A \mathbf{x}_* = A^T \mathbf{f}.$$

Comme $A^T A$ est symétrique, définie et positive, on est ramené au cas précédent. Il est dans ce cas intéressant d'écrire la fonctionnelle F correspondante

$$F(\mathbf{x}) = \frac{1}{2}(A^T A \mathbf{x}, \mathbf{x})_0 - (A^T \mathbf{f}, \mathbf{x})_0 = \frac{1}{2}(A\mathbf{x}, A\mathbf{x})_0 - (\mathbf{f}, A\mathbf{x})_0$$

Nous ne traiterons pas ce cas par la suite car il peut se ramener au précédent et nous nous limiterons à l'étude des matrices symétriques, définies et positives.

8.3 La méthode du gradient

Rappelons que A est une matrice symétrique définie positive et que l'on cherche à résoudre par un algorithme itératif

$$\text{Chercher } \mathbf{x}_* \in \mathbb{R}^I \text{ tel que } A\mathbf{x}_* = \mathbf{f}.$$

On initialise l'algorithme par

$$\mathbf{x}^{(0)} = 0_{\mathbb{R}^I}$$

On construit alors une suite $\mathbf{x}^{(n)} \in \mathbb{R}^I$ en suivant une direction de descente

$$\mathbf{x}^{(n+1)} = \mathbf{x}^{(n)} - \alpha_n \nabla F(\mathbf{x}^{(n)}) \quad \text{avec } \nabla F(\mathbf{x}) = (A\mathbf{x} - \mathbf{f})$$

où il nous reste à déterminer $\alpha_n > 0$.

La fonction F étant quadratique, elle coïncide avec son développement de Taylor d'ordre 2. Cela nous permet de déterminer la variation de la fonction F au cours des itérations

$$F(\mathbf{x}^{(n+1)}) = F(\mathbf{x}^{(n)}) - \alpha_n (\nabla F(\mathbf{x}^{(n)}), \nabla F(\mathbf{x}^{(n)}))_0 + \frac{\alpha_n^2}{2} (\nabla F(\mathbf{x}^{(n)}), \nabla F(\mathbf{x}^{(n)}))_A \quad (8.1)$$

avec $(\cdot, \cdot)_A$ le produit scalaire défini par

$$(\mathbf{x}, \mathbf{y})_A = (A\mathbf{x}, \mathbf{y})_0.$$

Nous expliquons maintenant comment choisir le coefficient α_n afin d'obtenir un algorithme convergent.

8.3.1 Méthode du gradient à pas fixe

Dans cette section, nous présentons la méthode du gradient à pas fixe qui propose de choisir un $\alpha_n = \alpha$ constant afin de garantir la décroissance de F . On va choisir $\alpha > 0$ afin d'avoir

$$-\alpha(\mathbf{y}, \mathbf{y})_0 + \frac{\alpha^2}{2}(\mathbf{y}, \mathbf{y})_A < 0 \quad \forall \mathbf{y} \in \mathbb{R}^I \setminus \{0\}.$$

Nous choisissons donc $\alpha \in]0, \alpha_\star[$ tel que

$$\alpha_\star = 2 \inf_{\mathbf{y} \in \mathbb{R}^I \setminus \{0\}} \frac{(\mathbf{y}, \mathbf{y})_0}{(\mathbf{y}, \mathbf{y})_A}.$$

Ce quotient a pour valeur d'après l'exercice de la section 2.4.1

$$\alpha_\star = \frac{2}{\lambda_{\max}(A)}.$$

Nous choisissons donc

$$\alpha = \frac{\beta}{\lambda_{\max}(A)} \quad \text{avec } \beta \in]0, 2[.$$

Remarque 12. *Le plus souvent, on ne connaît pas la plus grande valeur propre de A et il suffit de prendre α suffisamment petit.*

8.3.2 Méthode du gradient à pas optimal

La méthode du gradient à pas optimal consiste à choisir α_n afin de minimiser

$$-\alpha_n (\nabla F(\mathbf{x}^{(n)}), \nabla F(\mathbf{x}^{(n)}))_0 + \frac{\alpha_n^2}{2} (\nabla F(\mathbf{x}^{(n)}), \nabla F(\mathbf{x}^{(n)}))_A$$

Il suit en dérivant le polynôme de degré 2

$$\alpha_n = \frac{(\nabla F(\mathbf{x}^{(n)}), \nabla F(\mathbf{x}^{(n)}))_0}{(\nabla F(\mathbf{x}^{(n)}), \nabla F(\mathbf{x}^{(n)}))_A}$$

où on peut supposer que $\nabla F(\mathbf{x}^{(n)}) \neq 0$ car sinon l'algorithme a convergé.

8.4 Convergence de la méthode du gradient

Nous rappelons que $\mathbf{x}_\star \in \mathbb{R}^I$ est la solution du système linéaire

$$A\mathbf{x}_\star = \mathbf{f}.$$

En pratique, il est important de comprendre que nous ne connaissons pas la valeur exacte de $\mathbf{x}_\star$. Les critères de convergence de la méthode de l'algorithme du gradient qui peuvent être utilisés en pratique ne doivent pas nécessiter la connaissance de $\mathbf{x}_\star$. Nous introduisons le résidu

$$\varepsilon^{(n)} := A\mathbf{x}^{(n)} - \mathbf{f}$$

Comme A est inversible, nous avons par continuité des opérateurs linéaires dans les espaces de dimension finie

$$\varepsilon^{(n)} \rightarrow 0 \implies \mathbf{x}^{(n)} - \mathbf{x}_\star = A^{-1}(A\mathbf{x}^{(n)} - \mathbf{f}) = A^{-1}\varepsilon^{(n)} \rightarrow 0$$

Cette identité fait ressortir l'importance de pouvoir comparer les différentes normes de $\mathbf{x}^{(n)} - \mathbf{x}_\star$ générées par A et A^{-1} .

Nous rappelons quelques définitions vues précédemment

Définition 10. Soit A une matrice symétrique définie positive :

(i) Pour tout $s \in \mathbb{R}$, nous notons A^s l'unique matrice symétrique définie positive définie par

$$A^s = P\Lambda^s P^*$$

à partir de la diagonalisation de A dans une base orthonormale

$$A = P\Lambda P^*$$

(ii) Nous notons $\|\cdot\|_A$ la norme définie par

$$\|\mathbf{x}\|_A = \|A\mathbf{x}\|_0$$

(iii) Nous notons $(\cdot, \cdot)_A$ le produit scalaire

$$(\mathbf{x}, \mathbf{y})_A = (A\mathbf{x}, \mathbf{y})_0$$

Remarque 13. La définition précédente doit être complétée par les remarques suivantes

- Si $s \in \mathbb{N}$, la définition de A^s coïncide avec la notation classique.
- Pour tout couple de nombres réels s_1 et s_2 , nous avons la propriété suivante :

$$A^{s_1+s_2} = A^{s_1} A^{s_2}.$$

- La norme induite par le produit scalaire $(\cdot, \cdot)_A$ est $\|\cdot\|_{A^{\frac{1}{2}}}$
- Nous avons pour tout $s > 0$

$$\lambda_{\max}(A^s) = (\lambda_{\max}(A))^s \text{ et } \lambda_{\min}(A^s) = (\lambda_{\min}(A))^s$$

et pour tout $s < 0$

$$\lambda_{\max}(A^s) = (\lambda_{\min}(A))^s \text{ et } \lambda_{\min}(A^s) = (\lambda_{\max}(A))^s$$

Nous avons la proposition suivante

Proposition 21. Nous avons pour tout $\mathbf{x} \in \mathbb{R}^I$

$$\lambda_{\min}(A)\|\mathbf{x}\|_0 \leq \|\mathbf{x}\|_A \leq \lambda_{\max}(A)\|\mathbf{x}\|_0$$

Preuve. On se référera à l'exercice de la section 2.4.1.

8.4.1 Preuve de convergence

L'idée pour démontrer un théorème de convergence consiste à identifier le début d'une norme au carré dans l'expression de F

$$F(\mathbf{x}) + \frac{1}{2}(A^{-1}\mathbf{f}, \mathbf{f})_0 = \frac{1}{2}(A\mathbf{x}, \mathbf{x})_0 - (\mathbf{f}, \mathbf{x})_0 + \frac{1}{2}(A^{-1}\mathbf{f}, \mathbf{f})_0 = \frac{1}{2}(A\mathbf{x}, A\mathbf{x})_{A^{-1}} - (\mathbf{f}, A\mathbf{x})_{A^{-1}} + \frac{1}{2}(\mathbf{f}, \mathbf{f})_{A^{-1}}.$$

On déduit donc que

$$F(\mathbf{x}) + \frac{1}{2}(A^{-1}\mathbf{f}, \mathbf{f})_0 = \frac{1}{2}(A\mathbf{x} - \mathbf{f}, A\mathbf{x} - \mathbf{f})_{A^{-1}} \text{ avec } (\mathbf{x}, \mathbf{y})_{A^{-1}} = (A^{-1}\mathbf{x}, \mathbf{y})_0$$

Comme $\varepsilon^{(n)} = A\mathbf{x}^{(n)} - \mathbf{f}$, nous déduisons de l'équation (8.1) que

$$(\varepsilon^{(n+1)}, \varepsilon^{(n+1)})_{A^{-1}} = (\varepsilon^{(n)}, \varepsilon^{(n)})_{A^{-1}} - 2\alpha_n(\varepsilon^{(n)}, \varepsilon^{(n)})_0 + \alpha_n^2(\varepsilon^{(n)}, \varepsilon^{(n)})_A$$

En introduisant les normes induites par ces produits scalaires, nous avons

$$\|\varepsilon^{(n+1)}\|_{A^{-\frac{1}{2}}}^2 = \|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2 - 2\alpha_n\|\varepsilon^{(n)}\|_0^2 + \alpha_n^2\|\varepsilon^{(n)}\|_{A^{\frac{1}{2}}}^2$$

Comme $\|\varepsilon^{(n)}\|_{A^{\frac{1}{2}}}^2 \leq \lambda_{\max}(A)\|\varepsilon^{(n)}\|_0^2$, nous avons

$$\|\varepsilon^{(n+1)}\|_{A^{-\frac{1}{2}}}^2 \leq \|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2 + (\lambda_{\max}(A)\alpha_n^2 - 2\alpha_n)\|\varepsilon^{(n)}\|_0^2.$$

Pour $\alpha_n \in]0, \frac{2}{\lambda_{\max}(A)}[$, nous avons

$$(\lambda_{\max}(A)\alpha_n^2 - 2\alpha_n) < 0$$

Il suit de l'inégalité $\|\varepsilon^{(n)}\|_0^2 \geq \lambda_{\min}(A)\|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2$ que

$$\|\varepsilon^{(n+1)}\|_{A^{-\frac{1}{2}}}^2 \leq \|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2 + \lambda_{\min}(A)(\lambda_{\max}(A)\alpha_n^2 - 2\alpha_n)\|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2.$$

Nous concluons donc que

$$\|\varepsilon^{(n+1)}\|_{A^{-\frac{1}{2}}}^2 \leq \left(1 - 2\lambda_{\min}(A)\alpha_n + \lambda_{\min}(A)\lambda_{\max}(A)\alpha_n^2\right)\|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2. \quad (8.2)$$

8.4.2 Cas particulier du gradient à pas fixe

Nous rappelons que nous choisissons $\alpha_n \in \mathbb{R}^+$ de la forme

$$\alpha_n = \alpha = \frac{\beta}{\lambda_{\max}(A)} \text{ avec } \beta \in]0, 2[$$

Il suit de (8.2) que

$$\|\varepsilon^{(n+1)}\|_{A^{-\frac{1}{2}}}^2 \leq \left(1 - \gamma \frac{\lambda_{\min}(A)}{\lambda_{\max}(A)}\right)\|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2 \quad \text{avec } \gamma = 2\beta - \beta^2 \in]0, 1].$$

Un cas intéressant consiste à prendre $\beta = 1$. Nous avons dans ce cas $\gamma = 1$ et la convergence est géométrique avec pour raison $1 - \lambda_{\min}(A)/\lambda_{\max}(A)$

$$\|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2 \leq \left(1 - \frac{\lambda_{\min}(A)}{\lambda_{\max}(A)}\right)^n \|\mathbf{f}\|_{A^{-\frac{1}{2}}}^2.$$

Remarque 14. Nous remarquons que la vitesse de convergence de la méthode du gradient dépend du conditionnement de la matrice.

$$\kappa(A) = \|A\| \|A^{-1}\| = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)} \quad (8.3)$$

Il suit que

$$\|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2 \leq \left(1 - \frac{1}{\kappa(A)}\right)^n \|\mathbf{f}\|_{A^{-\frac{1}{2}}}^2 \iff \|\mathbf{x}^{(n)} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}}^2 \leq \left(1 - \frac{1}{\kappa(A)}\right)^n \|\mathbf{x}_\star\|_{A^{\frac{1}{2}}}^2.$$

En effet, nous avons

$$\|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2 = \|A^{-\frac{1}{2}}\varepsilon^{(n)}\|_0^2 = (A^{-\frac{1}{2}}\varepsilon^{(n)}, A^{-\frac{1}{2}}\varepsilon^{(n)})_0 = (A^{\frac{1}{2}}A^{-1}\varepsilon^{(n)}, A^{\frac{1}{2}}A^{-1}\varepsilon^{(n)})_0 = \|A^{-1}\varepsilon^{(n)}\|_{A^{\frac{1}{2}}}^2$$

Comme $\varepsilon^{(n)} = A\mathbf{x}^{(n)} - \mathbf{f}$

$$\|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2 = \|\mathbf{x}^{(n)} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}}^2.$$

De même

$$\|\mathbf{f}\|_{A^{-\frac{1}{2}}}^2 = \|\mathbf{x}_\star\|_{A^{\frac{1}{2}}}^2.$$

8.4.3 Cas particulier du gradient à pas optimal

Comme $\varepsilon^{(n)} = A\mathbf{x}^{(n)} - \mathbf{f}$, nous déduisons de l'équation (8.1) que

$$(\varepsilon^{(n+1)}, \varepsilon^{(n+1)})_{A^{-1}} = (\varepsilon^{(n)}, \varepsilon^{(n)})_{A^{-1}} - 2\alpha_n(\varepsilon^{(n)}, \varepsilon^{(n)})_0 + \alpha_n^2(\varepsilon^{(n)}, \varepsilon^{(n)})_A$$

Nous rappelons que le pas a été choisi de la manière suivante

$$\alpha_n = \frac{(\varepsilon^{(n)}, \varepsilon^{(n)})_0}{(\varepsilon^{(n)}, \varepsilon^{(n)})_A}$$

Nous avons ainsi

$$(\varepsilon^{(n+1)}, \varepsilon^{(n+1)})_{A^{-1}} = \left(1 - \frac{(\varepsilon^{(n)}, \varepsilon^{(n)})_0^2}{(\varepsilon^{(n)}, \varepsilon^{(n)})_A(\varepsilon^{(n)}, \varepsilon^{(n)})_{A^{-1}}}\right) (\varepsilon^{(n)}, \varepsilon^{(n)})_{A^{-1}}.$$

On a dans ce cas sans avoir à calculer la plus grande valeur propre de A aussi l'estimation

$$\|\varepsilon^{(n)}\|_{A^{-\frac{1}{2}}}^2 \leq \left(1 - \frac{\lambda_{\min}(A)}{\lambda_{\max}(A)}\right)^n \|\mathbf{f}\|_{A^{-\frac{1}{2}}}^2 \iff \|\mathbf{x}^{(n)} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}}^2 \leq \left(1 - \frac{\lambda_{\min}(A)}{\lambda_{\max}(A)}\right)^n \|\mathbf{x}_\star\|_{A^{\frac{1}{2}}}^2$$

car pour tout $\mathbf{y} \in \mathbb{R}^I \setminus \{0\}$, nous avons

$$\lambda_{\min}(A) \leq \frac{(\mathbf{y}, \mathbf{y})_A}{(\mathbf{y}, \mathbf{y})_0} \leq \lambda_{\max}(A) \quad \text{et} \quad \frac{1}{\lambda_{\max}(A)} \leq \frac{(\mathbf{y}, \mathbf{y})_{A^{-1}}}{(\mathbf{y}, \mathbf{y})_0} \leq \frac{1}{\lambda_{\min}(A)}.$$

8.5 Exercices sur la méthode du gradient

8.5.1 Majoration de l'erreur

Soit $A \in \mathbb{R}^{I \times I}$ une matrice symétrique définie positive, $\mathbf{f} \in \mathbb{R}^I$ et $\mathbf{x}_\star$ la solution du problème

$$A\mathbf{x}_\star = \mathbf{f}$$

1. Évaluer $\|\mathbf{f}\|_{A^{-\frac{1}{2}}}^2$ en fonction de $\mathbf{x}_\star$ et $\mathbf{f}$.
2. Majorer $\|\mathbf{f}\|_{A^{-\frac{1}{2}}}^2$ par $\|\mathbf{f}\|_0^2$.
3. Majorer $\|\mathbf{x} - \mathbf{x}_\star\|_0^2$ par $\|A\mathbf{x} - \mathbf{f}\|_{A^{-\frac{1}{2}}}^2$.

8.5.2 Calcul de gradients et de hessienne

Soit

$$\mathbf{f} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad A = \begin{bmatrix} 1 & 0 & 3 \\ 2 & 1 & 0 \\ 3 & 2 & 4 \end{bmatrix} \quad \text{et} \quad F(\mathbf{x}) = \frac{1}{2}(A\mathbf{x}, \mathbf{x})_0 - (\mathbf{f}, \mathbf{x})_0.$$

1. Calculer le gradient et la hessienne de F .
2. La fonction F est-elle convexe ?

Chapitre 9

Interpolation de Tchebychev

Pour approfondir les notions de ce chapitre, on pourra consulter [10, 12].

9.1 L'interpolation polynomiale

L'interpolation d'une fonction $f \in C^0([a, b])$ consiste à approcher cette fonction par l'unique polynôme $\tau_N f$ de degré au plus $N - 1$ qui reproduit les valeurs de la fonction f en N noeuds d'interpolation $x_n \in [a, b]$ deux à deux distincts

$$\tau_N f(x_n) = f(x_n) \text{ pour tout } 1 \leq n \leq N.$$

On leur associe N polynômes de degré $N - 1$ qui vérifient

$$q_n(x_k) = \delta_{n,k}$$

Ceux-ci sont définis en assurant que x_k est racine de ce polynôme pour $k \neq n$

$$q_n(x) = \alpha_n \prod_{k=1, k \neq n}^N (x - x_k)$$

Le coefficient α_n est déterminé en assurant que $q_n(x_n) = 1$

$$q_n(x) = \frac{\prod_{k=1, k \neq n}^N (x - x_k)}{\prod_{k=1, k \neq n}^N (x_n - x_k)}.$$

On explicite alors l'opérateur d'interpolation $\tau_N f : \mathbb{R} \rightarrow \mathbb{R}$ d'une fonction $f \in C^0([a, b])$ en combinant les polynômes d'interpolation

$$\tau_N f(x) = \sum_{n=1}^N f(x_n) q_n(x)$$

Nous avons alors le théorème suivant

Théorème 5. *Si $f \in C^N([a, b])$, nous avons alors l'estimation suivante*

$$\|\tau_N f - f\|_\infty \leq \|f^{(N)}\|_\infty \frac{\|\Pi_N\|_\infty}{N!}$$

avec

$$\|u\|_\infty = \sup_{x \in [a, b]} |u(x)|, \quad \Pi_N(x) = \prod_{n=1}^N (x - x_n).$$

Preuve. Soit x un point distinct des noeuds d'interpolation

$$g_x(t) = \Pi_N(x) \left(f(t) - \tau_N f(t) \right) - \Pi_N(t) \left(f(x) - \tau_N f(x) \right)$$

Nous remarquons que la fonction g_x vérifie

$$g_x(x) = 0 \text{ et } g_x(x_n) = 0 \text{ pour } 1 \leq n \leq N.$$

La fonction g_x admet $N + 1$ racines. D'après le théorème de Rolle, il existe donc un point $\eta \in [a, b]$ tel que

$$g_x^{(N)}(\eta) = 0$$

Nous avons donc

$$\Pi_N(x) \left(f^{(N)}(\eta) - (\tau_N f)^{(N)}(\eta) \right) - \Pi_N^{(N)}(\eta) \left(f(x) - \tau_N f(x) \right) = 0$$

Comme $(\tau_N f)^{(N)}(t) = 0$ et $\Pi_N^{(N)}(t) = N!$, nous avons

$$f(x) - \tau_N f(x) = \frac{f^{(N)}(\eta)}{N!} \Pi_N(x).$$

On passe à la valeur absolue et on obtient le résultat souhaité.

9.2 Le polynôme de Tchebychev

On introduit le polynôme de Tchebychev défini sur $[-1, 1]$ par la formule

$$p_N^T(z) = \cos(N \arccos(z)) = \cos(Ny) \text{ avec } y = \arccos(z).$$

Proposition 22. La fonction p_N^T est un polynôme de degré N et pour $N \geq 1$

$$p_N^T(z) = 2^{N-1} z^N + r_N(z)$$

avec r_N un polynôme de degré $N - 1$.

Preuve. On agit par récurrence. On a $p_0^T \equiv 1$. Supposons que p_n^T est un polynôme de degré n pour tout $n \leq N - 1$.

$$z^N = \left(\frac{\exp(iy) + \exp(-iy)}{2} \right)^N \text{ avec } y = \arccos(z)$$

Il suit de la formule du binôme de Newton que

$$z^N = \frac{1}{2^N} \left[\sum_{n=0}^N C_N^n \exp(iny) \exp(-i(N-n)y) \right] = \frac{1}{2^N} \left[\sum_{n=0}^N C_N^n \exp(i(2n-N)y) \right]$$

En sens inverse, nous avons aussi

$$z^N = \frac{1}{2^N} \left[\sum_{n=0}^N C_N^{N-n} \exp(i(N-2n)y) \right]$$

En sommant les deux expressions et en tenant compte du fait que $C_N^{N-n} = C_N^n$

$$z^N = \frac{1}{2^N} \left[\sum_{n=0}^N C_N^n \frac{\exp(i(N-2n)y) + \exp(-i(N-2n)y)}{2} \right]$$

Il suit donc que

$$z^N = \frac{1}{2^N} \left[\sum_{n=0}^N C_N^n \cos((N-2n)y) \right] = \frac{1}{2^N} \sum_{n=0}^N C_N^n p_{|N-2n|}^T(z)$$

Nous avons ainsi

$$2^N z^N = p_N^T(z) + \left(\sum_{n=1}^{N-1} C_N^n p_{|N-2n|}^T(z) \right) + p_N^T(z)$$

Il suit

$$p_N^T(z) = 2^{N-1} z^N - \frac{1}{2} \sum_{n=1}^{N-1} C_N^n p_{|N-2n|}^T(z).$$

Ceci conclut la preuve car la somme est un polynôme de degré $N-2$.

Proposition 23. (i) Le polynôme p_N^T est pair si N est pair et impair si N est impair.

(ii) Pour $N \geq 1$, le polynôme p_N^T admet N racines simples entre -1 et 1 réparties de manière symétrique autour de zéro.

$$z_n^T = \cos\left(\frac{n\pi}{N} - \frac{\pi}{2N}\right) \text{ pour } 1 \leq n \leq N$$

Preuve. (i) Nous avons

$$p_N^T(-z) = \cos(N \arccos(-z)) = \cos(N(\pi - \arccos(z))) = (-1)^N \cos(N \arccos(z)) = (-1)^N p_N^T(z).$$

(ii) La fonction p_N^T s'annule ssi

$$N \arccos(z) = \frac{\pi}{2} \text{ modulo } \pi.$$

La fonction $z \mapsto N \arccos(z)$ étant une fonction strictement décroissante de $N\pi$ à 0 , p_N^T admet N zéros z_n^T

$$z_n^T = \cos\left(\frac{n\pi}{N} - \frac{\pi}{2N}\right) \text{ avec } 1 \leq n \leq N.$$

Corollaire 1. (i) Le polynôme de Tchebychev s'écrit sous la forme

$$p_N^T(z) = 2^{N-1} \prod_{n=1}^N (z - z_n^T)$$

(ii) Pour tout $z \in [-1, 1]$, nous avons

$$|p_N^T(z)| \leq 1$$

(iii) Pour tout $z \in \mathbb{R}$ tel que $|z| \geq 1$, nous avons

$$2^{N-1} (z^2 - 1)^{\frac{N}{2}} \leq |p_N^T(z)| \leq 2^{N-1} |z|^N$$

Preuve. (i) déjà obtenu.

(ii) Sur $[-1, 1]$, nous avons $p_N^T(z) = \cos(N \arccos(z))$.

(iii) Rappelons que les polynômes dont toutes les racines sont réelles sont monotones pour x plus grand que leur plus grande racine. Par conséquent, la fonction p_N^T est strictement croissante sur $[1, +\infty[$

$$p_N^T(z) \geq p_N^T(1) = 1 \geq 0$$

On a donc

$$p_N^T(z) = \sqrt{p_N^T(z) p_N^T(z)} = 2^{N-1} \sqrt{\prod_{n=1}^N (z - z_n^T) \prod_{n=1}^N (z - z_{N+1-n}^T)} = 2^{N-1} \sqrt{\prod_{n=1}^N (z - z_n^T)(z - z_{N+1-n}^T)}$$

Comme les racines sont symétriques, nous avons $z_{N+1-n}^T = -z_n^T \in [-1, 1]$

$$(z - z_n^T)(z - z_{N+1-n}^T) = (z - z_n^T)(z + z_n^T) = z^2 - (z_n^T)^2 \in [z^2 - 1, z^2].$$

Nous venons d'obtenir que

$$2^{N-1} \left(\sqrt{z^2 - 1} \right)^N \leq p_N^T(z) \leq 2^{N-1} \left(\sqrt{z^2} \right)^N$$

Le résultat sur $]-\infty, -1[$ s'obtient par symétrie.

9.3 Interpolation de Tchebychev

On se place sur le segment $[a, b]$. Les points d'interpolation de Tchebychev sont reliés par une transformation affine aux racines du polynôme de Tchebychev

$$x_n^T = \frac{a+b}{2} + \frac{b-a}{2} z_n^T \quad \text{avec} \quad z_n^T = \cos\left(\frac{n\pi}{N} - \frac{\pi}{2N}\right) \quad \text{avec } 1 \leq n \leq N.$$

On note τ_N^T l'opérateur d'interpolation aux points de Tchebychev x_n^T .

Théorème 6. Pour tout $f \in C^N([a, b])$, nous avons

$$\max_{x \in [a, b]} |\tau_N^T f(x) - f(x)| \leq \left(\frac{b-a}{2}\right)^N \frac{1}{2^{N-1}} \frac{\|f^{(N)}\|_\infty}{N!}$$

avec

$$\|u\|_\infty = \sup_{x \in [a, b]} |u(x)|, \quad \Pi_N^T(x) = \prod_{k=1}^N (x - x_k^T),$$

Preuve. D'après le théorème 5, nous avons

$$|\tau_N f(x) - f(x)| \leq \frac{\|f^{(N)}\|_\infty}{N!} \|\Pi_N\|_\infty$$

Nous remarquons que

$$\Pi_N^T(x) = \prod_{n=1}^N (x - x_n^T) = \prod_{n=1}^N \left(\frac{a+b}{2} + \frac{b-a}{2} z - x_n^T\right) = \prod_{n=1}^N \left(\frac{b-a}{2} z - \frac{b-a}{2} z_n^T\right) = \left(\frac{b-a}{2}\right)^N \prod_{n=1}^N (z - z_n^T).$$

où $x \in [a, b]$ et $z \in [-1, 1]$ sont reliés par la relation $x = \frac{a+b}{2} + \frac{b-a}{2} z$. Il suit de (i) du corollaire 1 que

$$\Pi_N^T(x) = \left(\frac{b-a}{2}\right)^N \frac{p_N^T(z)}{2^{N-1}}.$$

Nous avons grâce au (ii) du corollaire 1 que $|p_N^T(z)| \leq 1$. Il suit que

$$|\Pi_N^T(x)| \leq \left(\frac{b-a}{2}\right)^N \frac{1}{2^{N-1}}.$$

Chapitre 10

Méthode du gradient conjugué

La méthode du gradient conjugué a été introduite par Hestenes et Stiefel [7]. Pour approfondir les notions de ce chapitre, on pourra consulter [2, 6, 11].

10.1 Rappel sur les matrices symétriques

Soit $A \in \mathbb{R}^{I \times I}$ une matrice symétrique définie positive. Nous rappelons que A est diagonalisable dans une base orthonormale de vecteurs propres

$$A = P\Lambda P^T \text{ avec } P \in \mathbb{R}^{I \times I} \text{ unitaire et } \Lambda \in \mathbb{R}^{I \times I} \text{ diagonale.}$$

Toutes ses valeurs propres $(\lambda_i)_{1 \leq i \leq I}$ sont des nombres réels strictement positifs. Elles peuvent être classées par ordre croissant sans répétition

$$(\lambda^{(j)})_{1 \leq j \leq J} \text{ avec } J \leq I.$$

La matrice A a pour polynôme annulateur minimal

$$q(t) = \prod_{j=1}^J (t - \lambda^{(j)}) = t^J + q_{J-1} t^{J-1} + \dots + q_1 t + q_0 \quad \text{avec } q_0 \neq 0.$$

Comme $q(A) = 0$, l'inverse de la matrice A est donné par

$$A^{-1} = -\frac{A^{J-1} + q_{J-1} A^{J-2} + \dots + q_2 A + q_1 Id}{q_0}$$

L'inverse de A est donc un polynôme de A .

Dans toute la suite nous ordonnons les valeurs propres par ordre croissant

$$0 < \lambda_{min} = \lambda^{(1)} < \lambda^{(2)} < \dots < \lambda^{(J-1)} < \lambda^{(J)} = \lambda_{max}.$$

$$0 < \lambda_{min} = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_{I-1} \leq \lambda_I = \lambda_{max}.$$

À tout $\mathbf{x} \in \mathbb{R}^I$, on associe $\mathbf{y} = P^T \mathbf{x} \in \mathbb{R}^I$. Nous avons les identités suivantes

$$\|\mathbf{x}\|^2 = \|\mathbf{y}\|^2, \quad (A\mathbf{x}, \mathbf{x})_0 = \sum_{i=1}^I \lambda_i |y_i|^2, \quad \|A\mathbf{x}\|^2 = \sum_{i=1}^I \lambda_i^2 |y_i|^2$$

et les inégalités suivantes

$$\lambda_{min} \|\mathbf{x}\|^2 \leq (A\mathbf{x}, \mathbf{x})_0 \leq \lambda_{max} \|\mathbf{x}\|^2 \quad \text{et} \quad \lambda_{min} \|\mathbf{x}\| \leq \|A\mathbf{x}\| \leq \lambda_{max} \|\mathbf{x}\|$$

Rappelons les notations classiques :

$$(\mathbf{y}, \mathbf{z})_A = (A\mathbf{y}, \mathbf{z})_0 \quad \text{et} \quad \|\mathbf{y}\|_{A^{\frac{1}{2}}} = \sqrt{(A\mathbf{y}, \mathbf{y})_0}.$$

10.2 Les espaces de Krylov et la méthode du gradient conjugué

On cherche à résoudre le système linéaire :

Étant donné $\mathbf{f} \in \mathbb{R}^I$, chercher $\mathbf{x}_\star \in \mathbb{R}^I$ qui vérifie

$$A\mathbf{x}_\star = \mathbf{f}$$

La méthode du gradient conjugué est une méthode itérative qui résout à chaque itération ce problème en minimisant la fonction

$$J_{\mathbf{f}} : \mathbb{R}^I \longrightarrow \mathbb{R}, \quad J_{\mathbf{f}}(\mathbf{x}) = (A\mathbf{x} - \mathbf{f}, A\mathbf{x} - \mathbf{f})_{A^{-1}}$$

sur l'espace de Krylov $K_n(A, \mathbf{f})$ qui est l'espace engendré par les puissances de A appliquées à $\mathbf{f}$.

$$K_n(A, \mathbf{f}) := \left\{ \mathbf{x} \in \mathbb{R}^I \text{ tel que } \mathbf{x} = \gamma_1 \mathbf{f} + \gamma_2 A\mathbf{f} + \cdots + \gamma_n A^{n-1} \mathbf{f} \text{ avec } \gamma = (\gamma_1, \dots, \gamma_n) \in \mathbb{R}^n \right\}.$$

Cette méthode consiste en réalité à calculer la distance entre $\mathbf{x}$ et $\mathbf{x}_\star$. En effet, nous avons

$$J_{\mathbf{f}}(\mathbf{x}) = (\mathbf{x} - \mathbf{x}_\star, \mathbf{x} - \mathbf{x}_\star)_A = \|\mathbf{x} - \mathbf{x}_\star\|_{A^{-1}}^2$$

Définition 11. On définit la suite $(\mathbf{x}^{(n)})_{n \in \mathbb{N}^*}$ de vecteurs de $\mathbb{R}^I$ comme la suite qui vérifie

$$\mathbf{x}^{(n)} \in K_n(A, \mathbf{f}) \quad \text{et} \quad J_{\mathbf{f}}(\mathbf{x}^{(n)}) \leq J_{\mathbf{f}}(\mathbf{x}) \quad \text{pour tout } \mathbf{x} \in K_n(A, \mathbf{f}).$$

Remarque 15. Nous remarquons que ce problème de minimisation admet une unique solution. En effet, le vecteur $\mathbf{x}^{(n)}$ est la projection orthogonale pour le produit scalaire $(\cdot, \cdot)_A$ de $\mathbf{x}_\star$ sur l'espace vectoriel $K_n(A, \mathbf{f})$. On peut d'autre part facilement calculer sa valeur à l'aide d'une base orthonormale pour $(\cdot, \cdot)_A$ ($\mathbf{w}^{(1)}, \mathbf{w}^{(2)}, \dots, \mathbf{w}^{(n)}$) de $K_n(A, \mathbf{f})$

$$\mathbf{x}^{(n)} = \sum_{\ell=1}^n (\mathbf{x}_\star, \mathbf{w}^{(\ell)})_A \mathbf{w}^{(\ell)} = \sum_{\ell=1}^n (A\mathbf{x}_\star, \mathbf{w}^{(\ell)})_0 \mathbf{w}^{(\ell)} = \sum_{\ell=1}^n (\mathbf{f}, \mathbf{w}^{(\ell)})_0 \mathbf{w}^{(\ell)}.$$

Il ne nous reste donc plus qu'à déterminer une base orthonormale de $K_n(A, \mathbf{f})$

Théorème 7. Pour $J = \text{card}(\text{Spectre}(A))$, nous avons

$$A\mathbf{x}^{(J)} = \mathbf{f} \quad \text{et} \quad \mathbf{x}^{(J)} = \mathbf{x}_\star.$$

Remarque 16. Ce théorème peut être interprété de la manière suivante. L'algorithme converge en J itérations.

Preuve. Nous remarquons que A^{-1} est un polynôme en A de degré $J-1$. Ainsi, nous avons $A^{-1}\mathbf{f} \in K_J(A, \mathbf{f})$. D'autre part,

$$J_{\mathbf{f}}(A^{-1}\mathbf{f}) = \|AA^{-1}\mathbf{f} - \mathbf{f}\|_{A^{-1}}^2 = 0 \leq \|A\mathbf{x} - \mathbf{f}\|_{A^{-1}}^2 \quad \text{pour tout } \mathbf{x} \in \mathbb{R}^I.$$

Nous avons donc $\mathbf{x}^{(J)} = A^{-1}\mathbf{f} = \mathbf{x}_\star$.

10.3 Équation d'optimalité

Proposition 24. Pour tout $\mathbf{y} \in K_n(A, \mathbf{f})$, nous avons

$$(A\mathbf{x}^{(n)} - \mathbf{f}, \mathbf{y})_0 = 0.$$

Par définition de l'itéré $\mathbf{x}^{(n)}$, nous avons

$$\mathbf{x}^{(n)} \in K_n(A, \mathbf{f}) \text{ et } J_{\mathbf{f}}(\mathbf{x}^{(n)}) \leq J_{\mathbf{f}}(\mathbf{x}) \quad \forall \mathbf{x} \in K_n(A, \mathbf{f})$$

Soit $\mathbf{y} \in K_n(A, \mathbf{f})$, il suit pour $\mathbf{x} = \mathbf{x}^{(n)} + t\mathbf{y}$ avec $t \in \mathbb{R}$

$$(\mathbf{x}^{(n)} - \mathbf{x}_\star, \mathbf{x}^{(n)} - \mathbf{x}_\star)_A = J_{\mathbf{f}}(\mathbf{x}^{(n)}) \leq J_{\mathbf{f}}(\mathbf{x}) = (\mathbf{x}^{(n)} + t\mathbf{y} - \mathbf{x}_\star, \mathbf{x}^{(n)} + t\mathbf{y} - \mathbf{x}_\star)_A$$

Nous développons et simplifions

$$0 \leq 2t(\mathbf{x}^{(n)} - \mathbf{x}_*, \mathbf{y})_A + t^2 (\mathbf{y}, \mathbf{y})_A$$

La fonction $g(t) = 2t(\mathbf{x}^{(n)} - \mathbf{x}_*, \mathbf{y})_A + t^2 (\mathbf{y}, \mathbf{y})_A$ vérifie $g(0) = 0$. Il est nécessaire que $g'(0) = 0$ afin qu'elle ne change pas de signe. Ainsi, nous avons

$$(\mathbf{x}^{(n)} - \mathbf{x}_*, \mathbf{y})_A = 0.$$

Il suit que

$$(A\mathbf{x}^{(n)} - \mathbf{f}, \mathbf{y})_0 = (A\mathbf{x}^{(n)} - A\mathbf{x}_*, \mathbf{y})_0 = (\mathbf{x}^{(n)} - \mathbf{x}_*, \mathbf{y})_A = 0.$$

Ceci termine la preuve.

Corollaire 2. *Les résidus sont deux à deux orthogonaux pour le produit scalaire euclidéen. Pour tout couple de nombres entiers strictement positifs $m \neq n$*

$$(A\mathbf{x}^{(n)} - \mathbf{f}, A\mathbf{x}^{(m)} - \mathbf{f})_0 = 0.$$

Preuve. Pour $n > m$, il suffit de remarquer que

$$A\mathbf{x}^{(m)} - \mathbf{f} \in K_{m+1}(A, \mathbf{f}) \subset K_n(A, \mathbf{f}).$$

Pour $m > n$, on agit par symétrie

$$(A\mathbf{x}^{(n)} - \mathbf{f}, A\mathbf{x}^{(m)} - \mathbf{f})_0 = (A\mathbf{x}^{(m)} - \mathbf{f}, A\mathbf{x}^{(n)} - \mathbf{f})_0 = 0.$$

10.4 L'algorithme du gradient conjugué

La programmation de l'algorithme classique passe par l'introduction des résidus qui valent au début de l'algorithme

$$\mathbf{r}^{(0)} = -\mathbf{f}$$

et avant la n -ème itération, pour $n \geq 1$,

$$\mathbf{r}^{(n)} = A\mathbf{x}^{(n-1)} - \mathbf{f}$$

Remarque 17. *Nous remarquons que si $\mathbf{r}^{(n)} = 0$ alors nous avons résolu le système linéaire.*

Il suit du corollaire 2 que $(\mathbf{r}^{(m)})_{0 \leq m \leq n}$ est une famille orthogonale de $K_{n+1}(A, \mathbf{f})$ pour le produit scalaire euclidéen. Dans le cas où $\mathbf{r}^{(n)} \neq 0$, il s'agit même d'une base orthogonale pour le produit scalaire euclidéen. Ce système n'est pas orthogonal pour le A produit scalaire. On définit $(\mathbf{p}^{(m)})_{0 \leq m \leq n}$ comme la base orthogonale pour le produit scalaire $(\cdot, \cdot)_A$ de $K_{n+1}(A, \mathbf{f})$

$$\mathbf{p}^{(0)} = \mathbf{r}^{(0)}$$

et pour $n \geq 1$

$$\mathbf{p}^{(n)} = \mathbf{r}^{(n)} - \sum_{k=0}^{n-1} \beta_k^{(n)} \mathbf{p}^{(k)} \quad \text{avec } \beta_k^{(n)} = \frac{(\mathbf{r}^{(n)}, \mathbf{p}^{(k)})_A}{(\mathbf{p}^{(k)}, \mathbf{p}^{(k)})_A}$$

On a $\mathbf{p}^{(0)} \in K_1(A, \mathbf{f})$ et pour $n \geq 1$

$$\mathbf{p}^{(n)} \in K_{n+1}(A, \mathbf{f}) \cap [K_n(A, \mathbf{f})]^\perp_A$$

Pour $k \leq n-2$, il suit de la condition d'optimalité comme $A\mathbf{p}^{(k)} \in K_n(A, \mathbf{f})$ que

$$(\mathbf{r}^{(n)}, \mathbf{p}^{(k)})_A = (\mathbf{r}^{(n)}, A\mathbf{p}^{(k)})_0 = 0$$

Ainsi, nous avons

$$\mathbf{p}^{(n)} = \mathbf{r}^{(n)} - \frac{(\mathbf{r}^{(n)}, A\mathbf{p}^{(n-1)})_0}{(A\mathbf{p}^{(n-1)}, \mathbf{p}^{(n-1)})_0} \mathbf{p}^{(n-1)}$$

Si $\mathbf{p}^{(n)} \neq 0$, nous avons

$$\mathbf{x}^{(n)} = \sum_{m=0}^n \alpha_m^{(n)} \mathbf{p}^{(m)}$$

Comme $\mathbf{x}^{(n)}$ est le projeté orthogonal de $\mathbf{x}_\star$ sur $K_{n+1}(A, \mathbf{f})$

$$\alpha_m^{(n)} = \frac{(\mathbf{x}_\star, \mathbf{p}^{(m)})_A}{(\mathbf{p}^{(m)}, \mathbf{p}^{(m)})_A} = \frac{(A\mathbf{x}_\star, \mathbf{p}^{(m)})_0}{(A\mathbf{p}^{(m)}, \mathbf{p}^{(m)})_0} = \frac{(\mathbf{f}, \mathbf{p}^{(m)})_0}{(A\mathbf{p}^{(m)}, \mathbf{p}^{(m)})_0}$$

Ainsi les coefficients $\alpha_m^{(n)}$ sont indépendants de n et sont tout simplement notés α_m . Nous avons donc

$$\mathbf{x}^{(n)} = \mathbf{x}^{(n-1)} + \alpha_n \mathbf{p}^{(n)} \quad \text{avec } \alpha_n = \frac{(\mathbf{f}, \mathbf{p}^{(n)})_0}{(A\mathbf{p}^{(n)}, \mathbf{p}^{(n)})_0}$$

On déduit que

$$A\mathbf{x}^{(n)} = A\mathbf{x}^{(n-1)} + \alpha_n A\mathbf{p}^{(n)} \implies \mathbf{r}^{(n+1)} = \mathbf{r}^{(n)} + \alpha_n A\mathbf{p}^{(n)}$$

Initialisation.

$$\mathbf{r}^{(0)} = -\mathbf{f}, \quad \mathbf{p}^{(0)} = \mathbf{r}^{(0)}, \quad \text{calcul de } A\mathbf{p}^{(0)}.$$

Calcul du premier itéré

$$\mathbf{x}^{(0)} = \alpha_0 \mathbf{p}^{(0)} \quad \text{avec } \alpha_0 = \frac{(\mathbf{f}, \mathbf{p}^{(0)})_0}{(A\mathbf{p}^{(0)}, \mathbf{p}^{(0)})_0}$$

Itération. Les calculs sont effectués dans cet ordre.

Mise à jour du résidu

$$\mathbf{r}^{(n)} = \mathbf{r}^{(n-1)} + \alpha_{n-1} A\mathbf{p}^{(n-1)}$$

Mise à jour de la direction conjuguée

$$\mathbf{p}^{(n)} = \mathbf{r}^{(n)} - \frac{(\mathbf{r}^{(n)}, A\mathbf{p}^{(n-1)})_0}{(A\mathbf{p}^{(n-1)}, \mathbf{p}^{(n-1)})_0} \mathbf{p}^{(n-1)}, \quad \text{Calcul de } A\mathbf{p}^{(n)}$$

Mise à jour de la solution

$$\mathbf{x}^{(n)} = \mathbf{x}^{(n-1)} + \alpha_n \mathbf{p}^{(n)} \quad \text{avec } \alpha_n = \frac{(\mathbf{f}, \mathbf{p}^{(n)})_0}{(A\mathbf{p}^{(n)}, \mathbf{p}^{(n)})_0}$$

10.5 Restart et convergence de la méthode du gradient conjugué

Nous venons de voir que l'algorithme du gradient conjugué converge en J itérations. Toutefois, on ne laisse que très rarement cet algorithme atteindre ce nombre d'itérations en pratique. En effet, J peut être très grand et on observe un problème de mémoire avec l'augmentation de la dimension de l'espace de Krylov. On préfère donc mettre en oeuvre une stratégie de restart en stoppant la dimension de l'espace de Krylov avant que les problèmes de mémoire n'apparaissent. Une seconde raison est liée au fait que la méthode du gradient conjugué a tendance à propager les erreurs d'arrondis lorsque J est très grand.

La méthode du restart consiste à limiter la dimension de l'espace de Krylov à N_{krylov} un nombre entier naturel petit et à relancer plusieurs fois l'algorithme du gradient conjugué.

Première itération extérieure. On calcule pour $1 \leq n \leq N_{krylov}$

$$\mathbf{x}^{(1,n)} \in K_n(A, \mathbf{f}) \quad \text{et} \quad J_{\mathbf{f}}(\mathbf{x}^{(1,n)}) \leq J_{\mathbf{f}}(\mathbf{y}) \quad \text{pour tout } \mathbf{y} \in K_n(A, \mathbf{f}).$$

On définit $\mathbf{x}^{(2,0)} := \mathbf{x}^{(1, N_{krylov})}$.

Deuxième itération extérieure. On calcule le résidu

$$\delta \mathbf{f}^{(2)} = \mathbf{f} - A\mathbf{x}^{(2,0)}$$

On calcule pour $1 \leq n \leq N_{krylov}$ les premières itérations du gradient conjugué associé à cette équation

$$\delta \mathbf{x}^{(2,n)} \in K_n(A, \delta \mathbf{f}^{(2)}) \quad \text{et} \quad J_{\delta \mathbf{f}^{(2)}}(\delta \mathbf{x}^{(2,n)}) \leq J_{\delta \mathbf{f}^{(2)}}(\mathbf{y}) \text{ pour tout } \mathbf{y} \in K_n(A, \delta \mathbf{f}^{(2)}).$$

avec

$$J_{\mathbf{g}}(\mathbf{x}) = (A\mathbf{x} - \mathbf{g}, A\mathbf{x} - \mathbf{g})_{A^{-1}}.$$

On définit $\mathbf{x}^{(3,0)} := \mathbf{x}^{(2,0)} + \delta \mathbf{x}^{(2, N_{krylov})}$.

Itération extérieure suivante. On calcule le résidu du système linéaire

$$\delta \mathbf{f}^{(m)} = \mathbf{f} - A\mathbf{x}^{(m,0)}$$

On calcule pour $1 \leq n \leq N_{krylov}$ les premières itérations du gradient conjugué

$$\delta \mathbf{x}^{(m,n)} \in K_n(A, \delta \mathbf{f}^{(m)}) \quad \text{et} \quad J_{\delta \mathbf{f}^{(m)}}(\delta \mathbf{x}^{(m,n)}) \leq J_{\delta \mathbf{f}^{(m)}}(\mathbf{y}) \text{ pour tout } \mathbf{y} \in K_n(A, \delta \mathbf{f}^{(m)}).$$

On définit $\mathbf{x}^{(m+1,0)} := \mathbf{x}^{(m,0)} + \delta \mathbf{x}^{(m, N_{krylov})}$.

Pour ces stratégies avec restart, il est intéressant d'avoir une idée de la vitesse de convergence par rapport aux itérations intérieures. Nous allons voir que celle-ci est directement reliée aux qualités spectrales de la matrice.

Remarque 18. On dit que m est le numéro de l'itération extérieure, tandis que n est le numéro de l'itération intérieure.

L'estimation de la vitesse de convergence est obtenue à l'aide de la théorie de convergence de la méthode du gradient à pas optimal.

Nous introduisons la suite définie par la méthode du gradient à pas fixe

$$\tilde{\mathbf{x}}^{(0)} = 0 \text{ et } \tilde{\mathbf{x}}^{(n+1)} = \tilde{\mathbf{x}}^{(n)} - \frac{1}{\lambda_{max}}(A\tilde{\mathbf{x}}^{(n)} - \mathbf{f})$$

Nous montrons par récurrence que $\tilde{\mathbf{x}}^{(n)} \in K_n(A, \mathbf{f})$ et converge car $\rho(Id - \frac{A}{\lambda_{max}}) < 1$ vers $\mathbf{x}_\star$ la solution du problème $A\mathbf{x}_\star = \mathbf{f}$. Comme $\mathbf{x}^{(n)}$ réalise le minimum de J sur $K_n(A, \mathbf{f})$, nous avons donc

$$\|\mathbf{x}^{(n)} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}} \leq \|\tilde{\mathbf{x}}^{(n)} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}}$$

Théorème 8. Pour tout nombre entier $n \geq 1$, nous avons

$$\|\mathbf{x}^{(n)} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}} \leq \left(1 - \frac{1}{\kappa_2(A)}\right)^{\frac{n}{2}} \|\mathbf{x}_\star\|_{A^{\frac{1}{2}}}.$$

Il existe dans la littérature des estimations plus précises du taux de convergence. Nous en verrons une lors d'un exercice. Ce point sera traité en exercice. On peut remarquer que la vitesse de convergence de l'algorithme est directement reliée au conditionnement de la matrice A .

10.6 Exemple d'implémentation du gradient conjugué

On peut trouver un exemple d'implémentation ici ([www](#))

```
import numpy as np
```

```
def conjugate_gradient(A, b, x0=None, tol=1e-6, max_iter=None):
    n = len(b)
```

```
    if x0 is None:
        x0 = np.zeros(n)
```

```

if max_iter is None:
    max_iter = 20

r = A@x0-b
x = x0.copy()
p=r.copy()
print('x',x)
r2=np.dot(r, r)
print('r2 a l iteration 0',r2)

for i in range(max_iter):
    Ap = A@p
    alpha = np.dot(b, p)/ np.dot(p, Ap)
    x = x + alpha * p
    rold=r.copy()
    r = r + alpha * Ap
    beta = np.dot(Ap, r) / np.dot(Ap,p)
    pold=p.copy()
    p = r - beta * p
    print('ortho p',np.dot(Ap,p))
    print('ortho r',np.dot(rold,r))
    r2=np.dot(r, r)
    print(f"r2 a l iteration {i}",r2)
    if np.sqrt(r2) < tol:
        print(f"Converged after {i} iterations")
        break
return x

# Exemple avec une matrice de taille 30x30
np.random.seed(0) # Pour la reproductibilité

# Génération d'une matrice symétrique définie positive
A = np.random.rand(30, 30)
A = 0.5 * (A + A.T) # Symétrisation
A = A + 30 * np.eye(30) # Ajout d'une constante diagonale pour rendre la matrice définie positive

b = np.random.rand(30) # Vecteur b aléatoire
x0 = np.zeros(30) # Solution initiale

# Résolution du système Ax = b
x_sol = conjugate_gradient(A, b, x0)

# Affichage des résultats
print("Solution trouvée :", x_sol)
print("Norme du residu :", np.linalg.norm(A @ x_sol - b))
#

```

10.7 Exercices

10.7.1 Exercice. Calcul de l'inverse d'une matrice

Soit A la matrice définie par

$$A = \begin{bmatrix} 5 & -2 & -4 \\ 4 & -1 & -4 \\ 4 & -2 & -3 \end{bmatrix}$$

1. Calculer, à l'aide de python, les valeurs propres de A et vecteurs propres de A .
2. Donner le polynôme annulateur minimal de A .
3. Calculer l'inverse de A .

10.7.2 Exercice. Approximation de l'inverse par un polynôme d'ordre 1

Soit A une matrice hermitienne. Nous notons λ_{min} et λ_{max} sa plus petite et plus grande valeur propre. Nous notons $\kappa_2 = \frac{\lambda_{max}}{\lambda_{min}}$ son conditionnement euclidéen. On cherche à résoudre

$$\text{Étant donné } \mathbf{f} \in \mathbb{R}^I \text{ chercher } \mathbf{x}_\star \in \mathbb{R}^I \text{ tel que } A\mathbf{x}_\star = \mathbf{f}.$$

On considère l'itéré $\mathbf{x}^{(n)}$ du gradient conjugué

$$\|\mathbf{x}^{(n)} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}}^2 = \min_{\mathbf{x} \in K_n(A, \mathbf{f})} \|\mathbf{x} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}}^2$$

À chaque itération, on définit le vecteur de $\mathbb{R}^I$

$$\mathbf{x}^{[n+1]} = \mathbf{x}^{(n)} + \frac{2}{\lambda_{min} + \lambda_{max}} (\mathbf{f} - A\mathbf{x}^{(n)}) \text{ avec } \mathbf{x}^{[0]} = 0.$$

1. Montrer que

$$\|\mathbf{x}^{(n+1)} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}} \leq \|\mathbf{x}^{[n+1]} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}}$$

2. Montrer pour $B = Id - \frac{2}{\lambda_{min} + \lambda_{max}} A$ que

$$Sp(B) \subset [-\rho_\star, \rho_\star] \text{ avec } \rho_\star = \frac{\lambda_{max} - \lambda_{min}}{\lambda_{max} + \lambda_{min}}$$

3. Montrer que $A^{\frac{1}{2}}B = BA^{\frac{1}{2}}$.

4. Montrer que

$$\|\mathbf{x}^{[n+1]} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}} \leq \frac{\lambda_{max} - \lambda_{min}}{\lambda_{max} + \lambda_{min}} \|\mathbf{x}^{(n)} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}}$$

5. Dédire que

$$\|\mathbf{x}^{(n)} - \mathbf{x}_\star\|_{A^{\frac{1}{2}}} \leq \left(\frac{\lambda_{max} - \lambda_{min}}{\lambda_{max} + \lambda_{min}} \right)^n \|\mathbf{x}_\star\|_{A^{\frac{1}{2}}}$$

10.7.3 Approximation de l'inverse d'une matrice par un polynôme matriciel

Soit A une matrice symétrique définie positive de valeur propre minimale λ_{min} et de valeur propre maximale λ_{max} .

On rappelle que le polynôme de Tchebychev est défini sur $[-1, 1]$

$$p_N(z) = \cos(N \arccos(z))$$

1. Montrer que p_N vérifie

$$p_N(z) = \sum_{0 \leq n \leq N/2} C_N^{2n} z^{N-2n} (z^2 - 1)^n$$

2. Expliquer pourquoi on peut le prolonger à tout $\mathbb{R}$.

3. Soit q_N le polynôme

$$q_N(\lambda) = p_N(z) \text{ avec } \lambda = \frac{\lambda_{max} + \lambda_{min}}{2} + \frac{\lambda_{max} - \lambda_{min}}{2} z$$

4. Montrer que $h_N : \mathbb{R} \longrightarrow \mathbb{R}$ est un polynôme avec

$$h_N(\lambda) = \frac{1}{\lambda} \left[1 - \frac{q_N(\lambda)}{q_N(0)} \right]$$

5. Montrer que

$$q_N(0) = p_N\left(-\frac{\kappa+1}{\kappa-1}\right) \text{ avec } \kappa = \frac{\lambda_{max}}{\lambda_{min}}.$$

6. Montrer que

$$\left| h_N(\lambda) - \frac{1}{\lambda} \right| \leq \frac{1}{\lambda} \frac{\max_{z \in [-1,1]} |p_N(z)|}{\left| p_N\left(-\frac{\kappa+1}{\kappa-1}\right) \right|}$$

7. Montrer que

$$\max_{z \in [-1,1]} |p_N(z)| \leq 1$$

8. Montrer que pour $z \leq -1$

$$|p_N(z)| \geq |z|^N$$

9. Montrer que

$$|q_N(0)| \geq \left(\frac{\kappa+1}{\kappa-1} \right)^N$$

10. Montrer que

$$\left| h_N(\lambda) - \frac{1}{\lambda} \right| \leq \frac{1}{\lambda} \left(\frac{\kappa-1}{\kappa+1} \right)^N$$

11. Montrer que pour $|z| \geq 1$

$$p_N(z) = \frac{\left(z + (z^2 - 1)^{\frac{1}{2}} \right)^N + \left(z - (z^2 - 1)^{\frac{1}{2}} \right)^N}{2}$$

12. Dédire que

$$\left| p_N\left(-\frac{\kappa+1}{\kappa-1}\right) \right| = \frac{\left(\kappa+1+2\sqrt{\kappa} \right)^N + \left(\kappa+1-2\sqrt{\kappa} \right)^N}{2(\kappa-1)^N}$$

13. Montrer que

$$\left| p_N\left(-\frac{\kappa+1}{\kappa-1}\right) \right| = \frac{1}{2} \left[\left(\frac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1} \right)^N + \left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1} \right)^N \right]$$

14. Dédire que

$$\left| h_N(\lambda) - \frac{1}{\lambda} \right| \leq \frac{1}{\lambda} \frac{2}{\left(\frac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1} \right)^N + \left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1} \right)^N}$$

15. Dédire de cette estimation que la solution $\mathbf{x}_n$ calculée par la méthode du gradient conjugué vérifie

$$\|\mathbf{x}_\star - \mathbf{x}_n\|_{A^{\frac{1}{2}}} \leq \frac{2}{\left(\frac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1} \right)^N + \left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1} \right)^N} \|\mathbf{x}_\star\|_{A^{\frac{1}{2}}}$$

Remarque 19. Cette estimation est en pratique beaucoup plus précise que celle obtenue dans les sections précédentes. On y voit clairement que la vitesse de convergence dépend du conditionnement de la matrice. Plus la matrice est bien conditionnée (κ proche de 1), plus la convergence est rapide. Il s'agit ici de l'estimation classique qui est souvent simplifiée en

$$\left| h_N(\lambda) - \frac{1}{\lambda} \right| \leq \frac{2}{\lambda} \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^N$$

qui est relativement précise lorsque le conditionnement κ est grand mais peu précise lorsque κ est proche de 1.

Ceci fournit alors l'estimation suivante pour l'algorithme du gradient conjugué. Soit $\mathbf{x}^{(n)}$ le n -ème itéré de la méthode du gradient conjugué

$$\mathbf{x}^{(n)} \in K_n(A, \mathbf{f}) \quad \|\mathbf{x}_\star - \mathbf{x}^{(n)}\|_{A^{\frac{1}{2}}} \leq \|\mathbf{x}_\star - \mathbf{x}\|_{A^{\frac{1}{2}}} \text{ pour tout } \mathbf{x} \in K_n(A, \mathbf{f})$$

Le polynôme h_n est de degré $n - 1$. Nous avons $h_n(A)\mathbf{f} \in K_n(A, \mathbf{f})$. Il suit que

$$\|\mathbf{x}_\star - \mathbf{x}^{(n)}\|_{A^{\frac{1}{2}}} \leq \|\mathbf{x}_\star - h_n(A)\mathbf{f}\|_{A^{\frac{1}{2}}} = \|A\mathbf{x}_\star - Ah_n(A)\mathbf{f}\|_{A^{-\frac{1}{2}}} = \|(Id - Ah_n(A))\mathbf{f}\|_{A^{-\frac{1}{2}}}.$$

Il suit par décomposition spectrale que

$$\|\mathbf{x}_\star - \mathbf{x}^{(n)}\|_{A^{\frac{1}{2}}} \leq \max_{[\lambda_{min}, \lambda_{max}]} |1 - \lambda h_n(\lambda)| \|\mathbf{f}\|_{A^{-\frac{1}{2}}}.$$

C'est-à-dire

$$\|\mathbf{x}_\star - \mathbf{x}^{(n)}\|_{A^{\frac{1}{2}}} \leq \frac{2}{\left(\frac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1}\right)^n + \left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^n} \|\mathbf{x}_\star\|_{A^{\frac{1}{2}}}.$$

Annexe A

Travaux Pratiques 1 : Mise en œuvre numérique de l'algorithme de Gram-Schmidt


Ce TP sera réalisé sous Google Colab afin de vous former à cet outil.

A.1 Utilisation de google colab

Votre première tâche consiste à vous rendre dans Google Colab


<https://colab.research.google.com/>

Vous créez alors un nouveau Notebook



Demander à l'IA générative de :

créer une matrice de taille 10 qui a pour coefficients
 $M(i,j)=1/(1+(i-j)^2)$



Ceci devrait vous générer un code qui ressemble au suivant

```
# prompt: créer une matrice de taille 10 qui a pour coefficients
# M(i,j)=1/(1+(i-j)^2)

import numpy as np

def create_matrix(n):
    matrix = np.zeros((n, n))
    for i in range(n):
        for j in range(n):
            matrix[i, j] = 1 / (1 + (i - j)**2)
    return matrix

# Créer une matrice de taille 10
matrix = create_matrix(10)
print(matrix)
```

Vérifier avec le plus grand soin le résultat obtenu. Vous devez obtenir ceci :

1	0.5	0.2	0.1	0.0588	0.0385	0.0270	0.02	0.0154	0.0122
0.5	1	0.5	0.2	0.1	0.0588	0.0385	0.0270	0.02	0.0154
0.2	0.5	1	0.5	0.2	0.1	0.0588	0.0385	0.0270	0.02
0.1	0.2	0.5	1	0.5	0.2	0.1	0.0588	0.0385	0.0270
0.0588	0.1	0.2	0.5	1	0.5	0.2	0.1	0.0588	0.0385
0.0385	0.0588	0.1	0.2	0.5	1	0.5	0.2	0.1	0.0588
0.0270	0.0385	0.0588	0.1	0.2	0.5	1	0.5	0.2	0.1
0.02	0.0270	0.0385	0.0588	0.1	0.2	0.5	1	0.5	0.2
0.0154	0.02	0.0270	0.0385	0.0588	0.1	0.2	0.5	1	0.5
0.0122	0.0154	0.02	0.0270	0.0385	0.0588	0.1	0.2	0.5	1

Nous allons par la suite travailler avec cette matrice.

A.2 Factorisation QR d'une matrice

La décomposition QR d'une matrice M , dont nous notons $\mathbf{v}_i$ la i -ème colonne

$$M = [\mathbf{v}_0, \mathbf{v}_1, \dots, \mathbf{v}_{I-1}].$$

consiste à factoriser M sous la forme d'un produit de deux matrices :

$$M = QR$$

avec

— Q est une matrice réelle, dont les colonnes forment un système de vecteurs orthonormés.

$$Q = [\mathbf{q}_0, \mathbf{q}_1, \dots, \mathbf{q}_{I-1}] \text{ avec } \mathbf{q}_i \in \mathbb{R}^I \text{ et } \mathbf{q}_i^T \mathbf{q}_j = \delta_{i,j}.$$

— R est une matrice triangulaire supérieure dont les coefficients diagonaux sont positifs

$$R_{i,j} = 0 \text{ si } i > j \quad \text{c'est-à-dire} \quad R = \begin{bmatrix} R_{00} & R_{01} & R_{02} & \cdots & R_{0,I-1} \\ 0 & R_{11} & R_{12} & \cdots & R_{1,I-1} \\ 0 & 0 & R_{22} & \cdots & R_{2,I-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & R_{I-1,I-1} \end{bmatrix}$$

A.3 L'algorithme de Gram-Schmidt

L'identité $M = QR$ signifie

$$\mathbf{v}_j = \sum_{i=0}^{I-1} \mathbf{q}_i R_{i,j} = \sum_{i=0}^j \mathbf{q}_i R_{i,j}$$

ou encore $Q = MR^{-1}$ avec R^{-1} une matrice triangulaire supérieure. En notant $\alpha_{i,j}$ les coefficients de R^{-1} , nous avons

$$\mathbf{q}_j = \sum_{i=0}^{I-1} \mathbf{v}_i \alpha_{i,j} = \sum_{i=0}^j \mathbf{v}_i \alpha_{i,j}$$

Ceci signifie que l'on combine les colonnes de M afin de construire une base orthonormale. Reprenons pour calculer R et Q les étapes de l'algorithme de Gram-Schmidt.

On détermine $R_{0,0} > 0$ en normalisant $\mathbf{v}_0$

$$\mathbf{v}_0 = R_{0,0} \mathbf{q}_0 \implies \|\mathbf{v}_0\| = |R_{0,0}| \|\mathbf{q}_0\| \xRightarrow{R_{0,0} > 0 \text{ et } \|\mathbf{q}_0\|=1} R_{0,0} = \|\mathbf{v}_0\|.$$

Nous avons donc aussi

$$\mathbf{q}_0 = \frac{\mathbf{v}_0}{R_{0,0}}$$

Pour $j \geq 1$, la détermination de $R_{i,j}$, pour $0 \leq i \leq j$, et $\mathbf{q}_j$ se fait par récurrence

$$\left\{ \begin{array}{l} \text{Pour } k < j, \quad \mathbf{v}_j = \sum_{i=0}^j \mathbf{q}_i R_{i,j} \implies \mathbf{q}_k^T \mathbf{v}_j = \sum_{i=0}^j \mathbf{q}_k^T \mathbf{q}_i R_{i,j} \xRightarrow{\mathbf{q}_k^T \mathbf{q}_i = \delta_{k,i}} R_{k,j} = \mathbf{q}_k^T \mathbf{v}_j \\ \mathbf{v}_j = \sum_{i=0}^j \mathbf{q}_i R_{i,j} \implies R_{j,j} \mathbf{q}_j = \mathbf{v}_j - \sum_{i=0}^{j-1} \mathbf{q}_i R_{i,j} \xRightarrow{R_{j,j} > 0 \text{ et } \|\mathbf{q}_j\|=1} R_{j,j} = \left\| \mathbf{v}_j - \sum_{i=0}^{j-1} \mathbf{q}_i R_{i,j} \right\| \\ R_{j,j} \mathbf{q}_j = \mathbf{v}_j - \sum_{i=0}^{j-1} \mathbf{q}_i R_{i,j} \implies \mathbf{q}_j = \frac{\mathbf{v}_j - \sum_{i=0}^{j-1} \mathbf{q}_i R_{i,j}}{R_{j,j}} \end{array} \right.$$

A.4 Mise en œuvre en python

Pour la matrice M de la section A.1, programmer en python à l'aide des questions précédentes,

1. Calculer $R_{0,0}$
2. Calculer $Q_{i,0}$ pour $0 \leq i \leq I-1$
3. Calculer $R_{0,1}$
4. Calculer $R_{1,1}$
5. Calculer $Q_{i,1}$ pour $0 \leq i \leq I-1$
6. En modifiant le code généré précédemment, calculer tous les $R_{i,j}$ et $Q_{i,j}$
7. Vérifier que vous avez bien

$$M = QR, \quad Q^T Q = Id \text{ et } R \text{ triangulaire supérieure}$$

8. Encapsuler votre code sous la forme

```
def facto_QR(M):  
    # votre code  
    return Q,R
```

9. Comparer votre résultat avec

```
# Factorisation QR  
Q, R = np.linalg.qr(M)
```

Une correction : (www)

A.5 Application à la résolution d'un système linéaire

À l'aide de la décomposition QR , on cherche à résoudre le système linéaire

$$M\mathbf{x} = \mathbf{f} \text{ avec } \mathbf{f} = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Répondre aux questions suivantes :

1. Donner une formule simple pour l'inverse de Q .
2. Soit $\mathbf{y} = R\mathbf{x}$, montrer que $\mathbf{y} = Q^T\mathbf{f}$.
3. Comment trouver la solution d'un système triangulaire supérieur ?
4. Écrire un programme qui cherche $\mathbf{x}$ tel que $R\mathbf{x} = \mathbf{y}$ avec R une matrice triangulaire supérieure qui prendra la forme

```
def solve_triangulaire_sup(R, y):  
    # votre code  
    return x
```
5. Écrire un code qui calcule la factorisation QR d'une matrice puis l'utilise pour déterminer la solution de $M\mathbf{x} = \mathbf{f}$. Celui-ci prendra la forme

Une correction.(www)

Annexe B

Travaux pratiques : transformations géométriques dans $\mathbb{R}^3$

B.1 Un programme qui trace un tétraèdre

1. Créer un code qui trace le tétraèdre de sommets

$$A = \begin{bmatrix} 5 \\ 5 \\ 5 \end{bmatrix}, \quad B = \begin{bmatrix} 5 \\ 5 \\ 6 \end{bmatrix}, \quad C = \begin{bmatrix} 6 \\ 5 \\ 5 \end{bmatrix}, \quad D = \begin{bmatrix} 5 \\ 6 \\ 5 \end{bmatrix}$$

et le vérifier graphiquement sur l'exemple suivant

Squelette proposé

```
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D

def plot_tetrahedron(A,B,C,D, ax):
    # votre code

# Exemple d'utilisation:
A = np.array([5,5,5])
B = np.array([5,5,6])
C = np.array([6,5,5])
D = np.array([5,6,5])
fig = plt.figure()
ax = fig.add_subplot(111, projection='3d')
plot_tetrahedron(A,B,C,D,ax)
plt.show()
```

- 2.

La correction. (www)

B.2 Projection orthogonale dans $\mathbb{R}^3$

Les matrices de projection en algèbre linéaire sont les matrices P qui vérifient l'équation matricielle

$$P^2 = P$$

Il suit que le polynôme $p(x) = x^2 - x = x(x - 1)$ est un polynôme annulateur de P qui est scindé. La matrice P est diagonalisable et l'ensemble de ses valeurs propres est inclus dans l'ensemble des zéros de p . C'est-à-dire

$$P = Q\Lambda Q^{-1}$$

avec Q une matrice inversible et Λ une matrice diagonale dont les éléments diagonaux sont soit des 1 soit des 0

$$\Lambda = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \text{ ou } \Lambda = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \text{ ou } \Lambda = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} \text{ ou } \Lambda = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Les cas 1 et 4 n'ont que peu d'intérêt car $P = 0$ et $P = Id$. L'évaluation de P permet d'écrire

$$P = \mathbf{q}_1 \mathbf{q}_1^{-1} \text{ ou } P = \begin{bmatrix} \mathbf{q}_1 & \mathbf{q}_2 \end{bmatrix} \begin{bmatrix} \mathbf{q}_1^{-1} \\ \mathbf{q}_2^{-1} \end{bmatrix} = \mathbf{q}_1 \mathbf{q}_1^{-1} + \mathbf{q}_2 \mathbf{q}_2^{-1}$$

avec $\mathbf{q}_i$ les colonnes de Q et $\mathbf{q}_j^{-1}$ les lignes de Q^{-1}

$$Q = \begin{bmatrix} \vdots & \vdots & \vdots \\ \mathbf{q}_1 & \mathbf{q}_2 & \mathbf{q}_3 \\ \vdots & \vdots & \vdots \end{bmatrix} \quad \text{et} \quad Q^{-1} = \begin{bmatrix} \cdots & \mathbf{q}_1^{-1} & \cdots \\ \cdots & \mathbf{q}_2^{-1} & \cdots \\ \cdots & \mathbf{q}_3^{-1} & \cdots \end{bmatrix}$$

Le cas $P = \mathbf{q}_1 \mathbf{q}_1^{-1}$ correspond à la projection sur la droite de vecteur directeur $\mathbf{q}_1$ parallèlement au plan engendré par $\mathbf{q}_2$ et $\mathbf{q}_3$, tandis que le cas $P = \mathbf{q}_1 \mathbf{q}_1^{-1} + \mathbf{q}_2 \mathbf{q}_2^{-1}$ correspond à la projection sur le plan engendré par $\mathbf{q}_1$ et $\mathbf{q}_2$ parallèlement à la droite de vecteur directeur $\mathbf{q}_3$.

Comme $QQ^{-1} = Id = \mathbf{q}_1 \mathbf{q}_1^{-1} + \mathbf{q}_2 \mathbf{q}_2^{-1} + \mathbf{q}_3 \mathbf{q}_3^{-1}$, nous avons la relation

$$P = \mathbf{q}_1 \mathbf{q}_1^{-1} = Id - \mathbf{q}_2 \mathbf{q}_2^{-1} - \mathbf{q}_3 \mathbf{q}_3^{-1} \quad \text{ou} \quad P = \mathbf{q}_1 \mathbf{q}_1^{-1} + \mathbf{q}_2 \mathbf{q}_2^{-1} = Id - \mathbf{q}_3 \mathbf{q}_3^{-1}$$

Une projection **orthogonale** est une projection qui vérifie la relation $P^T = P$. Il suit que l'on peut choisir la matrice Q orthogonale. Ainsi la base $\mathbf{q}_i$ est orthonormale. Nous avons alors

$$\mathbf{q}_i^{-1} = \mathbf{q}_i^T.$$

Nous avons donc pour les deux cas non triviaux

$$P = \mathbf{q}_1 \mathbf{q}_1^T \text{ et } P = \begin{bmatrix} \mathbf{q}_1 & \mathbf{q}_2 \end{bmatrix} \begin{bmatrix} \mathbf{q}_1^T \\ \mathbf{q}_2^T \end{bmatrix} = \mathbf{q}_1 \mathbf{q}_1^T + \mathbf{q}_2 \mathbf{q}_2^T = Id - \mathbf{q}_3 \mathbf{q}_3^T.$$

Pour une projection orthogonale, il n'est donc pas nécessaire de préciser la direction de projection.

Voici quelques exemples d'application de cette théorie :

1. La matrice de projection orthogonale sur la droite engendrée par le vecteur $\mathbf{u} \neq 0$ est donnée par

$$P = \frac{\mathbf{u} \mathbf{u}^T}{\|\mathbf{u}\|^2}$$

2. La matrice de projection orthogonale sur le plan engendré par les vecteurs indépendants $\mathbf{u} \neq 0$ et $\mathbf{v} \neq 0$ est donnée par

$$P = Id - \frac{\mathbf{w} \mathbf{w}^T}{\|\mathbf{w}\|^2}$$

avec $\mathbf{w} = \mathbf{u} \times \mathbf{v}$ le produit vectoriel entre $\mathbf{u}$ et $\mathbf{v}$

$$\mathbf{w} = \begin{bmatrix} \mathbf{u}_2 \mathbf{v}_3 - \mathbf{u}_3 \mathbf{v}_2 \\ \mathbf{u}_3 \mathbf{v}_1 - \mathbf{u}_1 \mathbf{v}_3 \\ \mathbf{u}_1 \mathbf{v}_2 - \mathbf{u}_2 \mathbf{v}_1 \end{bmatrix}$$

B.3 Mise en œuvre python des projections

1. Écrire un programme qui projette orthogonalement un point $\mathbf{x}$ sur la droite de vecteur directeur $\mathbf{u}$. Tester ce programme pour

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad \text{et} \quad \mathbf{u} = \begin{bmatrix} 0 \\ 1 \\ 2 \end{bmatrix}$$

2. Écrire un programme qui projette orthogonalement un point $\mathbf{x}$ sur le plan engendré par $\mathbf{u}$ et $\mathbf{v}$. Tester ce programme pour

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad \mathbf{u} = \begin{bmatrix} 0 \\ 1 \\ 2 \end{bmatrix} \quad \text{et} \quad \mathbf{v} = \begin{bmatrix} 0 \\ 0 \\ 2 \end{bmatrix}$$

3. Représenter les images du tétraèdre de la section B.1 par ces deux transformations.

La correction (www)

B.4 Symétrie orthogonale dans $\mathbb{R}^3$

La théorie pour les symétries est la même sauf que ce sont les matrices qui vérifient

$$S^2 = Id$$

Il en existe donc de 4 types :

$$S = Q\Lambda Q^{-1}$$

avec Q une matrice inversible et Λ une matrice diagonale dont les éléments diagonaux sont soit des 1 soit des -1

$$\Lambda = \begin{bmatrix} -1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -1 \end{bmatrix} \quad \text{ou} \quad \Lambda = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -1 \end{bmatrix} \quad \text{ou} \quad \Lambda = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -1 \end{bmatrix} \quad \text{ou} \quad \Lambda = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Les cas 1 et 4 ne nécessitent pas de développements supplémentaires car $S = -Id$ et $S = Id$. L'évaluation de S permet d'écrire

$$S = \mathbf{q}_1 \mathbf{q}_1^{-1} - \mathbf{q}_2 \mathbf{q}_2^{-1} - \mathbf{q}_3 \mathbf{q}_3^{-1} = 2\mathbf{q}_1 \mathbf{q}_1^{-1} - Id \quad \text{ou} \quad S = \mathbf{q}_1 \mathbf{q}_1^{-1} + \mathbf{q}_2 \mathbf{q}_2^{-1} - \mathbf{q}_3 \mathbf{q}_3^{-1} = Id - 2\mathbf{q}_3 \mathbf{q}_3^{-1}$$

- Le premier cas correspond à la symétrie qui laisse invariante la droite engendrée par $\mathbf{q}_1$ et renverse le plan engendré par $\mathbf{q}_2$ et $\mathbf{q}_3$.
- Le second cas correspond à la symétrie qui laisse invariant le plan engendré par $\mathbf{q}_1$ et $\mathbf{q}_2$ et renverse la droite engendrée par $\mathbf{q}_3$.

On se référera à la section sur les projections pour les notations et explications.

Une symétrie **orthogonale** est une symétrie qui vérifie $S^T = S$. Avec Q orthogonale, nous avons donc pour les deux cas non triviaux

$$S = 2\mathbf{q}_1 \mathbf{q}_1^T - Id \quad \text{ou} \quad S = Id - 2\mathbf{q}_3 \mathbf{q}_3^T.$$

Application de cette théorie à des symétries orthogonales

1. La matrice de symétrie orthogonale par rapport à l'axe engendré par un vecteur $\mathbf{u}$ est donnée par

$$S = 2 \frac{\mathbf{u}\mathbf{u}^T}{\|\mathbf{u}\|^2} - Id$$

2. La matrice de symétrie orthogonale par rapport au plan engendré par deux vecteurs $\mathbf{u}$ et $\mathbf{v}$ est donnée par

$$S = Id - 2 \frac{\mathbf{w}\mathbf{w}^T}{\|\mathbf{w}\|^2}$$

avec $\mathbf{w} = \mathbf{u} \times \mathbf{v}$ le produit vectoriel entre $\mathbf{u}$ et $\mathbf{v}$

$$\mathbf{w} = \begin{bmatrix} \mathbf{u}_2 \mathbf{v}_3 - \mathbf{u}_3 \mathbf{v}_2 \\ \mathbf{u}_3 \mathbf{v}_1 - \mathbf{u}_1 \mathbf{v}_3 \\ \mathbf{u}_1 \mathbf{v}_2 - \mathbf{u}_2 \mathbf{v}_1 \end{bmatrix}$$

B.5 Mise en œuvre python des symétries

1. Coder une routine qui calcule la symétrie orthogonale d'un vecteur $\mathbf{x}$ par rapport à la droite engendrée par $\mathbf{u}$. Tester ce programme pour

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad \mathbf{u} = \begin{bmatrix} 0 \\ 1 \\ 2 \end{bmatrix}$$

2. Coder une routine qui calcule la symétrie orthogonale d'un vecteur $\mathbf{x}$ par rapport au plan $\mathbf{u}, \mathbf{v}$. Tester ce programme pour

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad \mathbf{u} = \begin{bmatrix} 0 \\ 1 \\ 2 \end{bmatrix} \quad \text{et} \quad \mathbf{v} = \begin{bmatrix} 0 \\ 0 \\ 2 \end{bmatrix}$$

3. Représenter les images du tétraèdre de la section B.1 par ces deux transformations.

La correction. (www)

Annexe C

Travaux pratiques 2 : Décomposition en valeurs singulières pour compresser les matrices

C.1 Produit matrice vecteur

Soit A la matrice carrée de taille I par I

$$A_{i,j} = \ln |y_j - x_i| \text{ avec } 0 \leq i, j \leq I-1 \text{ avec } x_i = i/I \text{ et } y_j = 3 + j/I.$$

1. Définir la matrice A en python à l'aide d'une routine qui a la forme suivante

```
def create_matrix(I):  
    # votre code  
    return M  
# Exemple d'utilisation:  
I = 5  
M = create_matrix(I)  
print(M)
```

2. Calculer et tracer en fonction de I le temps de calcul pour évaluer le produit A^2

$$I_n = 10 \cdot 2^n \quad \text{avec } n \in \llbracket 0, 10 \rrbracket.$$

La correction. (www)

C.2 Décomposition en valeurs singulières de A

Une décomposition en valeurs singulières prend la forme suivante :

$$A = UDV$$

avec U et V deux matrices unitaires et D une matrice diagonale positive.

$$U = \begin{bmatrix} \vdots & \vdots & \vdots & \vdots \\ u_0 & u_1 & \cdots & u_{I-1} \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}, \quad D = \begin{bmatrix} \sigma_0 & 0 & \cdots & 0 \\ 0 & \sigma_1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{I-1} \end{bmatrix}, \quad V = \begin{bmatrix} \cdots & v_0 & \cdots \\ \cdots & v_1 & \cdots \\ \cdots & \cdots & \cdots \\ \cdots & v_{I-1} & \cdots \end{bmatrix}$$

avec u_i les colonnes de U , v_j les lignes de V et σ_i les éléments diagonaux de D classés par ordre décroissant

$$\sigma_0 \geq \sigma_1 \geq \cdots \geq \sigma_{I-1} \geq 0.$$

Cette décomposition est calculée en python par la formule suivante :

```
U, S, V = np.linalg.svd(A)
D=np.diag(S)
```

On définit la décomposition en valeurs singulières tronquée qui est une approximation de A par

$$A^{(k)} = U^{(k)} D^{(k)} V^{(k)},$$

avec $1 \leq k \leq I - 1$

$$U^{(k)} = \begin{bmatrix} \vdots & \vdots & \vdots & \vdots \\ u_0 & u_1 & \cdots & u_{k-1} \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}, \quad D^{(k)} = \begin{bmatrix} \sigma_0 & 0 & \cdots & 0 \\ 0 & \sigma_1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{k-1} \end{bmatrix}, \quad V^{(k)} = \begin{bmatrix} \cdots & v_0 & \cdots \\ \cdots & v_1 & \cdots \\ \cdots & \cdots & \cdots \\ \cdots & v_{k-1} & \cdots \end{bmatrix}$$

1. Coder une décomposition en valeurs singulières tronquée

```
def Tsvd(A, k):
    votre code
    return Uk, Sk, Vk
```

2. Calculer en fonction de $k \in \llbracket 1, 10 \rrbracket$ pour $I = 2000$ l'erreur commise par cette décomposition tronquée. Représenter ceci sur un graphique.
3. Utiliser la décomposition en valeurs singulières tronquée pour calculer une approximation de A^2 pour $k = 10$ pour

$$I_n = 10 \cdot 2^n.$$

4. Mesurer le gain en temps de calcul, le représenter sur un graphique pour $k = 10$.

La correction. (www)

C.3 Évaluation théorique du temps de calcul

1. Combien de multiplications sont nécessaires pour évaluer A^2 par la méthode directe en fonction de I ?
2. Combien de multiplications sont nécessaires pour évaluer A^2 à l'aide de la décomposition en valeurs singulières tronquée en fonction de I et k ?
3. Quel est l'espace mémoire nécessaire pour stocker la matrice A en fonction de I ?
4. Quel est l'espace mémoire nécessaire pour stocker la décomposition en valeurs singulières de A ?
5. Faire les applications numériques pour $I = 1000$ et $k = 10$

Rappel. Un réel en python (un float) nécessite 8 octets de mémoire.

Correction.

1. Le calcul de A^2 passe par le calcul de ses I^2 coefficients

$$(A^2)_{i,j} = \sum_{k=0}^{I-1} A_{i,k} A_{k,j}$$

Chaque coefficient nécessite I multiplications. Il y a donc en tout I^3 multiplications.

2. Pour évaluer A^2 à l'aide de la SVD, on évalue
 - le produit $V_k U_k$ qui est le produit d'une matrice k par I par une matrice I par k . Elle a donc k^2 coefficients qui nécessitent chacun I multiplications.

$$k^2 I \text{ multiplications}$$

— le produit $(V_k U_k) S_k$ qui est le produit de deux matrices k par k qui nécessite

k^3 multiplications

— le produit $S_k (V_k U_k S_k)$ qui est le produit de deux matrices k par k qui nécessite

k^3 multiplications

— le produit $U_k (S_k V_k U_k S_k)$ qui est le produit d'une matrice I par k par une matrice k par k qui nécessite

$k^2 I$ multiplications

— le produit $(U_k S_k V_k U_k S_k) V_k$ qui est le produit d'une matrice I par k par une matrice k par I qui nécessite

$k I^2$ multiplications

Le calcul nécessite donc

$2k^3 + 2k^2 I + k I^2$ multiplications.

Si I est grand, il s'agit d'environ $k I^2$ multiplications. Ce nombre est pour $k = 10$ et $I = 1000$ beaucoup plus petit que I^3 .

3. Pour stocker A , il est nécessaire de stocker I^2 réels

4. Pour stocker la décomposition SVD, il est nécessaire de stocker

— $k I$ réels pour U_k

— k^2 réels pour S_k

— $k I$ réels pour V_k

C'est-à-dire $2k I + k^2$ réels (environ $2k I$ réels). Ce nombre est beaucoup plus petit que I^2 si I est grand.

Annexe D

Travaux pratiques 3 : Décomposition régulière singulière

On cherche à définir une méthode itérative pour résoudre un problème linéaire de la forme

$$\text{Chercher } \mathbf{x} \in \mathbb{C}^I \text{ tel que } A\mathbf{x} = \mathbf{f} \text{ avec } \mathbf{f} \in \mathbb{C}^I,$$

en définissant une suite $\mathbf{x}_n$ qui va tendre vers $\mathbf{x}$ à l'aide d'un algorithme de Picard.

D.1 Définition

Soit $A \in \mathbb{C}^{I \times I}$ une matrice que l'on décompose sous la forme

$$A = M - N$$

avec M une matrice inversible et $N = M - A$ telle que

$$\rho(M^{-1}N) < 1$$

On définit la suite $\mathbf{x}_n$, avec $n \in \mathbb{N}$, par

$$\mathbf{x}_0 = 0 \text{ et } M\mathbf{x}_{n+1} = N\mathbf{x}_n + \mathbf{f}$$

1. Montrer que la matrice A est inversible. Dédire le caractère bien posé du problème.
2. Montrer que la suite $\mathbf{x}_n$ converge vers la solution $\mathbf{x}$ du système linéaire

D.2 Exemples de décomposition

D.2.1 Décomposition de Jacobi

On définit la matrice $M \in \mathbb{C}^{I \times I}$ qui reproduit la diagonale de A qui vérifie

$$M_{i,j} = 0 \text{ si } i \neq j \text{ et } M_{i,i} = A_{i,i}$$

On complète alors la décomposition en définissant $N \in \mathbb{C}^{I \times I}$ par

$$N_{i,j} = -A_{i,j} \text{ si } i \neq j \text{ et } N_{i,i} = 0$$

Nous avons bien $A = M - N$.

Exemple Pour $A \in \mathbb{R}^{I \times I}$ telle que

$$A_{i,j} = 0$$

sauf si $i = j$ où

$$A_{i,i} = 5$$

et si $|i - j| = 1$ où

$$A_{i,j} = 1$$

1. Expliciter la décomposition de Jacobi
2. Montrer que $\rho(M^{-1}N) < 1$

D.2.2 Décomposition de Gauss-Seidel

On définit la matrice $M \in \mathbb{C}^{I \times I}$ qui reproduit la partie inférieure de A qui vérifie

$$M_{i,j} = 0 \text{ si } i < j \text{ et } M_{i,j} = A_{i,j} \text{ sinon.}$$

On complète alors la décomposition en définissant $N \in \mathbb{C}^{I \times I}$ par

$$N_{i,j} = -A_{i,j} \text{ si } i < j \text{ et } N_{i,j} = 0 \text{ sinon.}$$

Nous avons bien $A = M - N$.

Exercice Soit A une matrice symétrique définie positive.

1. Montrer que la diagonale de A ne contient que des nombres strictement positifs. Nous notons D la matrice qui contient la diagonale de A
2. Montrer que pour tout $\mathbf{y} \in \mathbb{R}^I$

$$(M\mathbf{y}, \mathbf{y})_0 = \frac{1}{2}(D\mathbf{y}, \mathbf{y})_0 + \frac{1}{2}(A\mathbf{y}, \mathbf{y})_0.$$

3. Montrer que M est inversible.
4. Montrer que si λ est valeur propre de $M^{-1}N$ alors il existe $\mathbf{v} \in \mathbb{C}^I$

$$\mathbf{v} \neq 0 \text{ et } N\mathbf{v} = \lambda M\mathbf{v}.$$

5. Montrer que pour tout $\mathbf{y} \in \mathbb{R}^I$

$$(N\mathbf{y}, \mathbf{y})_0 = \frac{1}{2}(D\mathbf{y}, \mathbf{y})_0 - \frac{1}{2}(A\mathbf{y}, \mathbf{y})_0.$$

6. Dédire que si $(\lambda, \mathbf{v}) \in \mathbb{R} \times \mathbb{C}^I$ est un mode propre de $M^{-1}N$ alors

$$\frac{1-\lambda}{2}(D\mathbf{v}, \mathbf{v})_0 = \frac{1+\lambda}{2}(A\mathbf{v}, \mathbf{v})_0.$$

7. Dédire que $\lambda \neq \pm 1$ et que $1 - \lambda$ et $1 + \lambda$ ont le même signe.
8. Dédire que

$$\rho(M^{-1}N) < 1$$

9. Conclure que la décomposition de Gauss-Seidel permet de définir une décomposition singulière régulière convergente

D.3 Mise en œuvre en python

D.3.1 Programmation de l'algorithme de Jacobi

Pour la matrice $A \in \mathbb{R}^{10 \times 10}$ tridiagonale telle que

$$A_{i,i} = 5, \quad A_{i,j} = -1, \quad \text{si } |i - j| = 1$$

et le second membre $\mathbf{f} = (1, 0, \dots, 0) \in \mathbb{R}^{10}$, programmer l'algorithme itératif de Jacobi en respectant le plan suivant

```
# Importation des différentes bibliothèques
# Definition de routine qui résout Dx=f matrice diagonale avec D diagonale
def resol_diago(D,f):
    return x
# Definition de la routine qui décompose A = D-N
def decompo_jacobi(A,f):
    votre code
    return D,N
# Definition de x_{n+1} en fonction de x_n
def iterateur_jacobi(x,f):
# Definition de la matrice A de l'exercice
# Definition de second membre f de l'exercice
# Calcul de M et N par la routine précédente
# Calcul de la solution x de Ax=f à l'aide de python par une autre méthode que Jacobi
# definition de x_0
# boucle pour n allant de 1 à 100
    # Calcul de x_{n+1} en fonction de x_n
    # Calcul du résidu residu[n]=|| A x_n -f ||
    # Calcul de l'erreur erreur[n]=||x_n-x||
    # affichage du numero de l'iteration, du residu et de l'erreur
# Tracer la courbe du residu et de l'erreur
```

Remarque 20. Vous ne pouvez pas espérer faire fonctionner votre code en ne testant pas votre code ligne à ligne.

Si vous codez 1 ligne et que vous faites une erreur dans cette ligne, vous n'aurez pour la trouver qu'à lire cette ligne.

Si vous codez 10 lignes et que vous faites 1 erreur, cela prendra 10 fois plus de temps à la trouver.

Dans ce cours, il vous est conseillé (c'est quasiment une obligation) d'afficher tous les objets que vous programmez afin de vérifier que vous avez programmé ce que vous espérez.

Annexe E

Résolution d'un système surdéterminé

On considère le problème de trouver le polynôme p de degré 5

$$p(x) = p_0 + p_1x + p_2x^2 + p_3x^3 + p_4x^4 + p_5x^5$$

qui approche sur $[0, 1]$ la fonction $\sin(\pi x)$. On introduit I points x_i sur le segment $[0, 1]$

$$x_i = \frac{h}{2} + i \cdot h \text{ avec } 0 \leq i \leq I-1 \text{ et } h = 1/I$$

On va chercher à résoudre le problème mal posé au sens des moindres carrés

Chercher p polynôme de degré 5 tel que $p(x_i) = \sin(\pi x_i)$.

1. Montrer que ce problème s'écrit

Chercher $\mathbf{x}_\star \in \mathbb{R}^6$ tel que $\|A\mathbf{x}_\star - \mathbf{f}\|_0 \leq \|A\mathbf{x} - \mathbf{f}\|_0$ pour tout $\mathbf{x} \in \mathbb{R}^6$,

avec $\mathbf{x}_\star \in \mathbb{R}^6$, $A \in \mathbb{R}^{I \times 6}$ et $\mathbf{f} \in \mathbb{R}^I$

$$\mathbf{x}_\star = \begin{bmatrix} p_0 \\ p_1 \\ \vdots \\ p_5 \end{bmatrix}, \quad A = \begin{bmatrix} (x_0)^0 & (x_0)^1 & (x_0)^2 & (x_0)^3 & (x_0)^4 & (x_0)^5 \\ (x_1)^0 & (x_1)^1 & (x_1)^2 & (x_1)^3 & (x_1)^4 & (x_1)^5 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ (x_{I-1})^0 & (x_{I-1})^1 & (x_{I-1})^2 & (x_{I-1})^3 & (x_{I-1})^4 & (x_{I-1})^5 \end{bmatrix}, \quad \mathbf{f} = \begin{bmatrix} \sin(\pi x_0) \\ \sin(\pi x_1) \\ \vdots \\ \sin(\pi x_{I-1}) \end{bmatrix}$$

2. Montrer que $\mathbf{x}_\star$ est solution de

$$A^* A \mathbf{x}_\star = A^* \mathbf{f}$$

3. Définir en python la matrice A , le vecteur $\mathbf{f}$ et calculer $\mathbf{x}_\star$.

4. Tracer la fonction $x \mapsto \sin(\pi x)$ et le polynôme approximateur sur le même graphique

Une correction. (www)

Annexe F

Travaux pratiques 4 : la méthode du gradient

F.1 Le problème de minimisation

Soit $A \in \mathbb{R}^{10 \times 10}$ la matrice dont tous les coefficients sont nuls sauf si $i = j$ où $A_{i,j} = 5$ et si $|i - j| = 1$ où $A_{i,j} = -1$. Soit $F : \mathbb{R}^{10} \rightarrow \mathbb{R}$

1. Montrer que A est symétrique définie positive
2. Calculer le gradient et la hessienne de F
3. Montrer que si $\mathbf{x}_\star$ minimise F alors

$$A\mathbf{x}_\star = \mathbf{f}$$

4. Montrer que le minimum de F existe et est unique.

F.2 Définition et analyse de la méthode numérique

1. Proposer une méthode de gradient à pas fixe pour résoudre ce problème
2. Rappeler le résultat de convergence pour la méthode du gradient à pas fixe
3. Proposer une méthode de gradient à pas optimal pour résoudre ce problème

F.3 Implémentation

Pour la matrice $A \in \mathbb{R}^{10 \times 10}$ tridiagonale telle que

$$A_{i,i} = 5, \quad A_{i,j} = -1, \quad \text{si } |i - j| = 1$$

et le second membre $\mathbf{f} = (1, 0, \dots, 0) \in \mathbb{R}^{10}$, programmer l'algorithme du gradient en respectant le plan suivant

```
# Importation des différentes bibliothèques
# Definition de routine qui calcule le résidu
def calcul_residu(A,f):
    epsi = ...
    return epsi
# Definition de x_{n+1} en fonction de x_n
def iterateur_gradient(x,f,epsi,alpha):
    xp=x + ...
    return xp
```

```

# définition alpha
def calcul_alpha(x,f,epsi):
    alpha = ...
    return alpha
# Definition de la matrice A de l exercice
def definition_A(I):
    A = ...
    return A
# Definition de second membre f de l exercice
def definition_f(I):
    f = ...
    return f
# Calcul de la solution x de Ax=f par une autre methode que Jacobi
# definition de x_0
# boucle pour n allant de 1 à 100
    # Calcul du résidu residu[n]=|| A x_n -f ||
    # Calcul de x_{n+1} en fonction de x_n
    # Calcul de l erreur erreur[n]=||x_n-x||
    # affichage du numero de l iteration, du residu et de l erreur
# Tracer la courbe de la norme du residu et de la norme de l erreur

```

Remarque 21. *Pour ce TP, il est important que vous repartiez de vos codes précédents afin de limiter vos temps de développement.*

Bibliographie

- [1] Grégoire ALLAIRE : *Analyse numérique et optimisation*. Éditions de l'École polytechnique, Palaiseau, 2005.
- [2] Grégoire ALLAIRE et Sidi Mahmoud KABER : *Algèbre linéaire numérique*. Ellipses, Paris, 2002.
- [3] Philippe G. CIARLET : *Introduction à l'analyse numérique matricielle et à l'optimisation*. Masson, Paris, 1982.
- [4] James W. DEMMEL : *Applied Numerical Linear Algebra*. SIAM, Philadelphia, 1997.
- [5] John G. F. FRANCIS : The QR transformation : a unitary analogue to the LR transformation, part 1. *The Computer Journal*, 4(3):265–271, 1961.
- [6] Gene H. GOLUB et Charles F. VAN LOAN : *Matrix Computations*. Johns Hopkins University Press, Baltimore, 4 édition, 2013.
- [7] Magnus R. HESTENES et Eduard STIEFEL : Methods of conjugate gradients for solving linear systems. *Journal of Research of the National Bureau of Standards*, 49(6):409–436, 1952.
- [8] Alston S. HOUSEHOLDER : Unitary triangularization of a nonsymmetric matrix. *Journal of the ACM*, 5(4):339–342, 1958.
- [9] Patrick LASCAUX et Raymond THÉODOR : *Analyse numérique matricielle appliquée à l'art de l'ingénieur*. Masson, Paris, 1986. 2 tomes.
- [10] Alfio QUARTERONI, Riccardo SACCO et Fausto SALERI : *Méthodes numériques : algorithmes, analyse et applications*. Springer, Milan, 2007.
- [11] Yousef SAAD : *Iterative Methods for Sparse Linear Systems*. SIAM, Philadelphia, 2 édition, 2003.
- [12] Lloyd N. TREFETHEN : *Approximation Theory and Approximation Practice*. SIAM, Philadelphia, 2013.
- [13] Lloyd N. TREFETHEN et David BAU, III : *Numerical Linear Algebra*. SIAM, Philadelphia, 1997.